TRABAJO FIN DE GRADO

Técnicas de Machine Learning y Deep Learning para anotación de células en datos de single-cell RNA seq

Convocatoria de junio, curso 2025/2026

A mi familia, y a todos los que hicieron especial esta etapa. Gracias.

Resumen

La secuenciación de ARN de célula única permite analizar la expresión génica de células individuales con un nivel de resolución sin precedentes. Con el creciente número de herramientas de análisis de datos de scRNA-seq desarrolladas, ha surgido la necesidad de establecer metodologías capaces de procesar y extraer conocimiento biológico de conjuntos de datos transcriptómicos cada vez más complejos y heterogéneos.

En este Trabajo Fin de Grado se estudian y reproducen diferentes técnicas de Machine Learning y Deep Learning aplicadas a la anotación celular en datos de scRNA-seq. Para ello, se realiza una revisión del estado del arte de las principales metodologías empleadas en el análisis de datos transcriptómicos de célula única y de los enfoques actuales de anotación celular automática. La parte experimental se estructura en dos bloques. El primero analiza distintos métodos de anotación celular sobre datos del proyecto Mouse Cell Atlas mediante el framework DANCE. El segundo aborda el análisis de datos de glioblastoma sobre tecnologías SmartSeq2 y 10X Genomics.

Finalmente, este trabajo refleja la creciente relevancia de las técnicas de Machine Learning y Deep Learning en el análisis de datos de scRNA-seq, así como algunos de los principales desafíos actuales, las posibles líneas futuras de trabajo y la importancia de la reproducibilidad experimental dentro de este campo de investigación emergente.

Palabras clave: secuenciación de ARN de célula única, scRNA-seq, anotación celular, transcriptómica, Machine Learning, Deep Learning, bioinformática, clasificación celular, análisis transcriptómico, DANCE

Abstract

Single-cell RNA sequencing enables the analysis of gene expression in individual cells with an unprecedented level of resolution. With the increasing number of scRNA-seq data analysis tools that have been developed, the need has emerged for methodologies capable of processing and extracting biological knowledge from increasingly complex and heterogeneous transcriptomic datasets.

This Bachelor's Thesis studies and reproduces different Machine Learning and Deep Learning techniques applied to cell annotation in scRNA-seq data. To this end, a review of the state of the art of the main methodologies employed in single-cell transcriptomic data analysis and current approaches to automatic cell annotation is carried out. The experimental section is structured into two blocks. The first analyzes different cell annotation methods on data from the Mouse Cell Atlas project using the DANCE framework. The second addresses the analysis of glioblastoma data using SmartSeq2 and 10X Genomics technologies.

Finally, this work highlights the growing importance of Machine Learning and Deep Learning techniques in scRNA-seq data analysis, as well as some of the major current challenges, potential future research directions, and the importance of experimental reproducibility within this emerging field of research.

Keywords: single-cell RNA sequencing, scRNA-seq, cell annotation, transcriptomics, Machine Learning, Deep Learning, bioinformatics, cell classification, transcriptomic analysis, DANCE

Índice general

Material suplementario XII

1 Motivación 1
1.1. El problema de la anotación celular 3
1.2. Objetivos 3

2 Metodología 6
2.1. Planificación de tareas y fases 6
2.2. Planificación temporal 9
2.3. Planificación de los experimentos 11
2.4. Análisis de costes 11
2.4.1. Metodología de cálculo y fuentes 11
2.4.2. Costes de personal 12
2.4.3. Costes de infraestructura y suministros 12

3 Introducción 14
3.1. Tecnologías para la secuenciación de células individuales 14
3.1.1. Tecnologías clasificadas por modalidad 16
3.2. Datos de scRNA-seq 20
3.2.1. Adquisición 22
3.2.2. Preprocesamiento 25
3.2.3. Procesamiento 26
3.2.4. Análisis posterior 31
3.3. Matriz de conteos 36
3.4. Tareas en el análisis de scRNA-seq 37
3.4.1. Imputación 38

4 El problema de la anotación celular 41
4.1. Introducción 41
4.2. Métodos automáticos 41
4.2.1. Métodos basados en genes marcadores 43
4.2.2. Métodos basados en referencia 44
4.2.3. Métodos basados en clasificación supervisada 44
4.3. Retos actuales 53
4.4. Herramientas y frameworks 55
4.4.1. DANCE 55
4.4.2. Scanpy 58

5 Primer experimento 60
5.1. Conjunto de datos 61
5.1.1. Configuración 62
5.1.2. Estructura 63

5.2. Primera parte: evaluación de modelos de anotación celular con preprocesado nativo de DANCE sobre Mouse from MCA 66
5.2.1. Procesamiento 67
5.2.2. Entrenamiento de modelos 68
5.2.3. Resultados 69
5.3. Segunda parte: evaluación de modelos de anotación celular con preprocesado de Scanpy sobre Mouse from MCA 73
5.3.1. Transformación de los datos 73
5.3.2. Procesamiento 75
5.3.3. Clustering 81
5.3.4. Entrenamiento de modelos 83
5.3.5. Resultados 84
5.4. Discusión 86

6 Segundo experimento 88
6.1. Introducción 88
6.2. Datos de gliobastoma 90
6.3. Análisis exploratorio y clasificación pseudo-supervisada sobre el subconjunto 10X de glioblastoma 91
6.3.1. Planteamiento 91
6.3.2. Carga e inspección de los datos 92
6.3.3. Procesamiento 95
6.3.4. Clustering 100
6.3.5. Entrenamiento de modelos 101
6.3.6. Resultados 103
6.4. Anotación supervisada sobre el subconjunto SmartSeq2 de glioblastoma 106
6.4.1. Planteamiento 106
6.4.2. Carga e inspección de los datos 106
6.4.3. Procesamiento 110
6.4.4. Clustering 113
6.4.5. Entrenamiento de modelos 114
6.4.6. Resultados 115
6.5. Discusión 116

7 Conclusiones 118
7.1. Trabajos futuros 118

8 Anexos 120
8.1. Anexo A. Repositorio de Github 120
8.2. Anexo B. Entorno de ejecución 120
8.3. Anexo C. Dependencias del entorno de ejecución 120

9 Glosario de términos 124

Bibliografía 125

Índice de figuras

1.1. Representación conceptual y matemática de la limitación del Bulk RNA-seq. La heterogeneidad celular se colapsa en un vector de expresión medio $\bar{\mathbf{x}}$. La información sobre subpoblaciones minoritarias y la varianza intercelular desaparece durante el proceso de lisis y promediado de la señal. 1
1.2. Comparativa de las estructuras de datos transcriptómicos. A) El perfilado bulk colapsa la heterogeneidad celular en un vector de medias aritméticas. B) El paradigma single-cell captura la dimensionalidad total de la muestra. 2

2.1. Diagrama de Gantt: planificación temporal detallada del proyecto. . . . 10
2.2. Esquema del flujo experimental. 11

3.1. Incremento exponencial del rendimiento en scRNA-seq. La adopción de tecnologías de microfluidos marcó el inicio de la era del Big Data en biología unicelular. 15
3.2. Taxonomía de tareas computacionales en genómica de célula única. Clasificación jerárquica que distingue entre enfoques unimodales, integraciones multivariantes y análisis con resolución espacial. 16
3.3. Visualización de matrices de datos generadas mediante tecnologías de célula única. Basada en [1] 17
3.4. Esquema conceptual de integración multimodal entre scATAC-seq y scRNA-seq. La accesibilidad cromatínica en regiones reguladoras, como promotores y enhancers, condiciona la unión de factores de transcripción y, en consecuencia, la expresión génica observada mediante scRNA-seq. Figura extraída de [2]. 19
3.5. Visualización de transcriptómica espacial. Organización tisular mediante gradiente de expresión. Figura extraída de [3]. 20
3.6. Esquema de un flujo de trabajo estándar de análisis de scRNA-seq. Cada etapa (separada por líneas discontinuas) consta de una serie de pasos específicos. Figura extraída de [4]. 22
3.7. En el protocolo SMART-seq3, las células se lisan y las secuencias de ARN se transcriben inversamente, se amplifican y se preparan en bibliotecas listas para la secuenciación. Figura extraída de [5]. 23
3.8. En la secuenciación de ARN de célula única basada en gotas, las células individuales se encapsulan con microesferas con código de barras en gotas de aceite, lo que permite la lisis celular, la captura de ARN, la transcripción inversa y la amplificación para generar ADNc con código de barras único para cada célula. Figura extraída de [5]. 24
3.9. Esquema ilustrativo del uso de códigos de barras celulares y UMIs en experimentos de scRNA-seq basado en gotas. Figura extraída de Macosko et al. [6]. 25

3.10. Representación esquemática de una matriz de conteos en datos de scRNA-seq. Figura extraída del material docente de The Rockefeller University [7]. 26
3.11. La reducción de la dimensionalidad permite proyectar datos de alta dimensión en un espacio de menor dimensión. En la figura se muestra la proyección de un objeto tridimensional en dos dimensiones. Figura extraída de [8]. 30
3.12. Esquema conceptual del análisis downstream en scRNA-seq. Adaptada de [9]. 32
3.13. El algoritmo de Leiden calcula una agrupación en un grafo KNN obtenido del espacio de expresión reducido PC. Figura extraída de [8]. . 34
3.14. Representación de una matriz de conteos en datos de secuenciación de ARN de célula única. Las filas representan genes y las columnas células individuales. Cada entrada de la matriz contiene el número de moléculas de ARN detectadas para un gen en una célula determinada. . 36
3.15. Matriz de conteos en datos de secuenciación de ARN de célula única. La columna resaltada en rojo representa los recuentos de todos los genes en una célula específica (j), donde cada elemento indica el número de lecturas o UMIs asociados a un gen concreto en dicha célula. De manera análoga, la fila resaltada en verde muestra los recuentos de un gen específico (i) en todas las células. La intersección entre la fila verde y la columna roja representa el recuento correspondiente al gen (i) en la célula (j), ilustrando la cantidad detectada de transcritos de dicho gen en esa célula concreta. Figura extraída de [10]. 37
3.16. Clasificación de los algoritmos para imputación de datos scRNA-seq. . . 38
3.17. Ilustración del flujo de trabajo de la etapa de imputación del método scImpute. En primer lugar, scImpute estima la probabilidad de dropout de cada gen en cada célula mediante el ajuste de un modelo de mezcla. Posteriormente, los valores identificados con alta probabilidad de corresponder a eventos de dropout en la célula j (conjunto de genes A_j) son imputados utilizando información del mismo gen en otras células transcriptómicamente similares, seleccionadas a partir del conjunto de genes B_j, menos afectados por eventos de dropout. Figura extraída de [11]. 39
3.18. Esquema general del método scRMD. (A) La matriz de expresión observada puede descomponerse en una matriz subyacente de bajo rango L, una matriz de dropouts S y una matriz de ruido E. (B) Tras la imputación realizada por scRMD, los métodos convencionales de análisis de datos RNA-seq pueden aplicarse sobre la matriz de expresión reconstruida. Figura extraída de [12]. 39

4.1. Esquema de SingleCellNet (SCN). SCN selecciona los mejores pares de genes de clasificación de los datos de entrenamiento utilizando un enfoque similar al algoritmo Top-scoring-pair y los transforma en una matriz binaria. Luego se entrena un clasificador de bosque aleatorio multiclase con los datos de entrenamiento transformados. Los datos de scRNA-Seq de consulta también se transformarán en pares y se genera una puntuación de clasificación para cada célula de consulta. Figura extraída de [13]. 46
4.2. Esquema general del desarrollo y funcionamiento de CellTypist. (A) Recopilación de muestras procedentes de distintos tejidos humanos linfoides y no linfoides. (B) Perfilado transcriptómico de célula única junto con secuenciación de receptores inmunitarios TCR y BCR. (C) Flujo de trabajo de CellTypist, incluyendo recopilación y procesamiento de datos, entrenamiento del modelo y predicción de tipos celulares, junto con la evolución del rendimiento durante el entrenamiento mediante descenso estocástico por mini-lotes. (D) Representación UMAP de las células inmunitarias coloreadas según el tejido de origen. (E) Representación UMAP coloreada según los tipos celulares predichos por CellTypist. Figura extraída de [14]. 47
4.3. Representación del funcionamiento de una máquina de vectores de soporte (SVM). Figura extraída de [15] 49
4.4. Comparación conceptual entre redes neuronales artificiales tradicionales y arquitecturas de aprendizaje profundo. Las arquitecturas profundas incorporan múltiples capas ocultas capaces de aprender representaciones jerárquicas y no lineales de los datos transcriptómicos. Figura extraída de [16]. 50
4.5. Marco conceptual general y validación de scDeepSort. (A) Se seleccionaron atlas de transcriptómica de células individuales humanas y de ratón de HCL y MCA como datos subyacentes para entrenar scDeepSort. (B) Para cada célula, se construyó una red gráfica de esta célula, sus genes y células vecinas para el aprendizaje supervisado de scDeepSort con etiquetas celulares conocidas de los atlas transcriptómicos para cada tejido. (C) Se emplearon conjuntos de datos internos de atlas humanos y de ratón y conjuntos de datos de prueba externos de datos de transcriptómica de células individuales que involucran múltiples tejidos para probar el rendimiento de scDeepSort. Se compararon los métodos de anotación dependientes de marcadores y perfiles con scDeepSort. Figura extraída de [17]. 52
4.6. Perspectiva del usuario de la plataforma DANCE. a Descripción general del flujo de análisis ómico de células individuales con la plataforma DANCE. b Tareas posteriores compatibles actualmente en DANCE. Figura extraída de [18]. 56
4.7. Resumen de los módulos, tareas, modelos y conjuntos de datos compatibles con el paquete DANCE. Figura extraída de [18]. 57
4.8. Comparativa de librerías para el análisis de célula única. Figura extraída de [18]). 57

4.9. Estructura interna del objeto `AnnData` utilizado para el almacenamiento y análisis de datos de secuenciación de ARN de célula única. La matriz principal `X` contiene los valores de expresión génica, mientras que los distintos componentes auxiliares almacenan metadatos celulares (`obs`), información génica (`var`), representaciones embebidas (`obsm`), grafos de vecindad (`obsp`), capas adicionales (`layers`) y otra información no estructurada (`uns`). Figura extraída de [19]. 59

5.1. Diagrama del flujo experimental del Experimento 1. 61
5.2. Conjuntos de datos de ratón (mouse) disponibles dentro de la herramienta DANCE, correspondientes a distintos tejidos, entre ellos el cerebro (brain), rodilla (kidney) o bazo (spleen). 62
5.3. Representación del objeto AnnData y la organización de metadatos. Basada en [20]. 64
5.4. Distribución de los 11 tipos celulares del conjunto de datos. 65
5.5. Distribución de las poblaciones celulares según su correspondencia a células neuronales o no neuronales. 65
5.6. Flujo de trabajo de la primera parte del experimento. 66
5.7. Comparación del rendimiento entre la implementación de los modelos en DANCE y los resultados reportados en las publicaciones originales para tareas de clustering y anotación de tipos celulares. Los resultados obtenidos con DANCE corresponden al valor medio tras 20 ejecuciones con distintas semillas aleatorias, mientras que los valores originales han sido extraídos directamente de los artículos de referencia [18]. 69
5.8. Comparación del rendimiento de los modelos en el dataset Mouse Brain. 70
5.9. Comparación del F1-score macro entre los modelos evaluados. 71
5.10. Matrices de confusión de los modelos evaluados. 72
5.11. Proyección PCA del conjunto de test diferenciando aciertos y errores del modelo Celltypist. 73
5.12. Estructura de la clase `obsm['cell_type']`. 74
5.13. Transformación de la estructura `obsm['cell_type']` a formato categórico. 74
5.14. Distribución de métricas de calidad celular representadas mediante diagramas de caja (boxplots). En el panel izquierdo se muestra el número de genes detectados por célula (n genes), mientras que en el panel derecho se representa el número total de conteos o lecturas (n counts). 76
5.15. Distribución de métricas de calidad celular representadas mediante diagramas de violín. 77
5.16. Diagrama de dispersión que relaciona el número total de conteos con el número de genes detectados por célula, coloreado según el porcentaje de expresión de genes ribonucleicos (pct counts ribo). 77
5.17. Representación de la selección de genes altamente variables. A la izquierda se muestra la dispersión normalizada frente a la expresión media de los genes, mientras que a la derecha se representa la dispersión no normalizada. 78
5.18. Proporción de varianza explicada por los primeros componentes principales obtenidos mediante PCA. 79

5.19. Distribución de distintas métricas de calidad celular sobre el espacio definido por los primeros componentes principales. Se representan variables relacionadas con el número total de conteos, el número de genes detectados y los porcentajes asociados a genes ribosomales y hemoglobínicos. 80
5.20. Representación UMAP del conjunto de datos coloreada según distintas métricas de calidad celular y variables descriptivas. Se muestran el número total de conteos (`total_counts`), el número de genes detectados (`n_genes_by_counts`) y los porcentajes asociados a genes ribosomales (`pct_counts_ribo`) y hemoglobínicos (`pct_counts_hb`). 81
5.21. Representación UMAP coloreada según los clústeres obtenidos mediante el algoritmo Leiden. Se emplea la resolución estándar de Scanpy (`resolution = 1`), obteniéndose un total de 19 clústeres diferenciados. 81
5.22. Representación UMAP coloreada según la anotación celular original del conjunto de datos. 82
5.23. Genes diferencialmente expresados por clúster obtenido mediante el test de Wilcoxon implementado en Scanpy. Se muestran los genes más representativos de cada agrupación identificada mediante Leiden. 82
5.24. Resumen de los principales genes diferencialmente expresados asociados a cada clúster identificado mediante Leiden. 83
5.25. Matrices de confusión de los modelos evaluados. 85

6.1. Diseño experimental asociado al dataset SCP393. Se distinguen dos ramas: clasificación pseudo-supervisada sobre el conjunto 10X y análisis supervisado sobre el conjunto Smart-seq2. 89
6.2. Esquema del objeto `AnnData` sobre el subconjunto 10X. La matriz central `X` contiene los datos de expresión, mientras que las estructuras blancas laterales (`obs` y `var`) contienen los metadatos de células y genes respectivamente. 93
6.3. Distribución del número de genes detectados por célula y el número total de conteos. 94
6.4. Relación entre el número total de conteos y número de genes detectados. 94
6.5. Distribución del número de genes detectados por célula. 96
6.6. Representación de la selección de genes altamente variables. A la izquierda se muestra la dispersión normalizada frente a la expresión media de los genes, mientras que a la derecha se representa la dispersión no normalizada. 97
6.7. Proporción de varianza explicada por los primeros componentes principales obtenidos mediante PCA. 98
6.8. Representación UMAP del subconjunto 10X tras la construcción del grafo de vecinos sobre el espacio PCA. 99
6.9. Representación mediante t-SNE del subconjunto 10X. 100
6.10. Proyección UMAP coloreada según distintas métricas de calidad celular: número total de conteos (`total_counts`), número de genes detectados (`n_genes_by_counts`) y probabilidad estimada de doblete (`doublet_score`). 100

6.11. Algoritmo Leiden sobre la proyección UMAP utilizando distintas resoluciones (resolution=0.25 y 1.0). Se observa cómo el incremento de la resolución produce una subdivisión progresiva de las agrupaciones celulares. 101
6.12. Matrices de confusión de los modelos evaluados. 105
6.13. Fragmento de la matriz de expresión génica original del subconjunto Smart-seq2 antes de la construcción del objeto AnnData. 107
6.14. Esquema del objeto AnnData para el dataset Smart-seq2. Se destaca la integración de la matriz de expresión génica con los metadatos celulares (obs) y las anotaciones genómicas (var). 108
6.15. Diagramas de violín de las métricas de calidad celular calculadas sobre el subconjunto Smart-seq2: número de genes detectados por célula (n_genes_by_counts), número total de conteos (total_counts) y porcentaje de expresión concentrado en los 50 genes más expresados (pct_counts_in_top_50_genes). 109
6.16. Relación entre el número total de conteos y el número de genes detectados por célula. 110
6.17. Distribución de la puntuación de doblete (doublet_score) sobre el subconjunto Smart-seq2. La mayoría de las células presentan valores bajos, mientras que un reducido conjunto de observaciones muestra puntuaciones elevadas compatibles con posibles dobletes. 111
6.18. Representación de la selección de genes altamente variables. A la izquierda se muestra la dispersión normalizada frente a la expresión media de los genes, mientras que a la derecha se representa la dispersión no normalizada. 111
6.19. Proporción de varianza explicada por los primeros componentes principales obtenidos tras aplicar PCA sobre el subconjunto de genes altamente variables (HVGs). 112
6.20. Proyección UMAP del subconjunto Smart-seq2 coloreada según distintas métricas de calidad celular: número total de conteos (total_counts), número de genes detectados por célula (n_genes_by_counts) y puntuación de doblete (doublet_score). 112
6.21. Proyección UMAP del subconjunto Smart-seq2 coloreada según la anotación biológica original CellAssignment. 113
6.22. Resultados del clustering mediante Leiden representados sobre el espacio UMAP utilizando distintas resoluciones (resolution=0.25 y resolution=1.0). El incremento de la resolución produce una subdivisión progresiva de las agrupaciones celulares y una mayor granularidad en la estructura identificada. 114
6.23. Matrices de confusión de los modelos evaluados. 116

Índice de tablas

2.1. Resumen de las fases y objetivos del proyecto. 6
2.2. Planificación temporal y estimación de carga de trabajo por fase. 9
2.3. Distribución temporal del proyecto por meses. 10
2.4. Presupuesto estimado del proyecto. 13

3.1. Hitos tecnológicos en la evolución de la secuenciación de ARN. 14
3.2. Comparativa de tecnologías de perfilado multimodal de célula única. . . 18
3.3. Comparación entre los algoritmos Louvain y Leiden para detección de comunidades en datos scRNA-seq. 34

4.1. Herramientas para la anotación automática de tipos celulares en datos scRNA-seq [21]. 43
4.2. Resumen de los marcos de trabajo ampliamente utilizados en aprendizaje profundo y aprendizaje sobre grafos. Tabla extraída de [1]. . 53

5.1. Configuración del dataset elegido en el experimento. 63
5.2. Resumen de los flujos de procesamiento según el modelo a partir de los tutoriales oficiales de DANCE. 68
5.3. Rendimiento de los modelos de anotación celular en el dataset Mouse Brain. 70
5.4. Resumen del flujo de procesamiento implementado en Scanpy. 75
5.5. Resumen del entrenamiento de modelos de DANCE utilizando el preprocesamiento propio implementado en Scanpy. 84
5.6. Resultados obtenidos por los modelos de anotación celular utilizando el flujo de procesamiento implementado en Scanpy. 85
5.7. Comparación de la métrica Accuracy entre los experimentos realizados con el flujo de trabajo de DANCE y el procesamiento de datos con Scanpy. 86

6.1. Comparación del desarrollo experimental entre los subconjuntos 10X y SmartSeq2 empleados en el Segundo Experimento. 91
6.2. Ejemplo de asignación de pseudoetiquetas Leiden a células individuales. 102
6.3. Resultados de clasificación sobre el subconjunto 10X de glioblastoma. . . 104
6.4. Resumen estadístico de las principales métricas de control de calidad celular. 109
6.5. Resultados de clasificación sobre el subconjunto SmartSeq2 de glioblastoma 115

8.1. Dependencias y versiones utilizadas en el entorno de ejecución del Experimento 1 basado en DANCE. 122
8.2. Dependencias y versiones utilizadas en el Experimento 2. 123

Material suplementario

A continuación, se adjunta el enlace al repositorio de Github utilizado durante el desarrollo del presente trabajo, en el que se encuentra organizado el código empleado en los distintos experimentos.

Asimismo, la estructura completa del repositorio, junto con las instrucciones de uso y organización de los contenidos, se encuentra detallada en el archivo `README` incluido en el propio repositorio.

Enlace: *Enlace al repositorio omitido para preservar el anonimato de la candidatura.*

1. Motivación

El organismo humano constituye un sistema altamente complejo formado por billones de células que, aún compartiendo un mismo genoma, presentan funciones y comportamientos profundamente diferenciados. Esta diversidad celular surge de la regulación de la expresión génica, un proceso intrínsecamente estocástico, con aleatoriedad en la transcripción y la traducción que conduce a variaciones de célula a célula en los niveles de ARNm y proteínas. [22]. Esta variabilidad, dependiente de parámetros biofísicos y de la estructura de la red génica, dicta la identidad y el estado funcional de cada unidad biológica ante procesos críticos como el metabolismo, el desarrollo o el ciclo celular.

La división y diferenciación celular conducen a variaciones en los patrones de expresión génica, lo que constituye la causa subyacente de la heterogeneidad existente entre las células [23]. Históricamente, la técnica de secuenciación de ARN tradicional o Bulk RNA-seq solo podía detectar la expresión génica media de la población celular; no permite identificar la heterogeneidad entre las células y puede pasar fácilmente por alto la expresión específica de subconjuntos celulares. Matemáticamente, esto equivale a trabajar con un vector de expresión medio $\bar{x}$, donde se pierde la varianza intercelular y las subpoblaciones minoritarias quedan diluidas en el ruido estadístico de los tipos celulares más abundantes.

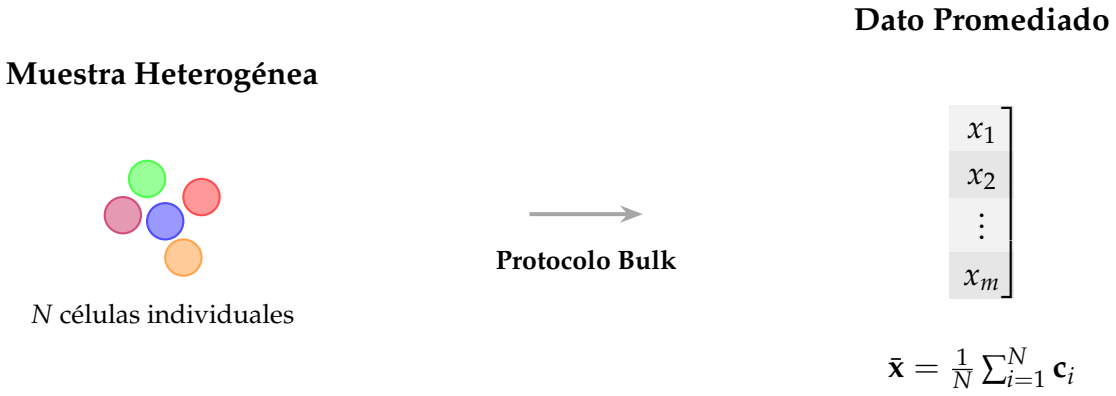


Figura 1.1: Representación conceptual y matemática de la limitación del Bulk RNA-seq. La heterogeneidad celular se colapsa en un vector de expresión medio $\bar{\mathbf{x}}$. La información sobre subpoblaciones minoritarias y la varianza intercelular desaparece durante el proceso de lisis y promediado de la señal.

Con el continuo avance de la ciencia y la tecnología, se han ido desarrollando gradualmente métodos de secuenciación del transcriptoma de células individuales de alto rendimiento. La secuencia de ARN unicelular ha permitido estudiar la expresión génica con una resolución sin precedentes.

Estos nuevos métodos han mejorado el rendimiento y los límites de detección de la secuenciación del transcriptoma, lo que permite un análisis imparcial y de alto

rendimiento del transcriptoma de células individuales. Se han convertido en una nueva tecnología para revelar la composición de los tejidos y las relaciones de regulación génica. El punto de inflexión se sitúa en 2009 con el trabajo de Tang et al. [24], quienes demostraron la viabilidad de realizar el perfilado transcriptómico a partir de una única célula (scRNA-seq).

A) Paradigma Bulk RNA-seq

Vector de expresión medio $\bar{\mathbf{x}}$

Expresión Media
μ_{g_1}
μ_{g_2}
$\vdots$
μ_{g_m}

$\bar{\mathbf{x}} \in \mathbb{R}^{m \times 1}$

Baja resolución: señal promediada

B) Paradigma scRNA-seq

Matriz multivariante $\mathbf{X}$

$\mathbf{c}_1$	$\mathbf{c}_2$	$\mathbf{c}_3$	$\mathbf{c}_4$	$\dots$
0.8	0.1	0.0	1.2	$\dots$
0.0	0.5	0.9	0.0	$\dots$
1.1	0.0	0.4	0.7	$\dots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$

$\mathbf{X} \in \mathbb{R}^{m \times n}$

Alta resolución: varianza preservada

Figura 1.2: Comparativa de las estructuras de datos transcriptómicos. A) El perfilado bulk colapsa la heterogeneidad celular en un vector de medias aritméticas. B) El paradigma single-cell captura la dimensionalidad total de la muestra.

En los últimos años, la rápida evolución de las tecnologías scRNA-seq ha provocado un incremento exponencial en la cantidad y complejidad de los datos generados. Actualmente, es posible analizar cientos de miles o incluso millones de células en un único experimento mediante plataformas de alto rendimiento [25]. Como consecuencia, el análisis transcriptómico unicelular ha pasado a formar parte del contexto del Big Data biomédico, donde la elevada dimensionalidad, la dispersión de los datos y el ruido técnico representan importantes desafíos [9].

En este escenario, las técnicas de Machine Learning y Deep Learning han adquirido una relevancia creciente dentro de la bioinformática. Estos enfoques permiten extraer patrones complejos a partir de grandes volúmenes de información transcriptómica y automatizar tareas que tradicionalmente requerían una elevada intervención manual y conocimiento experto [26]. Entre dichas tareas, uno de los principales desafíos en el análisis de datos scRNA-seq es la identificación y clasificación precisa de los distintos tipos celulares presentes en una muestra biológica.

El objetivo del análisis transcriptómico unicelular ya no se limita a detectar poblaciones celulares mayoritarias, sino a asignar identidades biológicas precisas a millones de células de manera reproducible, robusta y escalable. Por tanto, los modelos basados en aprendizaje automático y aprendizaje profundo se han consolidado como herramientas fundamentales para automatizar la anotación celular.

1.1. El problema de la anotación celular

> *"El reto del análisis de células individuales ya no consiste solo en capturar los datos, sino en asignar un significado biológico a la vasta diversidad de estados celulares que hemos descubierto."* — [27]

La tarea de anotación de tipos celulares no es trivial: constituye el proceso crítico de asignar una identidad biológica a cada perfil de expresión génica tras la secuenciación [21]. Este procedimiento es clave para comprender la estructura y función de los sistemas biológicos, así como para el estudio de enfermedades complejas como el cáncer, donde la heterogeneidad celular es una característica central en la interpretación de los datos [23].

Desde una perspectiva biológica, clasificar las unidades en grupos y categorías es esencial para su estudio y permite establecer paralelismos entre unidades análogas que se encuentran tanto en diferentes compartimentos del cuerpo como en especies distintas. Sin embargo, definir qué es un «tipo» celular presenta dificultades fundamentales: los niveles de expresión génica no siempre son binarios, sino que pueden variar gradualmente a lo largo de un espectro[27].

Tradicionalmente, la anotación se ha basado en algoritmos de clustering no supervisado seguidos de una inspección manual de genes marcadores. Un enfoque directo es comparar los perfiles de expresión single-cell con datasets previamente anotados, donde cualquier dataset de expresión génica etiquetado puede ser usado como una referencia. Sin embargo, su confiabilidad depende enormemente en la calidad de los datos originales y la experiencia de los autores originales.

Ante la magnitud y complejidad de los datos transcriptómicos, la anotación se aborda actualmente como un problema de aprendizaje supervisado [28]. Formalmente, dado un conjunto de entrenamiento $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}$, donde $\mathbf{x}_i \in \mathbb{R}^d$ representa el perfil de expresión y y_i la etiqueta biológica, el objetivo es inducir un modelo $f : \mathcal{X} \to \mathcal{Y}$ capaz de generalizar dicha identidad a nuevas observaciones.

La integración de redes neuronales profundas y marcos de trabajo como DANCE [29] busca estandarizar este análisis. No obstante, la aplicación de Deep Learning y Machine Learning en este ámbito continúa enfrentando una amplia diversidad de retos..

1.2. Objetivos

El presente trabajo se centra en estudiar y comprender el problema de la anotación celular de tipos celulares en datos de secuenciación de ARN de célula única, una tarea primordial que transforma datos crudos de expresión génica en conocimiento biológico interpretatable. Por lo tanto, el objetivo principal de este Trabajo Fin de Grado es el estudio y evaluación comparativa de diversas estrategias de anotación automática de tipos celulares en datos de scRNA-seq, fundamentadas en algoritmos de Machine Learning y Deep Learning.

En particular, se enfoca en comprender las principales etapas que componen los flujos de análisis transcriptómico de célula única, en investigar el impacto que ejercen las etapas de procesamiento sobre la capacidad predictiva de los modelos y en evaluar diferentes enfoques metodológicos apoyados en herramientas especializadas como Scanpy y DANCE.

Para alcanzar esta meta, se definen los siguientes objetivos específicos:

- **Estudio del estado del arte:** realizar una revisión bibliográfica y técnica de las principales metodologías empleadas en el análisis de datos de secuenciación de ARN de célula única, prestando especial atención a las técnicas de anotación celular automática basadas en Machine Learning y Deep Learning, así como a los principales frameworks, herramientas y enfoques utilizados actualmente en este ámbito.
- **Análisis del pipeline de procesamiento de datos scRNA-seq:** estudiar las diferentes etapas que componen un flujo típico de análisis transcriptómico de célula única, incluyendo procesos de control de calidad, normalización, selección de genes altamente variables, reducción de dimensionalidad, clustering y clasificación celular mediante herramientas especializadas de análisis bioinformático.
- **Preparación y configuración del entorno experimental:** configurar los entornos de ejecución necesarios para el desarrollo de los experimentos, incluyendo la instalación y gestión de librerías, dependencias, frameworks y herramientas especializadas empleadas en el análisis de datos de scRNA-seq y en la evaluación de modelos de anotación celular.
- **Estudio de modelos de anotación celular:** analizar distintos métodos supervisados de anotación celular automática, tanto basados en técnicas clásicas de Machine Learning como en arquitecturas de Deep Learning, evaluando sus características, limitaciones y comportamiento sobre conjuntos de datos de referencia.
- **Reproducción experimental mediante frameworks especializados:** reproducir experimentos de anotación celular utilizando frameworks especializados sobre datasets de referencia, en particular la librería DANCE, garantizando condiciones metodológicas homogéneas que permitan realizar comparaciones entre modelos.
- **Evaluación comparativa de modelos:** comparar el rendimiento de diferentes modelos de clasificación celular mediante métricas de evaluación, analizando el impacto del procesamiento y de las transformaciones realizadas sobre los resultados obtenidos.
- **Análisis transcriptómico sobre datos reales:** aplicar técnicas de análisis y anotación celular sobre datasets biológicos reales mediante enfoques supervisados y no supervisados, estudiando la estructura transcriptómica y la heterogeneidad celular presente en los datos.
- **Estudio de la reproducibilidad experimental:** analizar las dificultades asociadas a la reproducibilidad de pipelines y entornos de trabajo en análisis de scRNA-seq, incluyendo dependencias de librerías, frameworks especializados y configuraciones experimentales.

- **Identificación de limitaciones y futuras líneas de investigación:** examinar las principales limitaciones actuales de los métodos de anotación celular automática y plantear posibles líneas de trabajo futuras.

El resto del trabajo se estructura de la siguiente manera. En el Capítulo 2 se presenta la organización y metodología del trabajo realizado. A continuación, en el Capítulo 3 se introducen los principales conceptos relacionados con los datos de secuenciación de ARN de célula única, incluyendo las principales tecnologías de secuenciación, los flujos generales de análisis y las tareas más relevantes en el ámbito del análisis de datos scRNA-seq.

Posteriormente, el Capítulo 4 aborda específicamente el problema de la anotación celular automática, describiendo las principales estrategias y técnicas basadas en Machine Learning y Deep Learning.

Los Capítulos 5 y 6 recogen el desarrollo experimental del trabajo, donde se presentan los distintos experimentos realizados, así como los procedimientos de procesamiento, entrenamiento y evaluación de modelos llevados a cabo sobre diferentes conjuntos de datos.

Finalmente, el documento concluye con el Capítulo 7, en el que se exponen las conclusiones obtenidas y las posibles líneas de trabajo futuro. Además, se incluye un glosario de términos en el Capítulo 9 y los anexos correspondientes en el Capítulo 8.

2. Metodología

2.1. Planificación de tareas y fases

En la planificación del presente proyecto reside la simplificación de las tareas a realizar, estudiar las posibles desviaciones en la implementación de este proyecto y con la finalización del mismo, analizar el rendimiento de cada tarea realizada, comparando las estimaciones con el tiempo real empleado.

En este sentido, el trabajo se organiza en una serie de fases interrelacionadas que abarcan desde la comprensión del problema hasta la obtención y análisis de resultados. A diferencia de una planificación estrictamente secuencial, se ha optado por una organización flexible que permite la superposición parcial de tareas, facilitando así la adaptación a incidencias y la mejora continua del pipeline experimental.

Tabla 2.1: Resumen de las fases y objetivos del proyecto.

Fase del Proyecto	Objetivo
Fase 1: Análisis y diseño del estudio	Establecer el marco teórico, realizar la revisión bibliográfica de *scRNA-seq* y definir el diseño experimental.
Fase 2: Configuración del trabajo	Implementar el entorno en *Google Colab* y asegurar la reproducibilidad mediante la gestión de dependencias y versiones críticas.
Fase 3: Experimento 1 (Mouse)	Evaluar modelos en un entorno de referencia, contrastando el *pipeline* nativo de *DANCE* frente a un flujo en *Scanpy*.
Fase 4: Experimento 2 (GBM)	Analizar el comportamiento de los modelos en un escenario real de mayor complejidad biológica, evaluando su capacidad de generalización y la coherencia de las predicciones.
Fase 5: Análisis global de resultados	Sintetizar los hallazgos, comparar el rendimiento de los modelos y analizar el impacto biológico y computacional de los resultados.
Fase 6: Desarrollo de la memoria y repositorio Github	Formalizar la documentación académica y publicar el código fuente.
Fase 7: Revisión y defensa	Consolidar la calidad formal del documento, integrar correcciones y preparar la exposición oral ante el tribunal.

Fase 1: Análisis y diseño del estudio

Durante esta fase inicial se lleva a cabo un estudio teórico sobre el contexto científico y técnico en el que se enmarca el trabajo. En primer lugar, se realiza una revisión bibliográfica centrada en las tecnologías de secuenciación de célula única (scRNA-seq), así como en la naturaleza y estructura de los datos generados. Paralelamente, se analiza el problema de la anotación celular desde distintas perspectivas, incluyendo enfoques supervisados basados en clasificación y métodos no supervisados como el clustering.

Asimismo, se estudian herramientas y frameworks especializados en el análisis de datos de célula única, específicamente DANCE y posteriormente Scanpy, prestando especial atención a sus pipelines de preprocesamiento y capacidades de modelado. A partir de este análisis, se seleccionan los modelos de anotación celular que serán evaluados. Finalmente, se define el diseño experimental del trabajo, estableciendo dos escenarios principales: un primer experimento sobre un dataset de referencia (Mouse) y un segundo experimento sobre un caso real (glioblastoma).

Fase 2: Configuración de trabajo

En esta fase se establece el entorno computacional necesario para el desarrollo del proyecto. Para ello, se procede a la instalación y configuración de las principales librerías utilizadas, incluyendo herramientas de análisis de datos de célula única, bibliotecas de aprendizaje automático y frameworks de deep learning. Se define Google Colab como el entorno de ejecución controlado, lo que permite aislar dependencias y evitar conflictos entre versiones. En esta etapa, se abordan posibles incompatibilidades entre librerías, ajustando versiones de paquetes críticos como NumPy, scikit-learn o PyTorch.

Posteriormente, se realiza una verificación del correcto funcionamiento del entorno mediante la ejecución de pruebas básicas. Finalmente, se documenta la configuración del entorno, incluyendo versiones de paquetes y parámetros relevantes, con el objetivo de garantizar la reproducibilidad de los experimentos.

Fase 3: Experimento 1 – Dataset Mouse

En esta fase se desarrolla el primer bloque experimental del trabajo, centrado en un dataset de referencia correspondiente a tejido cerebral de ratón (Mouse). El uso de este conjunto de datos permite evaluar el comportamiento de los modelos de anotación celular en un entorno controlado, con etiquetas celulares disponibles y una estructura adecuada para la comparación experimental.

Este primer experimento se plantea en dos partes diferenciadas. En primer lugar, se desarrolla el experimento 1.1, en el que se utiliza el flujo de trabajo proporcionado por DANCE, tanto para el preprocesamiento de los datos como para la configuración, entrenamiento y evaluación de los modelos. Este trabajo permite analizar el comportamiento de los algoritmos dentro del marco metodológico propio de la librería.

Posteriormente, se lleva a cabo el experimento 1.2, en el que se modifica el flujo experimental anterior mediante la incorporación de un pipeline externo de preprocesamiento basado en Scanpy. En esta segunda aproximación, se realiza la carga e inspección del dataset, el filtrado de células y genes, el cálculo de métricas de control de calidad, la normalización, la transformación logarítmica y la selección de genes altamente variables. Asimismo, se aplican técnicas de reducción de dimensionalidad y visualización, como PCA y UMAP, junto con métodos de clustering no supervisado, con el objetivo de analizar la estructura interna del dataset antes de aplicar los modelos.

Una vez obtenidos los datos preprocesados mediante ambos enfoques, se procede al entrenamiento y evaluación de los modelos seleccionados. De este modo, el experimento permite comparar el rendimiento de los algoritmos bajo dos estrategias de preprocesamiento distintas: el pipeline nativo de DANCE y un pipeline personalizado basado en Scanpy. Los resultados se analizan mediante métricas, proporcionando una visión global tanto del comportamiento de los modelos como del efecto del pipeline de preprocesamiento sobre su rendimiento.

Fase 4: Experimento 2 – Dataset Glioblastoma

En esta fase se traslada el enfoque desarrollado a un dataset real de mayor complejidad, correspondiente a muestras de glioblastoma. Inicialmente, se lleva a cabo la construcción del dataset a partir de archivos de expresión génica en formato matricial, junto con los archivos asociados de genes y células. A continuación, se realiza una inspección inicial, analizando su estructura, calidad y posibles particularidades derivadas de su origen experimental. Seguidamente, se aplica un pipeline de preprocesamiento utilizando Scanpy similar al del experimento anterior, incluyendo filtrado, normalización, selección de genes variables y reducción de dimensionalidad.

Posteriormente, se lleva a cabo un análisis exploratorio mediante técnicas de clustering y visualización, con el objetivo de identificar posibles estados celulares o poblaciones tumorales. Esta fase incluye una interpretación biológica de los resultados. Finalmente, se aplican los modelos de anotación celular previamente seleccionados y analizados mediante métricas.

Fase 5: Análisis global de resultados

En esta fase se realiza una interpretación conjunta de los resultados obtenidos en ambos experimentos. Se comparan los resultados del dataset de referencia con los del caso real, analizando las diferencias en el comportamiento de los modelos en función de la complejidad de los datos. Asimismo, se estudia el impacto de los distintos pipelines de preprocesamiento sobre el rendimiento de los modelos, evaluando en qué medida influyen en la calidad de la anotación celular. Se lleva a cabo una comparación detallada entre los distintos modelos utilizados, identificando sus fortalezas y limitaciones. Finalmente, se discuten los resultados identificando posibles limitaciones del estudio, tanto a nivel de datos como de metodología, y proponiendo líneas futuras de trabajo.

Fase 6: Desarrollo de la memoria y repositorio Github

Durante esta fase se documenta de forma estructurada todo el trabajo realizado. Se redactan los distintos capítulos de la memoria y se incorporan además figuras, tablas y visualizaciones que permiten ilustrar los resultados y facilitar su interpretación.

Fase 7: Revisión final y preparación de la defensa

En la fase final se realizan las últimas revisiones del documento, incorporando las correcciones y sugerencias.

2.2. Planificación temporal

El desarrollo del trabajo se inicia el 20 de febrero de 2026 y se organiza en una planificación temporal que combina estructura y flexibilidad. Dado el carácter experimental del proyecto, se ha considerado la posibilidad de iteración entre fases, especialmente entre las etapas de preprocesamiento, experimentación, documentación y análisis. La dedicación total estimada al proyecto se sitúa entre 330 horas, distribuidas entre las distintas fases del trabajo.

Tabla 2.2: Planificación temporal y estimación de carga de trabajo por fase.

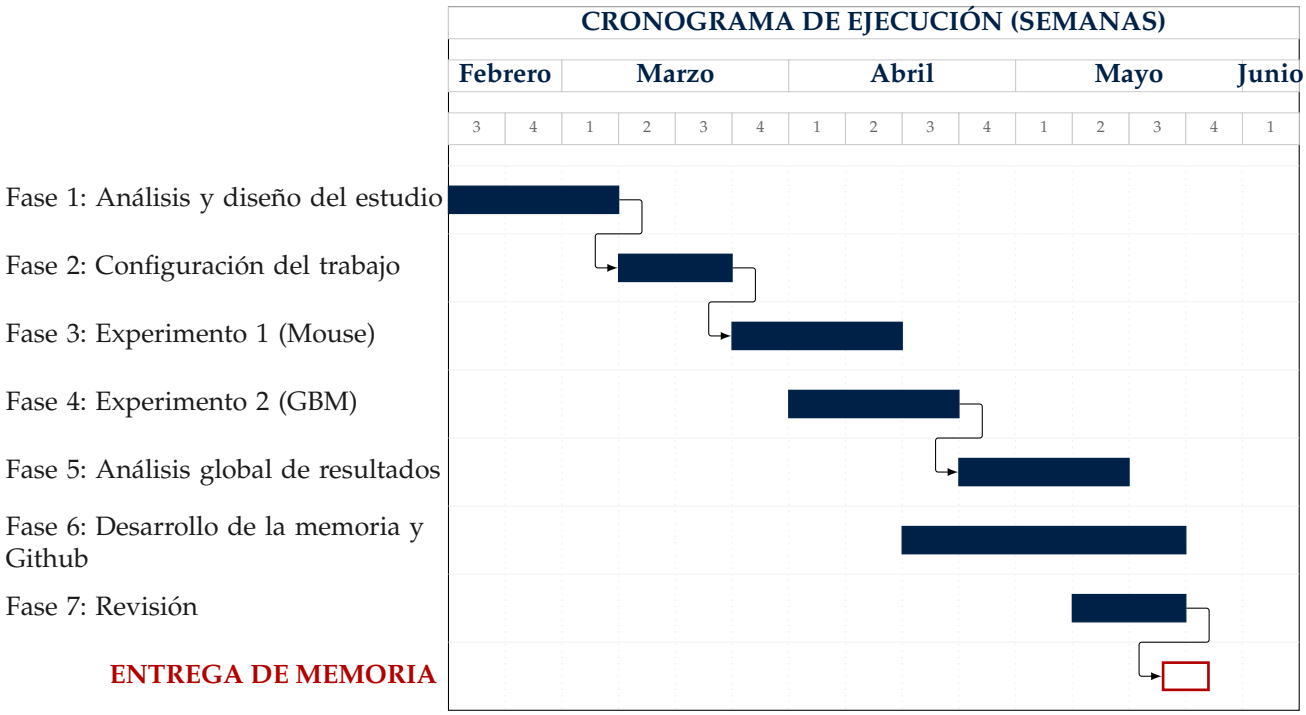
Fase del Proyecto	Periodo	Duración	Horas
Fase 1: Análisis y diseño del estudio	20 Feb – 10 Mar	3 semanas	25 h
Fase 2: Configuración del trabajo	11 Mar – 25 Mar	2 semanas	30 h
Fase 3: Experimento 1 (Mouse)	25 Mar – 10 Abr	2 semanas	75 h
Fase 4: Experimento 2 (GBM)	5 Abr – 20 Abr	2 semanas	60 h
Fase 5: Análisis global de resultados	20 Abr – 10 May	3 semanas	40 h
Fase 6: Desarrollo de la memoria y Github	15 Abr – 20 May	5 semanas	80 h
Fase 7: Revisión y defensa	16 May – 8 Jun	3 semanas	20 h

Tabla 2.3: Distribución temporal del proyecto por meses.

Fase del Proyecto	Feb	Mar	Abr	May	Jun
Fase 1: Análisis y diseño del estudio	X	X			
Fase 2: Configuración del trabajo		X			
Fase 3: Experimento 1 (Mouse)		X	X		
Fase 4: Experimento 2 (GBM)			X		
Fase 5: Análisis global de resultados			X	X	
Fase 6: Desarrollo de la memoria y Github			X	X	
Fase 7: Revisión y defensa				X	X

A continuación, se presenta el diagrama de Gantt correspondiente a la planificación temporal del proyecto. Esta representación gráfica permite visualizar de forma clara la distribución de las fases en el tiempo, así como el solapamiento entre las etapas del trabajo.

Figura 2.1: Diagrama de Gantt: planificación temporal detallada del proyecto.



2.3. Planificación de los experimentos

El desarrollo experimental del trabajo se ha estructurado en dos bloques principales, definidos en función del tipo de dataset utilizado, la disponibilidad de anotaciones celulares y el objetivo de cada análisis.

En primer lugar, se plantea un experimento sobre un dataset de referencia correspondiente a tejido cerebral de ratón. Este bloque permite evaluar modelos de anotación celular en un entorno controlado, utilizando el framework DANCE y la implementación de un flujo de procesamiento mediante Scanpy.

En segundo lugar, se desarrolla un experimento sobre datos de glioblastoma procedentes del estudio SCP393. Este bloque se divide, a su vez, en dos aproximaciones: una pseudo-supervisada sobre el subconjunto 10X, basada en etiquetas generadas mediante clustering, y otra supervisada sobre el subconjunto Smart-seq2, utilizando la variable `CellAssignment` como referencia biológica.

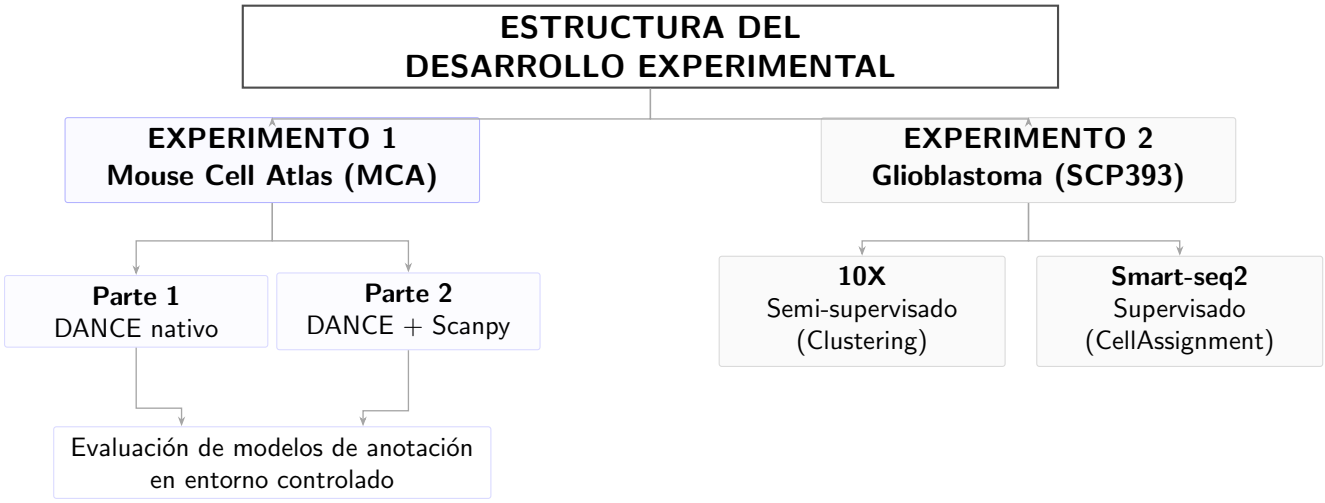


Figura 2.2: Esquema del flujo experimental.

2.4. Análisis de costes

El análisis económico del proyecto permite cuantificar el valor de mercado de los recursos invertidos. El coste total se desglosa en costes de personal (capital humano) y costes de infraestructura (hardware y suministros).

2.4.1. Metodología de cálculo y fuentes

Para la estimación de costes, se ha seguido una metodología de presupuesto por administración, fundamentada en las siguientes fuentes:

- **Costes salariales:** Datos extraídos de los informes de tendencias salariales de *Glassdoor* y *Payscale* (2024) para perfiles tecnológicos en España [30].

- **Costes sociales:** Tipos de cotización vigentes de la Seguridad Social para el año 2024 [31].
- **Amortización:** Método lineal basado en la vida útil estimada para equipos informáticos según las tablas de amortización de la Agencia Tributaria.

2.4.2. Costes de personal

El desarrollo ha sido realizado íntegramente por un perfil de *Machine Learning Engineer*. Según las fuentes consultadas, la retribución media bruta anual para este rol en España se sitúa en 53,960 €. Tomando como referencia una jornada laboral de 1,760 horas anuales (según convenio del sector), se obtiene el coste horario base:

$$\text{Coste base hora} = \frac{53{,}960\,€}{1{,}760\,\text{h}} \approx 30,65\,€/\text{h} \tag{2.1}$$

Sin embargo, para el cálculo mensualizado sobre el tiempo efectivo del proyecto (330 horas distribuidas en 4 meses), se aplica la siguiente fórmula:

$$\text{Sueldo mensual bruto} = \frac{53{,}960\,€}{12\ \text{meses}} = 4{,}496,67\,€/\text{mes}$$
$$\text{Costo horario efectivo} = \frac{4{,}496,67\,€}{160\ \text{h/mes}} = 28,10\,€/\text{h}$$

Aplicando la carga de horas del proyecto y el tipo de cotización a la Seguridad Social a cargo de la empresa (23,6 %):

$$\text{Subtotal personal} = 330\,\text{h} \times 28,10\,€/\text{h} = 9{,}273,00\,€$$
$$\text{Total Personal (incl. SS)} = 9{,}273,00\,€ \times 1,236 = 11{,}461,43\,€$$

2.4.3. Costes de infraestructura y suministros

Se ha utilizado un equipo *MacBook Air M1* (PVP 1,129 €). Siguiendo el criterio de amortización lineal a 5 años (60 meses) y habiendo dedicado 4 meses al proyecto:

$$\text{Amortización} = \frac{1{,}129\,€}{60\ \text{meses}} \times 4\ \text{meses} = 75,27\,€$$

Los suministros operativos se han calculado en base al consumo nominal del hardware y las tarifas actuales de conexión:

- **Coste energético:** $0,2\,\text{kW} \times 330\,\text{h} \times 0,13\,€/\text{kWh} = 8,58\,€$.
- **Conectividad:** Proporcional de una tarifa plana de $20\,€/\text{mes} \times 4$ meses $\times$ factor de uso $\approx 9,04\,€$.

Tabla 2.4: Presupuesto estimado del proyecto.

Concepto	Importe (€)
Coste de personal (Ingeniería + SS)	11.461,43
Amortización de equipo informático	75,27
Coste energético estimado	8,58
Conexión a internet	9,04
Subtotal	**11.554,32**
Reserva de contingencia (10 %)	1.155,43
TOTAL ESTIMADO DEL PROYECTO	**12.709,75**

Como se desprende de la Tabla 2.4, el coste total asciende a 12,709,75 **€**. Es importante destacar que el uso de herramientas de software libre (*Scanpy, DANCE, PyTorch*) ha permitido un ahorro del 100 % en concepto de licencias de software comercial.

3. Introducción

En el presente Capítulo 3, se exponen las principales bases y conocimientos relacionados con el análisis de datos de secuenciación de ARN de célula única. Para ello, se describen las principales tecnologías de célula única, la estructura de los datos scRNA-seq y las distintas etapas del flujo de análisis, desde la adquisición y procesamiento de los datos hasta algunas de las tareas más relevantes.

3.1. Tecnologías para la secuenciación de células individuales

La tecnología de secuenciación fue desarrollada por primera vez por Eberwine et al. e Iscove et al. mediante la expansión del cDNA. Sin embargo, no fue hasta la creación de scRNA-seq en 2009 con el trabajo de Tang et al. [24] que los métodos de célula única realmente ganaron mayor impulso [1].

La transición definitiva hacia el análisis de alta resolución se consolidó con la introducción de las tecnologías de microfluidez basadas en gotas (droplet-based), representadas por protocolos pioneros como Drop-seq [6] y la posterior estandarización a través de la plataforma comercial 10x Genomics Chromium. Estas metodologías han permitido escalar el rendimiento de forma exponencial: pasando de analizar decenas de células en los trabajos fundacionales de Tang2009, a procesar bibliotecas masivas que oscilan entre 10^5 y 10^6 perfiles transcriptómicos de forma simultánea. Como se detalla en la Tabla 3.1, esta evolución cronológica marca el paso de protocolos manuales a sistemas automatizados de alto rendimiento.

Tabla 3.1: Hitos tecnológicos en la evolución de la secuenciación de ARN.

Año	Tecnología / Hito	Avance Computacional	Referencia Clave
2009	Primer protocolo scRNA-seq	Análisis de célula única vs. tejido	Tang et al.
2012	Smart-seq	Mayor cobertura de transcritos	Ramsköld et al.
2015	Drop-seq / InDrops	Uso de códigos de barras (Barcoding)	Macosko et al.
2017	10x Genomics	Estandarización de flujos de trabajo	Zheng et al.
2020+	Atlas Celulares Masivos	Integración de Big Data y Deep Learning	Human Cell Atlas

Este incremento sin precedentes en la capacidad de captura, ilustrado en la progresión logarítmica de la Figura 3.1, ha desplazado el desafío crítico desde la generación del dato hacia su interpretación biológica. El volumen y la naturaleza de

estos conjuntos de datos, caracterizados por una alta dimensionalidad y una elevada tasa de valores nulos o dropouts, hacen que los métodos tradicionales de inspección manual de marcadores genéticos resulten técnica y logísticamente inasumibles.

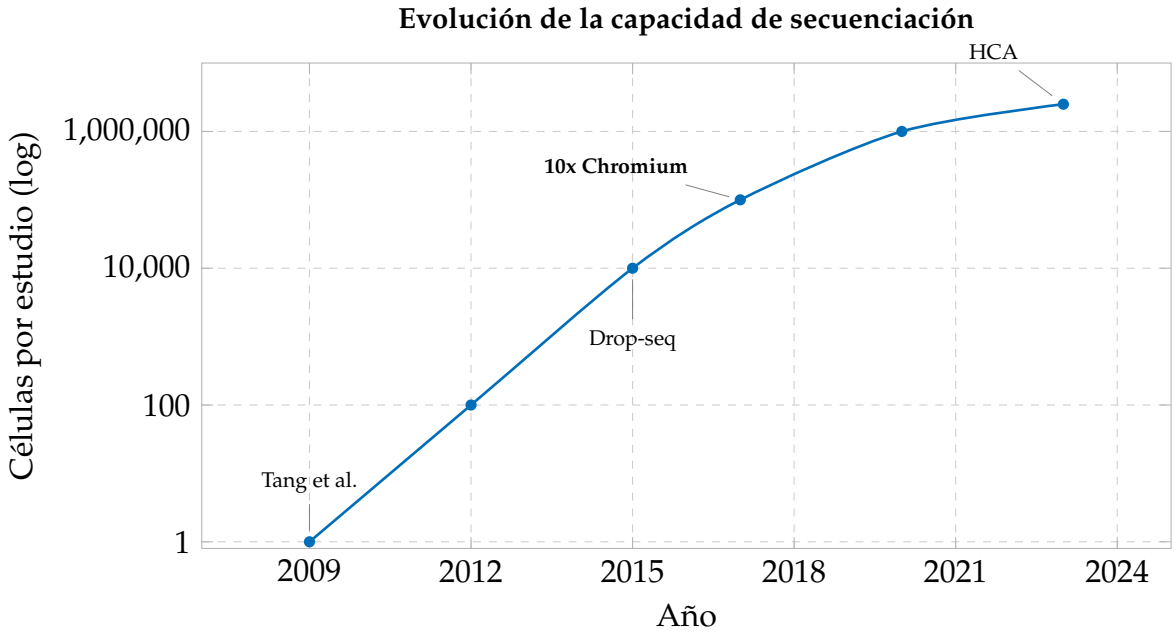


Figura 3.1: Incremento exponencial del rendimiento en scRNA-seq. La adopción de tecnologías de microfluidos marcó el inicio de la era del Big Data en biología unicelular.

A pesar de compartir un mismo objetivo experimental, las distintas tecnologías de secuenciación unicelular presentan diferencias sustanciales tanto en su arquitectura experimental como en las propiedades de los datos generados. En términos generales, los protocolos actuales pueden agruparse en dos grandes categorías: tecnologías de placa (plate-based) y tecnologías basadas en microfluidos o gotas (droplet-based).

Los métodos de placa, como Smart-seq y Smart-seq2, priorizan una elevada cobertura transcriptómica por célula, permitiendo detectar isoformas y genes de baja expresión con gran sensibilidad. Sin embargo, estos protocolos presentan un menor rendimiento escalable y un coste experimental considerablemente superior.

Por el contrario, las tecnologías basadas en gotas, como Drop-seq [6] o 10x Genomics Chromium [25], sacrifican parcialmente la profundidad de secuenciación individual a cambio de procesar simultáneamente cientos de miles de células mediante sistemas de microfluidez y estrategias de barcoding molecular.

Esta dicotomía entre profundidad transcriptómica y capacidad de escalado condiciona directamente las estrategias posteriores de análisis computacional. Mientras los protocolos de alta cobertura generan perfiles más ricos biológicamente, las plataformas masivas introducen mayores niveles de sparsity y ruido técnico, lo que repercute de forma significativa sobre tareas como la reducción de dimensionalidad, el clustering o la anotación automática de tipos celulares.

3.1.1. Tecnologías clasificadas por modalidad

Las tecnologías de célula única proporcionan una mayor resolución de las diferencias celulares y pueden atribuir comportamientos biológicos a células individuales [32]. A medida que una gama cada vez mayor de tecnologías de perfilado de célula única ha ampliado las posibilidades para el análisis de biología computacional, se han hecho evidentes más señales de interés previamente ocultas.

Este apartado, se centra en las tres categorías de tecnologías de células individuales, es decir, perfilado de una sola modalidad, perfilado multimodal y transcriptómica espacial. Además, se proporciona la taxonomía de las tareas computacionales mencionadas en este trabajo en la Figura 3.2.

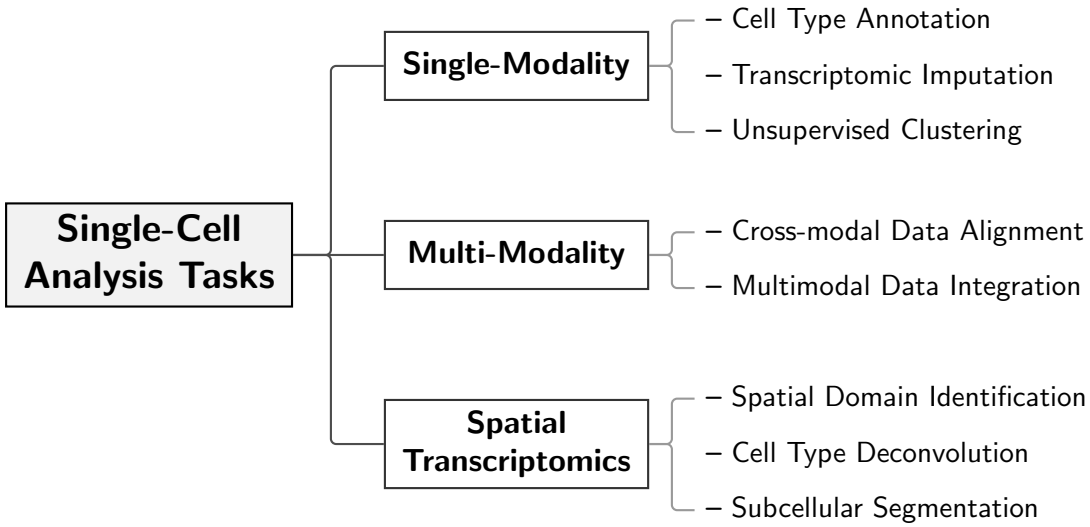


Figura 3.2: Taxonomía de tareas computacionales en genómica de célula única. Clasificación jerárquica que distingue entre enfoques unimodales, integraciones multivariantes y análisis con resolución espacial.

Perfilado de modalidad única

El perfilado de modalidad única constituye el pilar fundacional de la genómica de célula única, permitiendo la caracterización de la heterogeneidad celular mediante el análisis de una única capa de información molecular. Entre las distintas tecnologías desarrolladas, el análisis transcriptómico mediante single-cell RNA sequencing (scRNA-seq) se ha consolidado como la modalidad predominante, impulsado por la maduración de plataformas de microfluídica de gotas, como 10x Genomics Chromium, y métodos basados en placas, como Smart-seq2 [25, 33]. Estas aproximaciones han permitido identificar estados celulares raros, caracterizar poblaciones transitorias y reconstruir trayectorias dinámicas de diferenciación celular mediante algoritmos de pseudotiempo [34].

Paralelamente, el estudio de la accesibilidad de la cromatina mediante single-cell Assay for Transposase-Accessible Chromatin sequencing(scATAC-seq) ha emergido como una modalidad crítica para caracterizar el paisaje regulatorio y el potencial epigenético de las células individuales [35]. A diferencia de scRNA-seq, que cuantifica

directamente la abundancia de transcritos, scATAC-seq permite identificar regiones de cromatina abierta asociadas a elementos reguladores, como promotores, potenciadores (enhancers) y sitios de unión de factores de transcripción.

Los datos de célula única a menudo se dan en forma de una matriz, con características (por ejemplo, genes, proteínas o intervalo de ADN) que corresponden a las columnas y cada célula como una fila, como se muestra en la Figura 3.3.

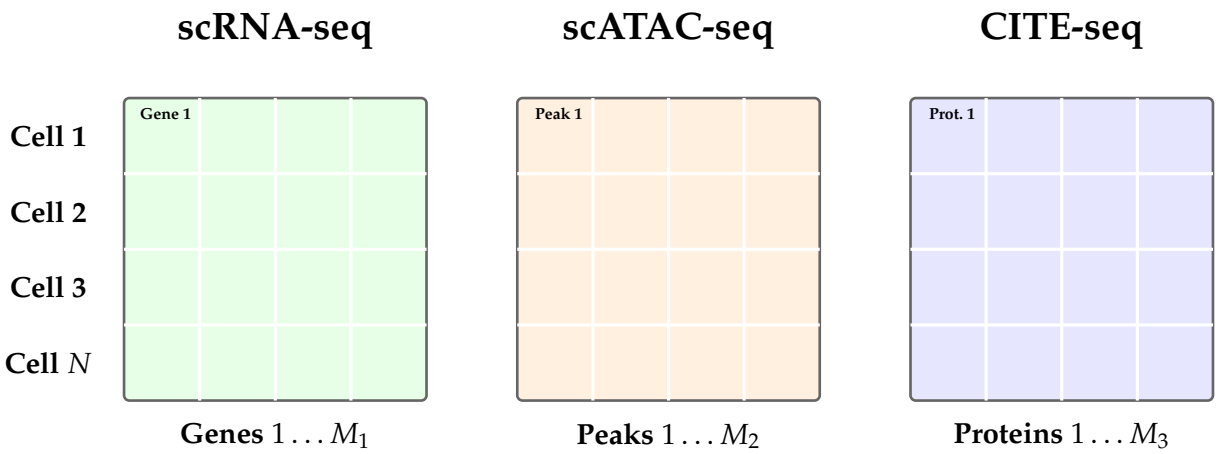


Figura 3.3: Visualización de matrices de datos generadas mediante tecnologías de célula única. Basada en [1]

A pesar del enorme éxito de estas tecnologías unimodales, cada modalidad captura únicamente una fracción parcial del estado celular. Mientras que scRNA-seq proporciona una instantánea de la actividad transcripcional, scATAC-seq permite inferir el estado regulatorio y el potencial epigenético subyacente. Esta limitación ha impulsado el desarrollo de estrategias multimodales capaces de integrar simultáneamente distintas capas de información molecular dentro de una misma célula.

Perfilado multimodal

Más allá del transcriptoma y el epigenoma, el proteoma celular representa una dimensión esencial, dado que las proteínas constituyen las unidades funcionales ejecutoras de la mayoría de los procesos biológicos. Las discrepancias observadas entre los niveles de ARNm y la abundancia proteica —atribuidas a tasas de degradación diferencial y regulación post-traduccional— subrayan la necesidad de mediciones simultáneas [36]. No obstante, si bien las técnicas de secuenciación de célula única para mediciones del transcriptoma se han proliferado ampliamente, los métodos de proteómica de célula única han progresado más lentamente debido a la imposibilidad de amplificar proteínas, a diferencia de los ácidos nucleicos.

Para superar esta limitación, han surgido tecnologías híbridas como CITE-seq (Cellular Indexing of Transcriptomes and Epitopes by Sequencing) y *REAP-seq*, que emplean anticuerpos conjugados con oligonucleótidos para cuantificar proteínas de superficie simultáneamente con el transcriptoma completo [37]. En el ámbito de la

cromatina, protocolos como SNARE-seq y SHARE-seq permiten vincular la accesibilidad genómica con la expresión génica en la misma célula, proporcionando una visión integrada del dogma central de la biología y permitiendo inferir mecanismos de regulación *cis* en el desarrollo celular [38, 39].

Tabla 3.2: Comparativa de tecnologías de perfilado multimodal de célula única.

Método	Analitos Capturados	Tecnología	Rendimiento
CITE-seq	Transcriptoma (ARNm) y proteínas de superficie (Epitopos)	Microfluídica	Alto ($> 10^4$)
REAP-seq	Transcriptoma (ARNm) y proteínas de superficie (Epitopos)	Microfluídica	Alto ($> 10^4$)
SNARE-seq	Transcriptoma (ARNm) y accesibilidad de cromatina (ATAC)	Microfluídica	Medio ($> 10^3$)
ECCITE-seq	ARNm, proteínas, perturbaciones CRISPR y TCR/BCR	Microfluídica	Alto ($> 10^4$)
ASAP-seq	Accesibilidad de cromatina (ATAC) y proteínas de superficie	Microfluídica	Alto ($> 10^4$)

En este sentido, las tecnologías multimodales permiten relacionar directamente la accesibilidad cromatínica con la actividad transcripcional, facilitando la identificación de redes regulatorias celulares y mecanismos de control génico. La integración conjunta de scRNA-seq y scATAC-seq posibilita conectar la expresión de factores de transcripción con la actividad de elementos reguladores y con los programas transcripcionales resultantes.

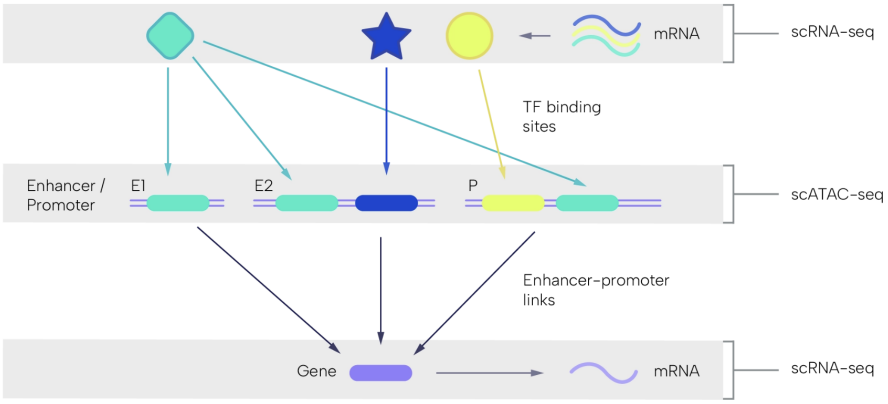


Figura 3.4: Esquema conceptual de integración multimodal entre scATAC-seq y scRNA-seq. La accesibilidad cromatínica en regiones reguladoras, como promotores y enhancers, condiciona la unión de factores de transcripción y, en consecuencia, la expresión génica observada mediante scRNA-seq. Figura extraída de [2].

Transcriptómica espacial de células individuales

La transcriptómica espacial representa el avance más reciente hacia la comprensión de la organización tisular, resolviendo la limitación crítica de los métodos convencionales que requieren la disociación celular y, por ende, la pérdida del contexto anatómico. Esta tecnología permite mapear la expresión génica conservando la arquitectura tisular, lo cual es fundamental para estudiar nichos celulares y comunicaciones parácrinas [40].

Existen dos aproximaciones metodológicas principales en este campo: los métodos basados en captura espacial y posterior secuenciación (ej. Visium, Slide-seq), que utilizan barcodes espaciales en una superficie de captura [41]; y los métodos basados en imagen, como MERFISH y seqFISH+, que emplean hibridación *in situ* fluorescente múltiple para detectar cientos de genes con resolución subcelular [3]. La integración computacional de estos datos espaciales plantea retos significativos, como la deconvolución de tipos celulares en *spots* que contienen múltiples células y la identificación de dominios espaciales funcionalmente coherentes mediante algoritmos de aprendizaje profundo [42, 29].

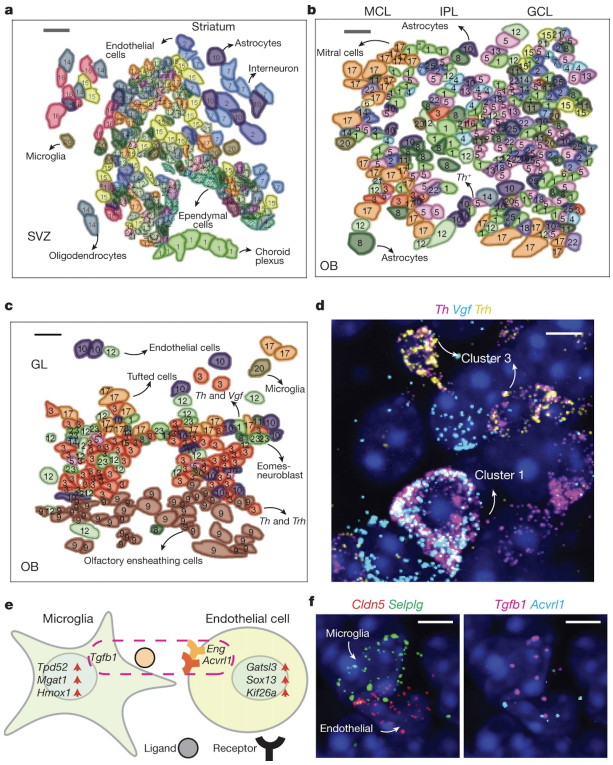


Figura 3.5: Visualización de transcriptómica espacial. Organización tisular mediante gradiente de expresión. Figura extraída de [3].

3.2. Datos de scRNA-seq

El análisis de los datos de células individuales a gran escala nos permiten abordar cuestiones biológicas que antes eran inaccesibles. En primer lugar, ahora podemos explorar la identidad de una célula individual y los factores subyacentes, sin depender de definiciones, hipótesis o marcadores previos. En segundo lugar, un proyecto para construir un atlas completo de todos los tipos y subtipos de células humanas se ha convertido en un objetivo tangible. Finalmente, las células individuales son el componente básico de los tejidos complejos. Mediante la deconvolución de muestras complejas, como biopsias de tumores, se puede inferir su entorno celular y caracterizar los tipos de células raras, funcionalmente importantes y desconocidas que contienen. [43]

A pesar del potencial analítico de las aproximaciones multimodales detalladas anteriormente, la secuenciación de ARN de célula individual (scRNA-seq), en particular, ha revolucionado la investigación biológica y permite la categorización de tipos celulares en múltiples especies y tejidos [21]. El análisis de datos scRNA-seq sigue un flujo de procesamiento bien definido, compuesto por múltiples etapas que transforman datos brutos de secuenciación en conocimiento biológico interpretable. Este pipeline ha sido ampliamente descrito en estudios previos como una secuencia de pasos que incluye control de calidad, normalización, reducción de dimensionalidad y análisis downstream.

El presente Trabajo de Fin de Grado centra su alcance específicamente en este dominio, focalizándose en el flujo de procesamiento computacional y el despliegue de modelos de aprendizaje automático para la anotación celular precisa.

El análisis de secuenciación de ARN de célula única se fundamenta en la transformación de lecturas de secuenciación bruta en inferencias biológicas mediante el uso de estadística multivariante y aprendizaje automático [9].

Aunque muchos estudios de scRNA-seq hasta la fecha han informado técnicas personalizadas, como nuevos desarrollos en herramientas de laboratorio húmedo, bioinformáticas o computacionales, la mayoría se ha adherido a un flujo de trabajo metodológico general (Figura 3.6).

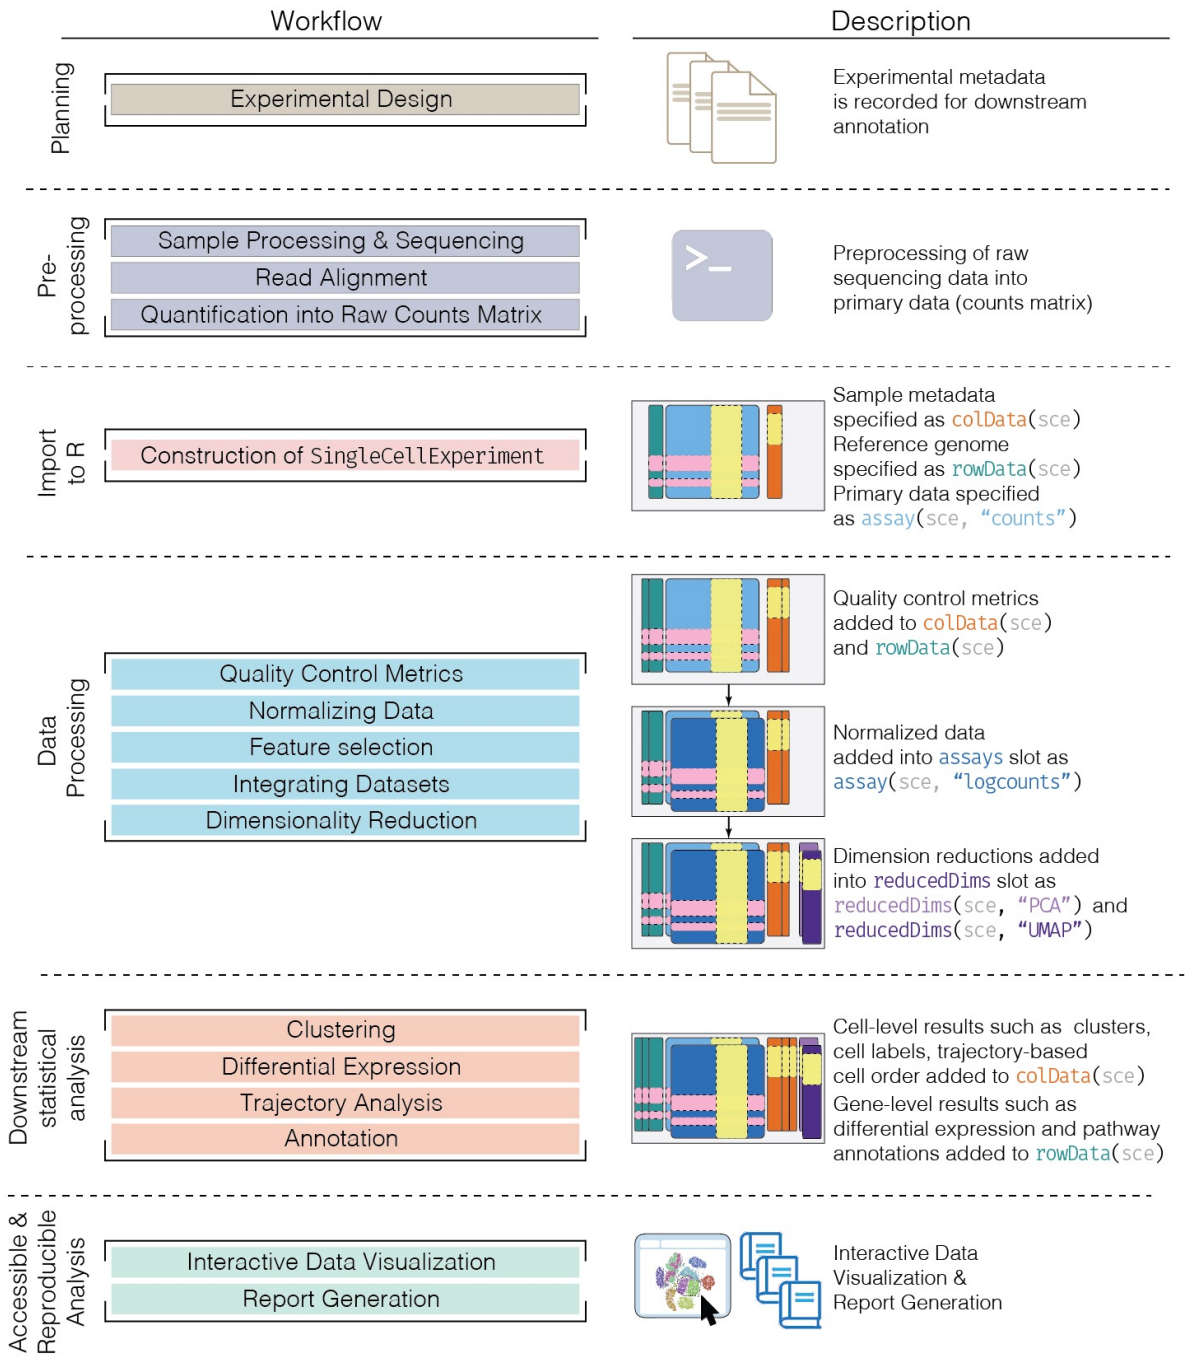


Figura 3.6: Esquema de un flujo de trabajo estándar de análisis de scRNA-seq. Cada etapa (separada por líneas discontinuas) consta de una serie de pasos específicos. Figura extraída de [4].

3.2.1. Adquisición

El material de partida para un experimento con células individuales se obtiene normalmente en forma de muestras de tejido biológico. Como primer paso, se genera una suspensión de células individuales mediante un proceso llamado disociación de células individuales, en el que se digiere el tejido.

Para analizar el ARNm de cada célula por separado, es necesario aislarlas, por tanto, el aislamiento efectivo de células viables individuales del tejido de interés es el siguiente paso para obtener información del transcriptoma.

Según la estrategia, actualmente, las técnicas de scRNA-seq se pueden clasificar en dos enfoques principales: los métodos basados en placas o microfluídicos y los métodos basados en gotas [44]:

- **Métodos basados en placas y microfluídica de canales:** las plataformas automatizadas basadas en microfluídica, como Fluidigm C1, aíslan y capturan las células individuales con canales microfluídicos paralelos. Estos métodos son similares y a menudo tienen un rendimiento limitado. La principal ventaja de estas plataformas radica en su alta sensibilidad, que permite cuantificar de forma fiable hasta ∼10,000 genes por célula [44]. Históricamente, estos sistemas sucedieron a técnicas de baja eficiencia como la dilución en serie o la micromanipulación robótica.

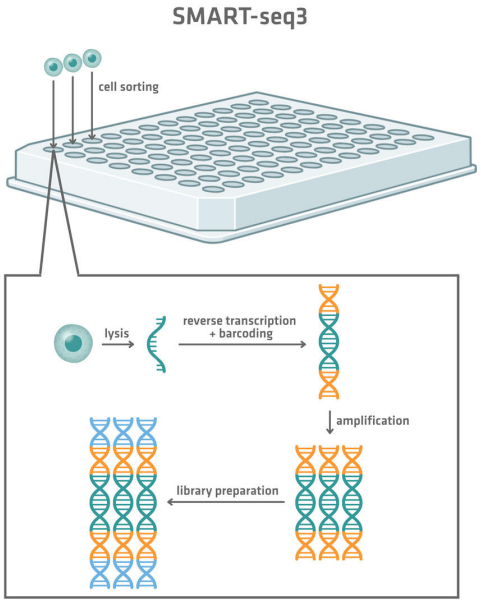


Figura 3.7: En el protocolo SMART-seq3, las células se lisan y las secuencias de ARN se transcriben inversamente, se amplifican y se preparan en bibliotecas listas para la secuenciación. Figura extraída de [5].

- **Métodos basados en gotas (Droplet-based):** los métodos basados en gotas codifican células individuales en gotas de aceite, donde cada transcrito es etiquetado con identificadores moleculares únicos (UMI) y códigos de barras celulares, reduciendo así considerablemente el tiempo y el coste necesarios por análisis, e incrementando enormemente el rendimiento. Sin embargo, debido a limitaciones en la eficiencia de captura, suelen detectar únicamente entre 1,000 y 3,000 genes por célula, lo que representa una pequeña parte de los genes que se expresan realmente [44]. Este fenómeno genera el problema técnico denominado pérdida de señal (dropouts), donde genes expresados biológicamente no son detectados, resultando en matrices de datos con una elevada dispersión (sparsity).

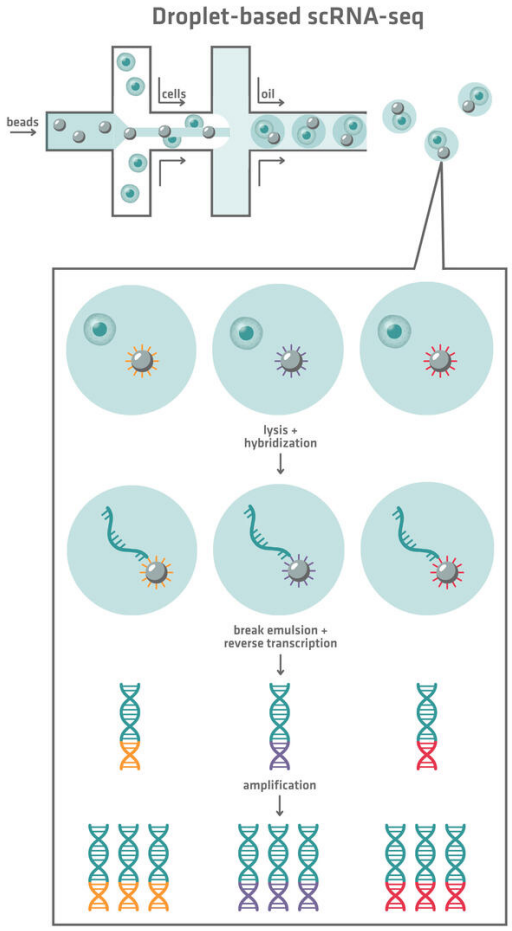


Figura 3.8: En la secuenciación de ARN de célula única basada en gotas, las células individuales se encapsulan con microesferas con código de barras en gotas de aceite, lo que permite la lisis celular, la captura de ARN, la transcripción inversa y la amplificación para generar ADNc con código de barras único para cada célula. Figura extraída de [5].

Cada gota incorpora los reactivos necesarios para romper las células y llevar a cabo la preparación de la biblioteca genética. Este proceso permite capturar el ARNm presente en el interior celular, convertirlo en ADN complementario (ADNc) mediante transcripción inversa y amplificar posteriormente dicho material genético. Al realizarse de forma individual en cada gota, el material transcriptómico de cada célula puede marcarse con un código de barras específico, lo que permite identificar posteriormente el origen celular de cada lectura obtenida. Además, numerosos protocolos incorporan identificadores moleculares únicos (Unique Molecular Identifiers, UMI), que permiten diferenciar entre copias generadas durante la amplificación y moléculas de ARNm originalmente distintas procedentes de un mismo gen. Finalmente, el ADNc se amplifica antes de la secuenciación con el objetivo de incrementar la sensibilidad de detección y mejorar la cuantificación de la expresión génica [9].

3.2.2. Preprocesamiento

Una vez capturado el ARN mensajero (ARNm) y creadas las bibliotecas de ADNc, se lleva a cabo la secuenciación masiva en paralelo. Este proceso produce grandes volúmenes de datos brutos, los cuales requieren diversas etapas de procesamiento para obtener matrices de conteos moleculares (matrices de conteos).

Estructura de los archivos FASTQ y demultiplexación

El resultado primario de la secuenciación se almacena en archivos en formato FASTQ, que contienen tanto las secuencias nucleotídicas obtenidas como sus puntuaciones de calidad asociadas. En experimentos de secuenciación de ARN de célula única, las lecturas suelen dividirse en dos fragmentos complementarios con funciones diferenciadas. La primera lectura (R1) contiene la información necesaria para identificar el origen celular y molecular de cada fragmento secuenciado, incluyendo el código de barras celular (cell barcode) y el identificador molecular único (UMI).

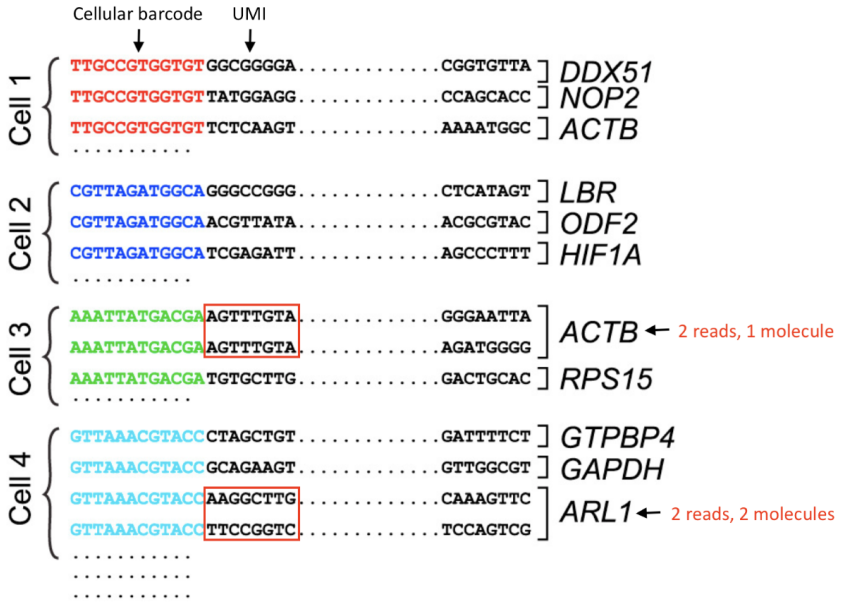


Figura 3.9: Esquema ilustrativo del uso de códigos de barras celulares y UMIs en experimentos de scRNA-seq basado en gotas. Figura extraída de Macosko et al. [6].

La segunda lectura (R2) almacena la secuencia correspondiente al ADNc derivado del ARN celular y constituye la información empleada posteriormente durante el alineamiento frente al genoma de referencia.

Tras la secuenciación, se realiza una etapa de demultiplexación, mediante la cual las lecturas se asignan a sus respectivas muestras de origen utilizando los índices introducidos durante la preparación de las bibliotecas [25].

Alineamiento y cuantificación molecular

Una vez obtenidas las lecturas, las secuencias derivadas del ADNc se alinean frente a un genoma o transcriptoma de referencia mediante herramientas de alto rendimiento, como STAR o Cell Ranger. Posteriormente, se lleva a cabo el proceso de cuantificación molecular basado en UMIs. Durante esta etapa, múltiples lecturas que presentan el mismo UMI y se alinean sobre un mismo gen dentro de una misma célula se consideran copias derivadas de una única molécula original de ARNm. Este procedimiento permite reducir los sesgos introducidos por la amplificación mediante PCR y obtener estimaciones más precisas de la abundancia transcriptómica [44]. El resultado final de este procesamiento es una matriz de conteos génicas, en la que las filas representan genes, las columnas representan células y cada valor corresponde al número de moléculas detectadas para un gen concreto en una célula determinada.

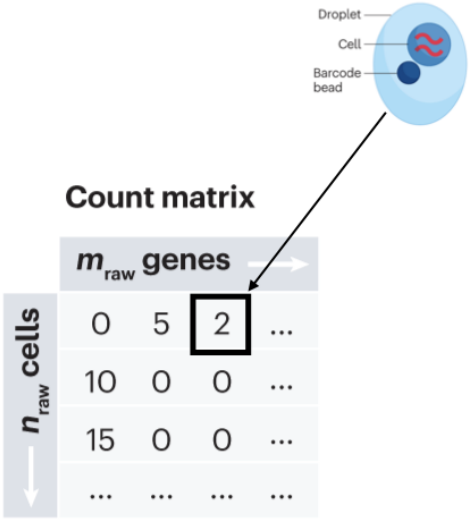


Figura 3.10: Representación esquemática de una matriz de conteos en datos de scRNA-seq. Figura extraída del material docente de The Rockefeller University [7].

3.2.3. Procesamiento

Se presentan dos propiedades dentro de los conjuntos de datos de célula única que deben tenerse en cuenta al realizar un análisis. En primer lugar, los datos de scRNA-seq contienen valores faltantes, lo que significa que hay un número excesivo de ceros en los datos debido a la limitación del ARNm . En segundo lugar, el potencial para corregir los datos y realizar un control de calidad puede ser limitado, ya que los datos pueden estar sesgados por factores biológicos. Por lo tanto, es necesario seleccionar métodos de procesamiento adecuados para los datos subyacentes, sin sobrecorregir ni eliminar los efectos biológicos.

El conjunto de herramientas para analizar datos de secuenciación de ARN de células individuales está evolucionando rápidamente debido a las nuevas tecnologías

de secuenciación y al creciente número de células capturadas, genes medidos y poblaciones celulares identificadas. Muchas de estas herramientas están dedicadas al procesamiento, cuyo objetivo es abordar los siguientes pasos de análisis: control de calidad, normalización, selección de características y reducción de dimensionalidad.

Los algoritmos seleccionados durante este proceso pueden afectar significativamente el análisis e interpretación posteriores de los datos. Por ejemplo, si se filtran demasiadas células durante el control de calidad, se podrían perder subpoblaciones celulares poco frecuentes y no obtener información relevante sobre la biología celular. Por otro lado, si se es demasiado permisivo, podría resultar difícil anotar las células si no se excluyeron las de baja calidad durante el preprocesamiento. En muchos casos, será necesario reevaluar el análisis de preprocesamiento posteriormente y modificar, por ejemplo, la estrategia de filtrado.

A continuación, se detallan los pasos del procesamiento de datos en un análisis típico de RNA-seq de célula única.

Control de calidad (QC)

El control de calidad (QC) constituye el proceso fundamental para garantizar que las inferencias biológicas resultantes se fundamenten en datos provenientes de células viables y no en artefactos técnicos del proceso de secuenciación. Basado en los estándares de buenas prácticas [9, 44], este procedimiento se estructura en los siguientes puntos críticos:

- **Evaluación de la viabilidad mediante covariables celulares:** la calidad de una célula se determina examinando de forma conjunta tres métricas: el número de recuentos moleculares (Unique Molecular Identifiers, UMI), el número de genes expresados y la fracción de lecturas mitocondriales. Un bajo número de genes junto con una elevada proporción mitocondrial (generalmente $>20\,\%$) es indicativo de células dañadas o en apoptosis, donde el ARNm citoplasmático se ha filtrado a través de una membrana plasmática rota, mientras que el ARNm mitocondrial permanece retenido.
- **Identificación y filtrado de dobletes:** en los métodos basados en gotas, entre el $5\,\%$ y el $20\,\%$ de los códigos de barras pueden encapsular más de una célula, creando perfiles de expresión híbridos.
- **Gestión de la contaminación por ARN ambiental:** se debe considerar la presencia de transcritos libres en la suspensión celular (ambient RNA o soup), originados por células lisadas antes del encapsulamiento. Estos recuentos ambientales pueden distorsionar el análisis de expresión diferencial al contaminar las gotas de células sanas.
- **Filtrado genético y eficiencia computacional:** la eliminación de genes que se expresan en un número muy reducido de células (p. ej., menos de 20) permite reducir la dimensionalidad y el ruido estadístico. No obstante, un filtrado excesivamente estricto puede dificultar la detección de tipos celulares raros o minoritarios y comprometer la comparabilidad entre diferentes estudios.
- **Naturaleza iterativa y multivariante del análisis:** los umbrales de QC no son

universales. Células metabólicamente activas, como los cardiomiocitos, pueden presentar naturalmente altos niveles de ARN mitocondrial sin estar dañadas.

Normalización

La normalización tiene como objetivo ajustar los recuentos brutos del conjunto de datos para compensar los efectos de muestreo variables, escalando la varianza observable a un rango particular. En la práctica se utilizan diversas técnicas de normalización, que varían en complejidad [8]. Se presentan cuatro técnicas de normalización diferentes: la transformación logarítmica desplazada, la normalización Scran, la aproximación analítica de los residuos de Pearson y la normalización mediante controles externos Spike-ins.

Sin embargo, la matriz de conteos obtenida tras el preprocesamiento no es directamente comparable entre células debido a la variabilidad técnica intrínseca del scRNA-seq. Los principales factores que motivan la necesidad de normalización son:

- **Sesgo de profundidad de secuenciación:** diferencias en la eficiencia de captura, transcripción inversa y secuenciación provocan que células biológicamente idénticas presenten distintos recuentos totales. La normalización busca compensar estos efectos de muestreo para estabilizar la varianza [45].
- **Controles externos (Spike-ins):** históricamente, se han utilizado moléculas de ARN exógenas sintéticas de concentración conocida (spike-ins) para mejorar los factores de escalado globales. No obstante, su uso no es rutinario en la actualidad debido a la complejidad técnica de garantizar estándares representativos y de alta calidad para cada muestra.

Actualmente existen diversas técnicas dependiendo del análisis posterior (downstream) previsto. De acuerdo con el marco de trabajo propuesto en Single-cell Best Practices [8]:

- **Logaritmo Desplazado (Shifted Logarithm)**: esta técnica de normalización se fundamenta en el método delta [46], el cual consiste en aplicar una función no lineal a los recuentos brutos con el objetivo de homogeneizar las variaciones a lo largo de todo el conjunto de datos. El logaritmo desplazado aborda este problema mediante:

$$x_{ij} = \log\left(\frac{y_{ij}}{s_i} + y_0\right) \tag{3.1}$$

  Donde y_{ij} representa los recuentos brutos del gen j en la célula i, s_i es el factor de tamaño asignado a dicha célula y y_0 describe un pseudoconteo, generalmente fijado en 1 para evitar la indeterminación del logaritmo en valores de cero.

- **Normalización por deconvolución (Scran):** fundamentado igualmente en el método delta, es el algoritmo de estimación del factor de tamaño basado en agrupamiento de Scran. Este procedimiento sigue los mismos principios operativos que el logaritmo desplazado, calculando la expresión normalizada mediante:

$$x_{ij} = \log\left(\frac{y_{ij}}{s_i} + y_0\right) \tag{3.2}$$

donde y_{ij} representa los recuentos brutos, s_i el factor de tamaño específico y y_0 el pseudoconteo para la estabilización. La distinción de scran radica en su metodología de estimación de s_i: en lugar de utilizar un escalado global, emplea un enfoque de deconvolución.

Bajo este enfoque, las células se dividen inicialmente en grupos o clusters mediante un agrupamiento grueso. Posteriormente, scran estima los factores de tamaño basándose en una regresión lineal sobre los genes para dichos grupos de células.

- **Residuos Analíticos de Pearson:** este método surge de la observación de que la variación célula a célula en los datos de scRNA-seq suele estar confundida por la interacción entre la heterogeneidad biológica y los efectos técnicos de muestreo.

  A diferencia de los métodos basados en factores de escala, esta técnica utiliza los residuos de Pearson derivados de una 'regresión binomial negativa regularizada' para construir un modelo de ruido técnico. Matemáticamente, el resultado de este método son valores normalizados que pueden adoptar signos positivos o negativos:

  - **Residuos negativos:** Indican que se observan menos recuentos de los esperados para un gen y una célula específicos, en comparación con la expresión promedio del gen y la profundidad de secuenciación celular.
  - **Residuos positivos:** Indican una observación de recuentos superior a la predicha por el modelo de ruido técnico.

- **Normalización mediante controles externos Spike-ins**: esta técnica consiste en la adición de una cantidad conocida de moléculas de ARN exógenas (generalmente del consorcio External RNA Controls Consortium o ERCC) a cada lisado celular antes de la preparación de la librería.

  A diferencia de los métodos de normalización interna, los *spike-ins* permiten calcular un factor de escala s_i independiente del contenido de ARN endógeno de la célula. La normalización se realiza mediante:

  $$s_i = \frac{\sum_{k \in \text{ERCC}} y_{ik}}{\mu_{\text{ERCC}}} \tag{3.3}$$

  donde y_{ik} representa los recuentos del control exógeno k en la célula i.

Selección de características

La selección de características consiste en la realización de un filtrados para conservar únicamente aquellos genes que aportan información relevante sobre la variabilidad biológica presente en el conjunto de datos.

Por lo tanto, es común emplear genes altamente variables (HVG), ya que estos permiten capturar gran parte de la heterogeneidad transcriptómica celular [47]. Dependiendo de la complejidad del dataset y de la tarea posterior de análisis, normalmente se seleccionan entre 1000 y 5000 HVG [9].

Además, trabajos previos han mostrado que muchos análisis downstream presentan una cierta robustez frente al número exacto de genes seleccionados. Por ejemplo, Klein et al. observaron que variaciones en el número de HVG entre 200 y 2400 producían representaciones de baja dimensionalidad similares en el espacio PCA [48]. Basándose en estas observaciones, diversos flujos de análisis tienden a priorizar una selección relativamente amplia de HVG.

Reducción de dimensionalidad y visualización

No todos los genes aportan la misma cantidad de información biológica y, por tanto, no todos resultan igualmente relevantes para tareas posteriores como el agrupamiento celular o la reducción de dimensionalidad. La selección de genes altamente variables permite disminuir considerablemente la dimensionalidad inicial de las matrices de expresión, sin embargo, incluso tras esta etapa de filtrado, los conjuntos de datos de scRNA-seq continúan presentando una dimensionalidad elevada.

Por este motivo, habitualmente se aplican algoritmos de reducción de dimensionalidad que permiten proyectar los datos en espacios de menor dimensión, preservando la estructura biológica más relevante y facilitando tanto su análisis como su visualización.

En términos generales, estos algoritmos persiguen dos objetivos principales: (i) el resumen de la información transcriptómica y (ii) la visualización de poblaciones celulares complejas. Las técnicas orientadas al resumen permiten condensar la información contenida en miles de genes en un conjunto reducido de componentes relevantes, facilitando tareas posteriores como clustering, inferencia de trayectorias o construcción de grafos de vecindad. Por otro lado, las técnicas de visualización generan representaciones bidimensionales o tridimensionales que permiten explorar la organización global de los datos y detectar posibles subpoblaciones celulares.

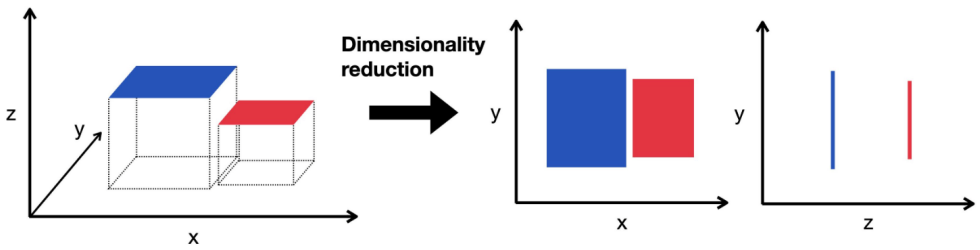


Figura 3.11: La reducción de la dimensionalidad permite proyectar datos de alta dimensión en un espacio de menor dimensión. En la figura se muestra la proyección de un objeto tridimensional en dos dimensiones. Figura extraída de [8].

Entre las técnicas más utilizadas destaca el análisis de componentes principales

(PCA), un método lineal que identifica patrones dominantes y combinaciones lineales de las variables originales con máxima varianza [9]. El principal objetivo es encontrar el primer componente principal con la mayor varianza en los datos y luego buscar el segundo componente de la misma manera, que no esté correlacionado con el primero.

Frente a los enfoques lineales, existen métodos no lineales capaces de preservar con mayor fidelidad las relaciones locales entre células. Entre ellos, t-SNE y UMAP se han convertido en herramientas ampliamente utilizadas para la representación visual de datos de scRNA-seq. t-SNE se basa en SNE (Hinton y Roweis, 2002 [49]), que parte de la conversión de las distancias euclidianas de alta dimensión entre puntos de datos en probabilidades condicionales que representan similitudes. La idea principal y las modificaciones de t-SNE son: (1) la versión simétrica de SNE y (2) el uso de una distribución t de Student para calcular la similitud entre dos puntos en el espacio de baja dimensión. En comparación con t-SNE, UMAP conserva una estructura más global con un rendimiento superior en tiempo de ejecución [50, 51]. El algoritmo de UMAP parte de varios supuestos sobre la estructura de los datos. En particular, asume que las observaciones se distribuyen de manera aproximadamente uniforme sobre una variedad riemanniana, que la métrica de dicha variedad puede considerarse localmente constante y que la estructura subyacente presenta conectividad local.

Xing et al. realizaron una comparación sistemática de distintos métodos de reducción de dimensionalidad evaluando aspectos como estabilidad, precisión y coste computacional [8]. En dicho estudio se analizaron diez aproximaciones diferentes, observándose que t-SNE presentaba uno de los mejores rendimientos globales en términos de representación de los datos.

Por otro lado, UMAP mostró una elevada estabilidad entre ejecuciones y una mejor capacidad para preservar la separación entre poblaciones celulares originales, lo que ha favorecido su adopción como una de las técnicas de visualización más utilizadas en análisis de scRNA-seq.

3.2.4. Análisis posterior

Tras el procesamiento, se utilizan métodos denominados análisis posteriores (downstream) para extraer información biológica y describir el sistema biológico subyacente. Estas descripciones se obtienen ajustando modelos interpretables a los datos. Ejemplos de estos modelos son grupos de células con perfiles de expresión génica similares que representan agrupaciones de tipos celulares, pequeños cambios en la expresión génica entre células similares que indican trayectorias continuas (de diferenciación), o genes con perfiles de expresión correlacionados que indican corregulación.

Desde un punto de vista conceptual, el análisis downstream se puede dividir en enfoques centrados en las células y enfoques centrados en los genes, como se muestra en la Figura 3.12. Los análisis a nivel celular suelen organizarse en torno a dos estructuras fundamentales: los clústeres celulares y las trayectorias celulares. Ambas estructuras pueden estudiarse posteriormente desde perspectivas celulares y génicas, dando lugar a metodologías específicas de análisis de clústeres y análisis de

trayectorias [9].

En términos generales, los métodos de análisis de clústeres intentan explicar la heterogeneidad presente en el conjunto de datos mediante la categorización de las células en grupos discretos con perfiles transcriptómicos similares. Por el contrario, los métodos de inferencia de trayectorias consideran que los datos representan instantáneas de un proceso dinámico continuo, investigando las relaciones transicionales entre estados celulares y reconstruyendo posibles progresiones biológicas subyacentes.

Los métodos se dividen en análisis a nivel celular y a nivel genético. Los análisis a nivel celular se subdividen a su vez en análisis de clústeres y de trayectorias, que incluyen también métodos de análisis a nivel genético. Todos los métodos con fondo azul corresponden a análisis a nivel genético.

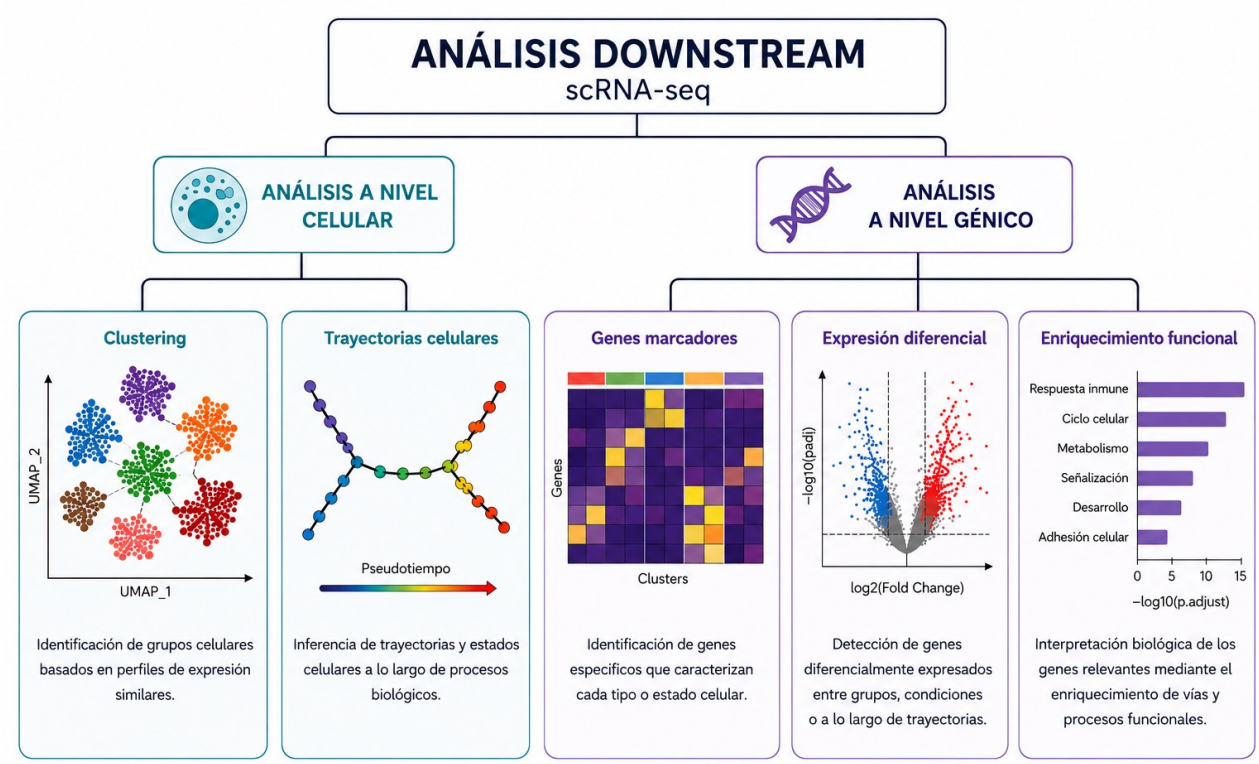


Figura 3.12: Esquema conceptual del análisis downstream en scRNA-seq. Adaptada de [9].

Análisis a nivel celular

Clustering

La organización de células en clústeres constituye uno de los resultados intermedios más importantes dentro del análisis de datos de célula única. El agrupamiento celular permite inferir posibles identidades celulares a partir de

perfiles de expresión génica similares, proporcionando una primera descripción de la heterogeneidad presente en el conjunto de datos [9].

Los enfoques clásicos de agrupamiento generan clústeres minimizando distancias o identificando regiones densas dentro del espacio de expresión reducido. El algoritmo k-means, por ejemplo, divide las células en k grupos mediante un proceso iterativo de optimización de centroides [52]. Sin embargo, este tipo de aproximaciones presenta limitaciones importantes en datos scRNA-seq.

Por este motivo, en el análisis de datos de célula única se han consolidado los enfoques basados en grafos, particularmente aquellos fundamentados en grafos de K vecinos más cercanos (K-Nearest Neighbors, KNN) [53].

El grafo KNN constituye una aproximación de la topología subyacente de los datos transcriptómicos. Las regiones densamente pobladas del espacio de expresión se corresponden con regiones densamente conectadas dentro del grafo, permitiendo detectar estructuras celulares coherentes mediante algoritmos de detección de comunidades [53].

Algoritmos: Louvain y Leiden

Los métodos de detección de comunidades representan actualmente el enfoque predominante para el agrupamiento de datos scRNA-seq. Estos algoritmos se basan en la partición de grafos y buscan identificar subconjuntos de nodos con una densidad de conexiones internas superior a la esperada aleatoriamente en el grafo completo.

Uno de los primeros métodos ampliamente utilizados en este contexto fue PhenoGraph [54], basado en optimización de modularidad sobre grafos KNN. Posteriormente, el algoritmo Louvain se consolidó como el enfoque estándar implementado en plataformas de análisis de referencia como Scanpy y Seurat [55, 56, 57].

El algoritmo Louvain detecta comunidades maximizando una función de modularidad multirresolución, identificando grupos de células que presentan un número de conexiones internas superior al esperado según el número total de enlaces presentes en el grafo [55]. Diversos estudios comparativos demostraron además que este tipo de aproximaciones basadas en grafos superaban a numerosos métodos clásicos de agrupamiento en datos de RNA-seq de célula única y citometría [58, 59, 60].

No obstante, Louvain presenta ciertas limitaciones relacionadas con la conectividad interna de las comunidades detectadas. En determinados casos, el algoritmo puede producir clústeres pobremente conectados o incluso particiones internamente desconectadas. Para solventar estas limitaciones, Traag et al. desarrollaron el algoritmo Leiden, considerado actualmente una versión mejorada de Louvain [61].

Leiden incorpora una fase adicional de refinamiento de comunidades que garantiza una mejor conectividad interna de los clústeres obtenidos, generando particiones más robustas y biológicamente interpretables. Debido a estas ventajas y al hecho de que Louvain ha dejado de mantenerse activamente, Leiden se ha convertido en el algoritmo preferente en numerosos flujos de trabajo contemporáneos de análisis scRNA-seq [61].

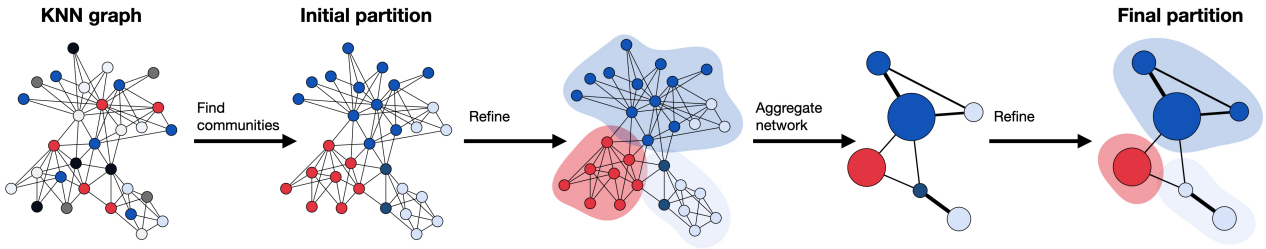


Figura 3.13: El algoritmo de Leiden calcula una agrupación en un grafo KNN obtenido del espacio de expresión reducido PC. Figura extraída de [8].

Tanto Louvain como Leiden incorporan además un parámetro de resolución que controla el grado de granularidad de la partición celular. Valores bajos producen clústeres amplios y menos numerosos, mientras que resoluciones altas generan subdivisiones más finas del espacio transcriptómico. Esta propiedad permite explorar diferentes escalas biológicas dentro de un mismo conjunto de datos, desde grandes tipos celulares hasta subpoblaciones o estados celulares específicos [9].

Tabla 3.3: Comparación entre los algoritmos Louvain y Leiden para detección de comunidades en datos scRNA-seq.

Método	Principio	Ventajas	Limitaciones	Uso actual
Louvain	Optimización de modularidad sobre grafos KNN mediante detección iterativa de comunidades.	Alta eficiencia computacional y amplia adopción histórica.	Puede generar comunidades pobremente conectadas o particiones internamente desconectadas.	Uso extendido, aunque progresivamente reemplazado por Leiden.
Leiden	Extensión del algoritmo Louvain con refinamiento adicional de comunidades y garantía de conectividad interna.	Genera clústeres más robustos, mejor conectados y biológicamente más interpretables.	Sensibilidad al parámetro de resolución y dependencia de la construcción previa del grafo KNN.	Considerado actualmente el enfoque preferente en numerosos flujos de trabajo scRNA-seq.

Anotación de clústeres

Una vez definidos los clústeres celulares, el siguiente paso consiste en asignar significado biológico a las agrupaciones identificadas. Este proceso, denominado anotación de clústeres o anotación de identidades celulares, se basa principalmente en la identificación de genes marcadores característicos de cada grupo celular [9].

Los genes marcadores suelen obtenerse mediante análisis de expresión diferencial entre las células pertenecientes a un clúster y el resto del conjunto de datos. Habitualmente, se emplean pruebas estadísticas como Wilcoxon o *t-test* para clasificar los genes según sus diferencias de expresión, considerando posteriormente los genes mejor posicionados como marcadores característicos del clúster.

La anotación puede realizarse mediante comparación manual con genes marcadores descritos previamente o utilizando atlas celulares de referencia, como el Human Cell Atlas [43] o atlas específicos de tejidos, como el atlas molecular del sistema nervioso de ratón [62].

Trayectorias celulares

En numerosos contextos biológicos, la heterogeneidad celular no puede describirse adecuadamente mediante agrupamientos discretos. Procesos como diferenciación, desarrollo, activación o transición celular presentan dinámicas continuas que requieren modelos particulares de inferencia temporal [63].

El análisis de trayectorias celulares intenta reconstruir estos procesos ordenando las células a lo largo de un pseudotiempo transcriptómico. Para ello, los algoritmos utilizan representaciones reducidas y genes altamente variables con el objetivo de inferir progresiones biológicas continuas entre distintos estados celulares [34, 64].

Existen actualmente múltiples herramientas capaces de modelar trayectorias de distinta complejidad, incluyendo estructuras lineales, bifurcaciones o grafos más complejos. Entre las aproximaciones más utilizadas destacan Slingshot [65], Monocle [34] y Diffusion Pseudotime (DPT) [64]. Más recientemente, métodos como PAGA han permitido integrar simultáneamente información de agrupamiento y relaciones dinámicas entre poblaciones celulares [53].

El estudio de trayectorias celulares ha permitido además desarrollar metodologías orientadas a inferir dinámicas transcripcionales mediante el análisis conjunto de ARN espliceado y no espliceado, dando lugar a aproximaciones basadas en RNA velocity como velocyto o scVelo [66, 67].

Análisis a nivel génico

Una vez caracterizadas las poblaciones celulares presentes en el conjunto de datos, el análisis downstream suele complementarse mediante estudios de expresión diferencial y enriquecimiento funcional.

Los análisis de expresión diferencial permiten identificar genes cuya expresión cambia significativamente entre poblaciones celulares o condiciones experimentales. Sin embargo, en datos scRNA-seq esta tarea resulta especialmente compleja debido a la elevada dispersión, variabilidad célula a célula y presencia de dropouts [68, 69].

Herramientas específicas como MAST [70] o scCODE [71] han sido desarrolladas para abordar estas particularidades. Posteriormente, los genes diferencialmente expresados pueden analizarse mediante estrategias de enriquecimiento funcional (*Gene Set Enrichment Analysis*, GSEA), utilizando bases de datos como Gene Ontology, KEGG o Reactome para identificar rutas biológicas y procesos moleculares enriquecidos [72, 73, 74].

Además, el desarrollo reciente de análisis de interacciones ligando-receptor ha permitido estudiar mecanismos de comunicación entre poblaciones celulares, ampliando considerablemente la capacidad interpretativa de los análisis downstream en datos scRNA-seq.

3.3. Matriz de conteos

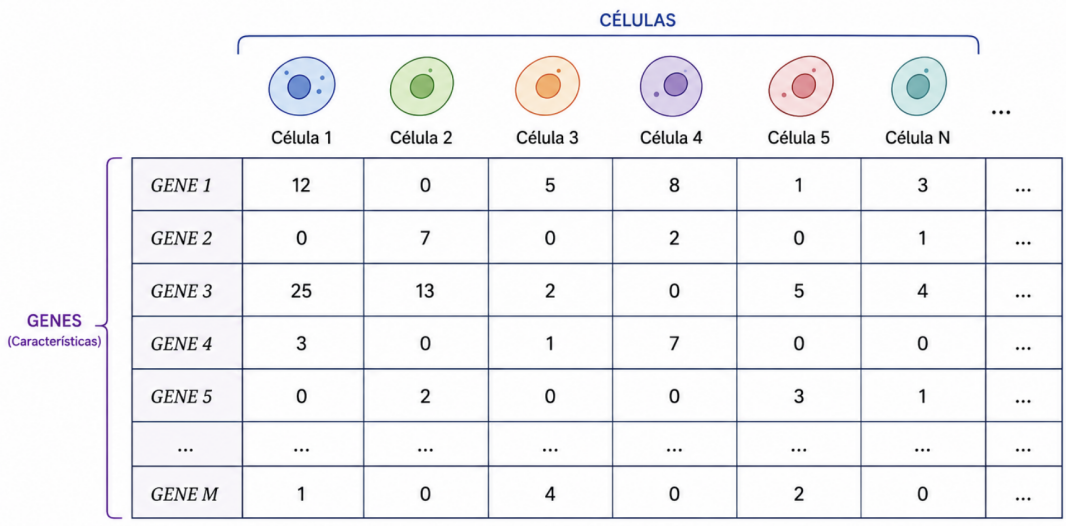
El elemento central en el análisis de datos de secuenciación de ARN de célula única (single-cell RNA sequencing, scRNA-seq) es la matriz de conteos (count matrix), que representa la cuantificación de la expresión génica a nivel celular [9].

Esta matriz puede expresarse matemáticamente como:

$$X \in \mathbb{N}^{G \times C}$$

donde G representa el número de genes y C el número de células analizadas. Cada entrada X_{ij} contiene el número de moléculas de ARN o lecturas detectadas para el gen i en la célula j.

La matriz de conteos constituye un espacio de características de muy alta dimensionalidad, donde cada célula queda representada mediante miles de variables transcriptómicas. En muchos experimentos scRNA-seq se cuantifican más de 20.000 genes por célula, generando matrices extremadamente grandes y complejas [75].



	Célula 1	Célula 2	Célula 3	Célula 4	Célula 5	Célula N	...
GENE 1	12	0	5	8	1	3	...
GENE 2	0	7	0	2	0	1	...
GENE 3	25	13	2	0	5	4	...
GENE 4	3	0	1	7	0	0	...
GENE 5	0	2	0	0	3	1	...
...	...	...	...	...	...	...	...
GENE M	1	0	4	0	2	0	...

Figura 3.14: Representación de una matriz de conteos en datos de secuenciación de ARN de célula única. Las filas representan genes y las columnas células individuales. Cada entrada de la matriz contiene el número de moléculas de ARN detectadas para un gen en una célula determinada.

En los experimentos de scRNA-seq, las células o núcleos aislados se procesan inicialmente para generar una biblioteca de ADN compatible con tecnologías de secuenciación de alto rendimiento. Tras la secuenciación, las lecturas obtenidas se alinean frente a un genoma de referencia mediante herramientas específicas, dando lugar a una matriz de conteos [10].

Esta matriz constituye la estructura fundamental para el análisis de datos scRNA-seq y organiza la información transcriptómica en forma de genes frente a

células. En ella, las filas representan genes, las columnas corresponden a células individuales y cada elemento de la matriz indica el número de lecturas o identificadores moleculares únicos (UMIs) detectados para un determinado gen en una célula concreta. De este modo, valores elevados reflejan una mayor abundancia de transcritos asociados a dicho gen en la célula correspondiente [10].

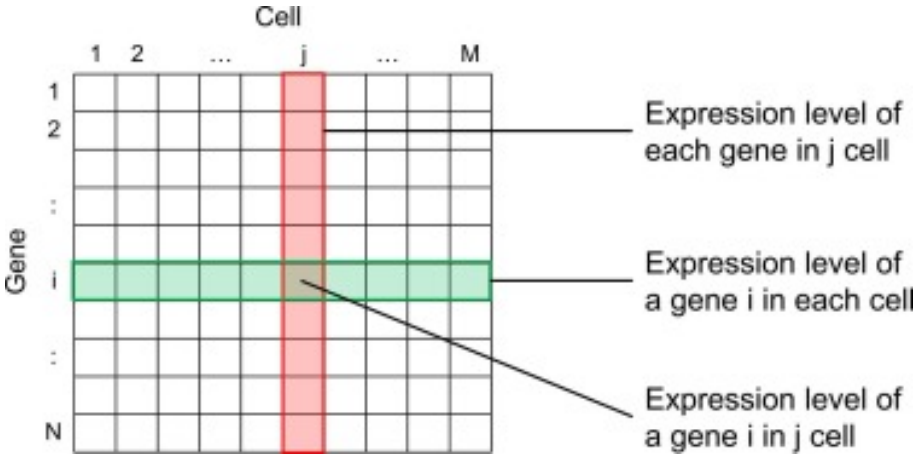


Figura 3.15: Matriz de conteos en datos de secuenciación de ARN de célula única. La columna resaltada en rojo representa los recuentos de todos los genes en una célula específica (*j*), donde cada elemento indica el número de lecturas o UMIs asociados a un gen concreto en dicha célula. De manera análoga, la fila resaltada en verde muestra los recuentos de un gen específico (*i*) en todas las células. La intersección entre la fila verde y la columna roja representa el recuento correspondiente al gen (*i*) en la célula (*j*), ilustrando la cantidad detectada de transcritos de dicho gen en esa célula concreta. Figura extraída de [10].

3.4. Tareas en el análisis de scRNA-seq

El análisis de datos scRNA-seq abarca un conjunto diverso de tareas, cada una orientada a extraer información biológica específica a partir de los datos transcriptómicos. Estas tareas han sido sistematizadas en múltiples revisiones como componentes clave del análisis de célula única [9, 76].

Actualmente, este campo abarca un amplio conjunto de tareas orientadas a extraer información biológica a partir de datos transcriptómicos y multimodales. En el contexto de scRNA-seq unimodal, algunas de las tareas más relevantes incluyen el procesamiento de los datos, la imputación de valores de dropout, la reducción de dimensionalidad, el clustering no supervisado, la anotación automática de tipos celulares y el análisis de expresión diferencial [9, 38].

Por otra parte, el desarrollo reciente de tecnologías multimodales y transcriptómica espacial ha impulsado nuevas líneas de investigación, como la integración multimodal, el alineamiento entre modalidades, la inferencia de dominios espaciales, la deconvolución celular y el modelado conjunto de información transcriptómica, epigenómica y espacial [32, 29].

No obstante, dado que el presente trabajo se centra en el análisis unimodal de datos scRNA-seq y, específicamente en el problema de la anotación celular, a continuación se explica la imputación, una estrategia orientada a recuperar o estimar los valores de expresión afectados por eventos de dropout.

3.4.1. Imputación

A diferencia de la secuenciación masiva de ARN (RNA-seq), una característica distintiva de los datos medidos mediante la secuenciación de ARN de célula única (scRNA-seq) es la mayor escasez, o fracción de 'ceros' observados, donde un cero se refiere a la ausencia de identificadores moleculares únicos (UMI) o lecturas que se mapean a un gen determinado en una célula. Estos ceros observados pueden deberse a fluctuaciones biológicas o a limitaciones técnicas.

La imputación surge como una estrategia orientada a recuperar o estimar los valores de expresión afectados por eventos de dropout, con el objetivo de reducir el ruido técnico y mejorar la fiabilidad de los análisis posteriores [77, 78].

En los últimos años, se han propuesto numerosos métodos de imputación para recuperar datos de expresión genética. La mayoría de los enfoques actuales de imputación pueden agruparse en las siguientes cuatro categorías [78]: (i) métodos basados en modelos estadísticos de variabilidad técnica y biológica y distribución de ruido, (ii) métodos basados en matrices de bajo rango, (iii) métodos de suavizado de datos y (iv) métodos basados en aprendizaje profundo.

La clasificación metodológica presentada a continuación se basa principalmente en la revisión realizada por Wang et al. [78].

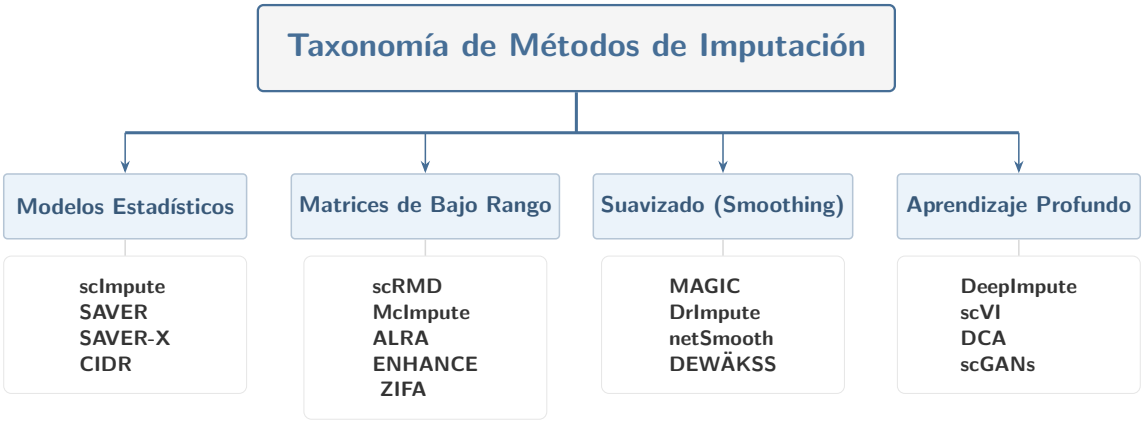


Figura 3.16: Clasificación de los algoritmos para imputación de datos scRNA-seq.

Los métodos basados en modelos estadísticos asumen una determinada distribución de los datos y tratan de separar la variabilidad biológica del ruido técnico mediante modelos probabilísticos. Dentro de esta categoría se encuentran métodos como scImpute, SAVER, SAVER-X o CIDR [11, 79, 80, 81]. scImpute estima las tasas de dropout mediante un modelo de mezcla Gamma-Normal y umbrales específicos de población celular [11], mientras que SAVER emplea un modelo Poisson-Gamma ara agrupar valores de expresión de todos los genes dentro de cada célula [79].

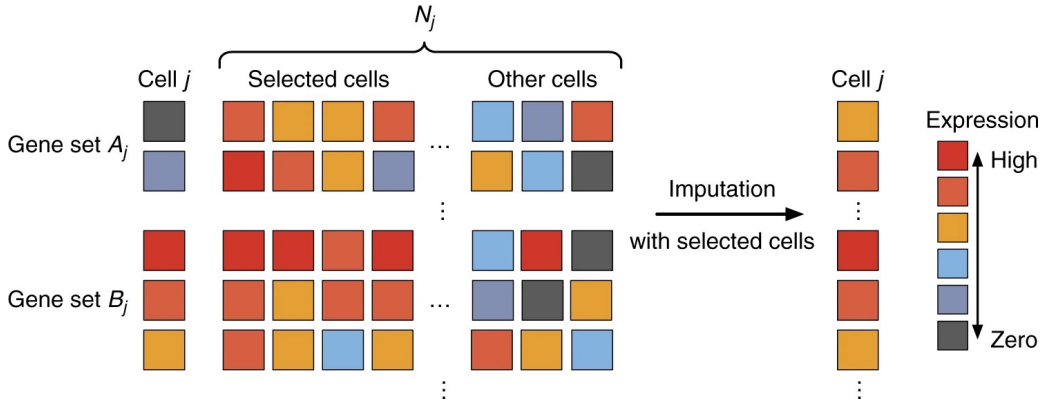


Figura 3.17: Ilustración del flujo de trabajo de la etapa de imputación del método scImpute. En primer lugar, scImpute estima la probabilidad de dropout de cada gen en cada célula mediante el ajuste de un modelo de mezcla. Posteriormente, los valores identificados con alta probabilidad de corresponder a eventos de dropout en la célula j (conjunto de genes A_j) son imputados utilizando información del mismo gen en otras células transcriptómicamente similares, seleccionadas a partir del conjunto de genes B_j, menos afectados por eventos de dropout. Figura extraída de [11].

Los métodos basados en la reconstrucción de los valores de expresión parten de la hipótesis de que la matriz de expresión observada puede reconstruirse a partir de una estructura latente de menor dimensionalidad, incluyendo enfoques como scRMD y McImpute [12, 82].

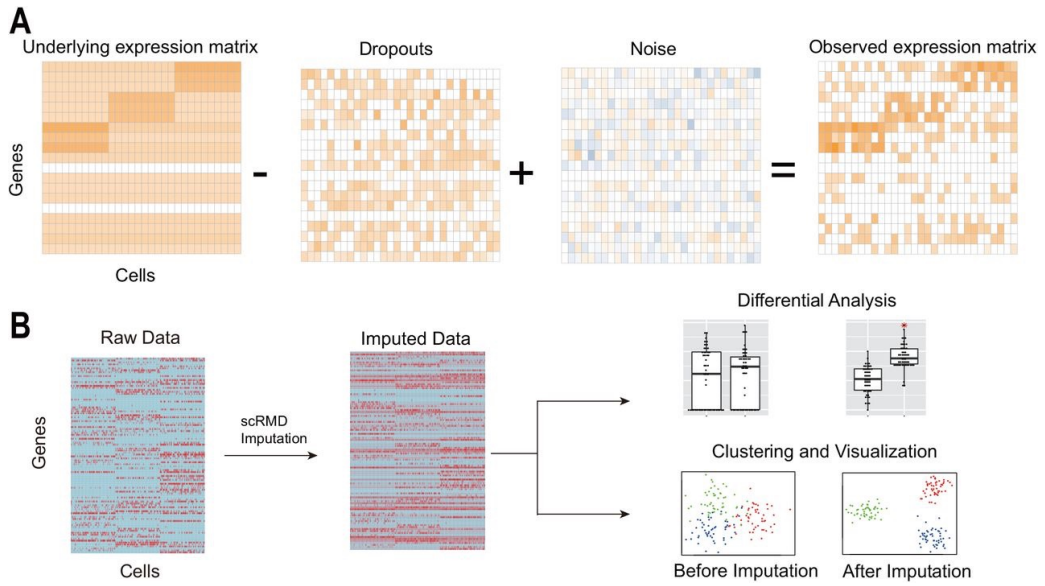


Figura 3.18: Esquema general del método scRMD. (A) La matriz de expresión observada puede descomponerse en una matriz subyacente de bajo rango L, una matriz de dropouts S y una matriz de ruido E. (B) Tras la imputación realizada por scRMD, los métodos convencionales de análisis de datos RNA-seq pueden aplicarse sobre la matriz de expresión reconstruida. Figura extraída de [12].

Por otro lado, los enfoques de suavizado estiman la expresión de una célula utilizando información procedente de células transcriptómicamente similares. Estos

métodos suelen modificar todos los valores de expresión, incluyendo los valores de dropout, los valores cero verdaderos y los valores no cero observados. Por ejemplo, el suavizado kNN utiliza una distribución de Poisson e información agregada de células similares [83, 84].

Finalmente, los métodos basados en aprendizaje profundo emplean arquitecturas neuronales, como autoencoders o modelos generativos, para aprender representaciones latentes no lineales y reconstruir la matriz de expresión observada [78]. DeepImpute y scVI son algoritmos de imputación basados en redes neuronales profundas capaces de aprender patrones de distribución complejos en los datos e imputar con precisión valores de dropout [85, 86].

No obstante, diversos estudios han señalado que, aunque puede mejorar determinados análisis, también puede introducir correlaciones artificiales, modificar la estructura original de los datos o generar señales biológicas espurias si no se aplica adecuadamente [87, 77]. En particular, uno de los principales retos consiste en distinguir correctamente entre ceros técnicos y ceros biológicos, ya que imputar valores sobre genes realmente no expresados puede alterar la interpretación biológica del experimento.

Hou et al. realizaron una evaluación sistemática de métodos de imputación en scRNA-seq, mostrando que el rendimiento de estos enfoques depende de forma considerable del tipo de dato, de la tarea downstream evaluada y de las propiedades del conjunto de datos analizado [77]. Asimismo, Wang et al. revisan las principales familias metodológicas existentes y destacan que no existe un único método óptimo para todos los escenarios, sino que la elección del enfoque debe depender de las características del dataset, del objetivo biológico y del análisis posterior que se pretenda realizar [78].

.

4. El problema de la anotación celular

4.1. Introducción

Una de las tareas principales del análisis de datos scRNA-seq consiste en interpretar la estructura celular del conjunto de datos mediante la asignación de identidades biológicas a las células, relacionándolas con tipos celulares conocidos, estados funcionales o fases del ciclo celular. Este proceso se conoce generalmente como anotación de identidad celular.

No obstante, las diferencias transcripcionales detectadas podrían no tener ninguna relevancia funcional. Por ello, una anotación celular debe reconocer la estructura jerárquica de los linajes biológicos y ser capaz de integrar nuevos puntos de datos en marcos de referencia estables, como los atlas celulares, que capturen tanto tipos celulares discretos como estados de transición fluidos [43].

Tradicionalemnte, la anotación celular se ha realizado de forma manual y es en parte subjetiva. Como consecuencia, se han creado herramientas orientadas a la identificación automática del tipo celular. Estos métodos buscan relacionar los perfiles de expresión génica de células individuales con identidades celulares conocidas mediante diferentes estrategias, entre las que destacan el uso bases de datos de genes marcadores seleccionadas, la correlación de datos de expresión de referencia o la transferencia de etiquetas a través de clasificación supervisada

4.2. Métodos automáticos

El desarrollo de métodos automáticos de anotación celular ha estado estrechamente ligado al crecimiento de los atlas transcriptómicos y a la necesidad de analizar conjuntos de datos cada vez más grandes y complejos. La disponibilidad de referencias transcriptómicas bien anotadas, junto con los avances en aprendizaje automático, ha permitido el diseño de herramientas capaces de transferir conocimiento biológico entre distintos conjuntos de datos y plataformas de secuenciación [21].

El aprendizaje automático constituye una rama de la inteligencia artificial orientada al desarrollo de modelos capaces de aprender relaciones y patrones directamente a partir de los datos, sin necesidad de definir explícitamente reglas o mecanismos subyacentes [16]. Una de sus principales ventajas reside en la capacidad de construir modelos predictivos incluso en escenarios donde los procesos biológicos o estadísticos responsables de los datos son desconocidos o se encuentran insuficientemente caracterizados.

De forma general, un flujo de trabajo típico de aprendizaje automático incluye varias etapas fundamentales: armonización y preparación de los datos, aprendizaje de

representaciones, entrenamiento o ajuste del modelo y evaluación del rendimiento [16].

La creciente diversidad de métodos ha dado lugar a un ecosistema heterogéneo de herramientas con distintos niveles de complejidad, interpretabilidad y capacidad de generalización. En particular, los métodos más recientes incorporan modelos probabilísticos, aprendizaje profundo y estrategias jerárquicas capaces de capturar relaciones complejas entre tipos y estados celulares [21, 27].

De forma general, las herramientas actuales pueden agruparse en tres grandes categorías: métodos basados en genes marcadores, métodos basados en referencia transcriptómica y métodos basados en clasificación supervisada.

La Tabla 4.1 resume las principales herramientas desarrolladas para la anotación automática de tipos celulares en datos scRNA-seq, así como los enfoques computacionales empleados por cada una de ellas.

Tabla 4.1: Herramientas para la anotación automática de tipos celulares en datos scRNA-seq [21].

Categoría	Herramienta	Lenguaje	Aproximación computacional
Genes marcadores	scCATCH	R	Sistema de puntuación
	SCSA	Python	Sistema de puntuación
	SCINA	R	Ajuste de distribución bimodal a genes marcadores
	CellAssign	R	Modelo bayesiano probabilístico
Basados en correlación	scmap-cluster	R/Web	Coseno, Spearman, Pearson
	scmap-cell	R/Web	kNN basado en distancia coseno
	SingleR	R	Correlación de Spearman
	CHETAH	R/Shiny	Spearman + confianza
	scMatch	Python	Spearman, Pearson
	ClustifyR	R	Spearman, Pearson, Kendall, coseno
	CIPR	R/Shiny	Producto escalar, Spearman, Pearson
Clasificación supervisada	CaSTLe	R	Clasificador XGBoost
	Moana	Python	kNN suavizado + SVM
	LAmbDA	Python	Múltiples técnicas de ML
	superCT	Web	Red neuronal artificial
	SingleCellNet	R	Random Forest
	Garnett	R	Regresión elastic net
	scPred	R	SVM
	ACTINN	Python	Red neuronal artificial
	OnClass	Python	kNN y red neuronal bilineal
	scClassify	R/Shiny	Clasificador kNN ponderado
Otros	scANVI	Python	Clasificador kNN
	Capybara	R	Programación cuadrática
	scID	R	Análisis discriminante lineal de Fisher
	scNym	Python	Red neuronal adversaria

4.2.1. Métodos basados en genes marcadores

Los métodos basados en genes marcadores utilizan conjuntos de genes característicos asociados a tipos celulares específicos para inferir automáticamente la identidad celular. Dichos marcadores pueden obtenerse a partir de la literatura científica, bases de datos especializadas u ontologías celulares previamente curadas [21].

Este enfoque se fundamenta en la hipótesis de que determinados genes presentan patrones de expresión altamente específicos para ciertos tipos celulares. Por tanto, la presencia o sobreexpresión de estos genes puede emplearse como criterio para asignar etiquetas biológicas a células individuales o clústeres celulares.

Entre las herramientas más representativas se encuentran scCATCH, SCSA, SCINA y CellAssign. Mientras que algunas utilizan sistemas de puntuación basados en enriquecimiento de marcadores, otras incorporan modelos probabilísticos o estadísticos más complejos, como distribuciones bimodales o modelos bayesianos [21].

Una de las principales ventajas de estos métodos reside en su interpretabilidad biológica y en la incorporación explícita de conocimiento experto. Sin embargo, su rendimiento depende fuertemente de la calidad y cobertura de las bases de datos de genes marcadores utilizadas. Además, presentan dificultades para identificar estados celulares transicionales o poblaciones celulares no representadas previamente en las referencias biológicas disponibles.

4.2.2. Métodos basados en referencia

Los métodos basados en referencia utilizan conjuntos de datos transcriptómicos previamente anotados como guía para identificar tipos celulares en nuevos conjuntos de datos. En lugar de emplear únicamente genes marcadores específicos, estos enfoques comparan perfiles completos de expresión génica entre células de consulta y referencias biológicas conocidas [88].

Generalmente, la anotación se realiza mediante medidas de similitud o correlación transcriptómica, como correlación de Pearson, Spearman, similitud coseno o algoritmos basados en vecinos más cercanos (k-nearest neighbors, kNN). El objetivo consiste en asignar a cada célula la identidad correspondiente al perfil de referencia más similar.

Herramientas como SingleR, scmap, CHETAH o ClustifyR representan algunas de las aproximaciones más utilizadas dentro de esta categoría [21]. Algunas de estas herramientas permiten además utilizar múltiples conjuntos de referencia simultáneamente, incorporar clasificaciones jerárquicas o identificar células potencialmente desconocidas.

Los métodos basados en referencia suelen ofrecer una mayor capacidad de generalización que los enfoques puramente basados en genes marcadores, especialmente cuando se dispone de atlas celulares amplios y bien anotados. No obstante, su rendimiento puede verse afectado por diferencias técnicas entre datasets, efectos de lote y variaciones derivadas de distintas plataformas de secuenciación.

4.2.3. Métodos basados en clasificación supervisada

En el campo del aprendizaje automático, el término aprendizaje supervisado se utiliza para referirse a la construcción de un modelo de distribución de etiquetas (tipos

celulares) en función de un conjunto de características (genes), entrenado con datos de referencia (un conjunto de datos previamente anotado).

Los métodos de clasificación supervisada abordan la anotación celular como un problema clásico de aprendizaje supervisado, en el que un modelo computacional es entrenado utilizando conjuntos de datos previamente anotados con el objetivo de aprender las relaciones existentes entre los perfiles de expresión génica y las identidades celulares correspondientes [21].

Formalmente, estos enfoques buscan construir una función predictiva capaz de asignar etiquetas biológicas a nuevas células no anotadas a partir de un conjunto de características transcriptómicas. Para ello, utilizan datasets de referencia etiquetados durante la fase de entrenamiento y posteriormente aplican el modelo aprendido sobre nuevas observaciones [89].

Pueden distinguirse dos grandes grupos: métodos basados en algoritmos clásicos de Machine Learning y métodos basados en Deep Learning.

Machine Learning

Los primeros enfoques supervisados para anotación celular automática se fundamentaron principalmente en técnicas clásicas de Machine Learning. Estos métodos emplean algoritmos supervisados capaces de construir fronteras de decisión a partir de perfiles transcriptómicos previamente anotados, permitiendo posteriormente clasificar nuevas células según sus patrones de expresión génica [89].

Entre los algoritmos más utilizados destacan las máquinas de vectores de soporte (SVM), Random Forest, XGBoost y métodos basados en k vecinos más cercanos (kNN). Estas técnicas han demostrado un rendimiento competitivo en numerosos benchmarks de anotación celular debido a su robustez, interpretabilidad y menor coste computacional respecto a arquitecturas profundas [21].

Herramientas como scPred utilizan clasificadores SVM entrenados sobre representaciones reducidas mediante análisis de componentes principales (PCA), con el objetivo de disminuir la dimensionalidad y reducir el impacto del ruido transcriptómico [90]. Por otro lado, SingleCellNet implementa clasificadores Random Forest junto con estrategias de transformación de pares génicos para mejorar la robustez frente a efectos de lote y variaciones tecnológicas [13].

Otros métodos, como Garnett o scClassify, incorporan además estructuras jerárquicas de tipos celulares y estrategias avanzadas de selección de características para mejorar la precisión de clasificación en poblaciones celulares complejas [91, 92].

Aunque los métodos clásicos de Machine Learning presentan generalmente una elevada eficiencia y una buena capacidad de generalización, suelen depender en mayor medida de procesos manuales de selección de características y de transformaciones previas de los datos [16].

Entre los algoritmos de Machine Learning más utilizados destacan las máquinas de vectores de soporte (SVM), Random Forest, k-nearest neighbors (kNN), regresión logística, árboles de decisión y métodos basados en boosting, como XGBoost [89, 21].

SingleCellNet

SingleCellNet es un método supervisado basado en Random Forest diseñado específicamente para clasificar datos de secuenciación de ARN de células individuales entre diferentes especies y plataformas.

A diferencia de otros enfoques que utilizan directamente los niveles absolutos de expresión génica, SingleCellNet transforma inicialmente los datos de entrada mediante una estrategia denominada Top-Pair Transformation. Este procedimiento consiste en generar comparaciones binarias entre pares de genes seleccionados, evaluando cuál de los dos presenta una mayor expresión en cada célula. De esta forma, los perfiles transcriptómicos originales se convierten en representaciones binarias menos sensibles a variaciones técnicas y efectos de normalización.

Posteriormente, el método selecciona los pares génicos más discriminativos entre tipos celulares mediante técnicas de coincidencia de plantillas y utiliza estas relaciones binarias como variables de entrada para entrenar un clasificador multiclase basado en Random Forest. Además, SingleCellNet incorpora una categoría adicional denominada 'desconocida', construida mediante perfiles sintéticos generados aleatoriamente, con el objetivo de identificar células que no pertenezcan a ninguna de las clases presentes en el conjunto de entrenamiento [13].

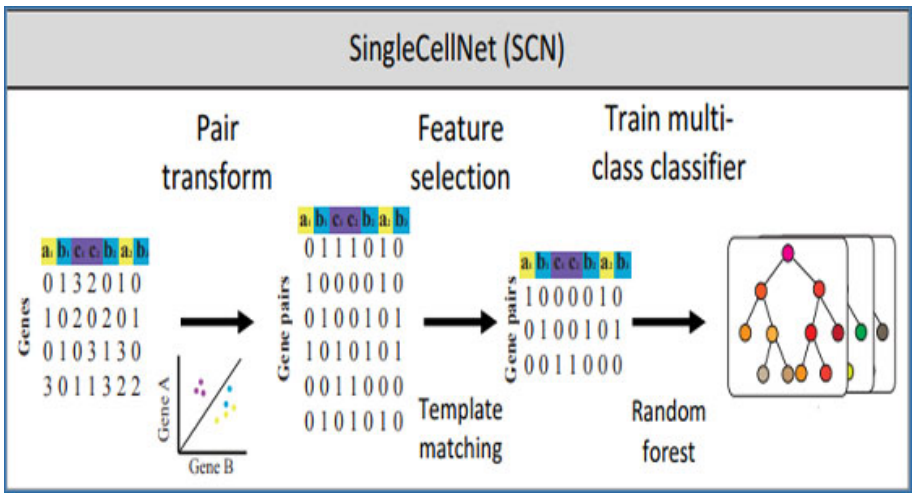


Figura 4.1: Esquema de SingleCellNet (SCN). SCN selecciona los mejores pares de genes de clasificación de los datos de entrenamiento utilizando un enfoque similar al algoritmo Top-scoring-pair y los transforma en una matriz binaria. Luego se entrena un clasificador de bosque aleatorio multiclase con los datos de entrenamiento transformados. Los datos de scRNA-Seq de consulta también se transformarán en pares y se genera una puntuación de clasificación para cada célula de consulta. Figura extraída de [13].

Celltypist

CellTypist es una herramienta automatizada de anotación de tipos celulares basada en clasificadores de regresión logística optimizados mediante el algoritmo de descenso de gradiente estocástico. A través de CellTypist, las etiquetas de los tipos celulares se

pueden transferir desde los modelos integrados (actualmente centrados en los tipos de células inmunitarias) o cualquier modelo entrenado a los datos de consulta [14].

Uno de los principales objetivos de Celltypist es proporcionar una anotación rápida y escalable sobre datasets de gran tamaño, permitiendo además transferir conocimiento entre distintos tejidos y plataformas de secuenciación. Para ello, el framework incorpora modelos preentrenados construidos a partir de grandes colecciones de datos inmunológicos y atlas celulares públicos [14].

El modelo realiza inicialmente procesos de normalización y selección de características transcriptómicas, tras los cuales aplica clasificadores lineales optimizados mediante regularización. Esta aproximación permite reducir el coste computacional y mejorar la interpretabilidad de las predicciones, manteniendo al mismo tiempo elevados niveles de precisión en la anotación celular.

Además, Celltypist permite realizar procesos de refinamiento mediante clustering posterior, facilitando la corrección de predicciones ambiguas y mejorando la consistencia biológica de las anotaciones finales.

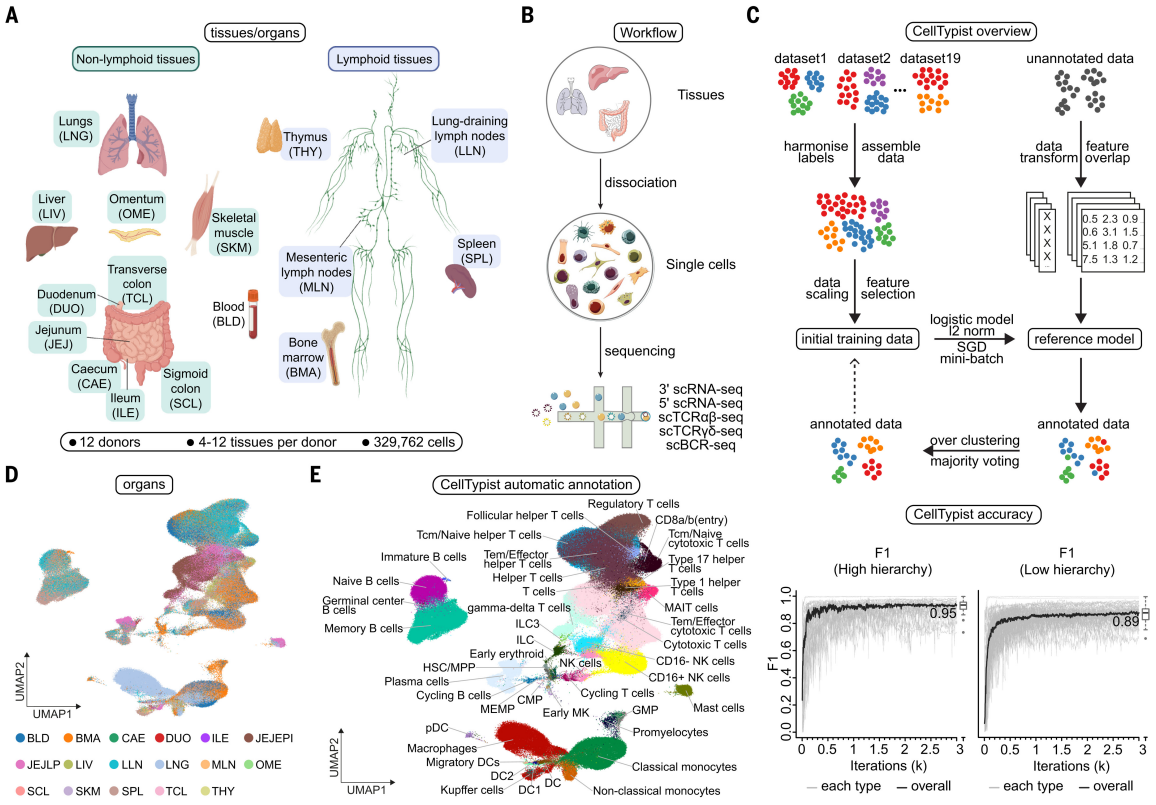


Figura 4.2: Esquema general del desarrollo y funcionamiento de CellTypist. (A) Recopilación de muestras procedentes de distintos tejidos humanos linfoides y no linfoides. (B) Perfilado transcriptómico de célula única junto con secuenciación de receptores inmunitarios TCR y BCR. (C) Flujo de trabajo de CellTypist, incluyendo recopilación y procesamiento de datos, entrenamiento del modelo y predicción de tipos celulares, junto con la evolución del rendimiento durante el entrenamiento mediante descenso estocástico por mini-lotes. (D) Representación UMAP de las células inmunitarias coloreadas según el tejido de origen. (E) Representación UMAP coloreada según los tipos celulares predichos por CellTypist. Figura extraída de [14].

SVM

Las máquinas de vectores de soporte (Support Vector Machines, SVM) constituyen uno de los algoritmos clásicos de aprendizaje supervisado más utilizados en bioinformática y análisis transcriptómico [93]. Su objetivo consiste en construir hiperplanos óptimos capaces de separar diferentes clases celulares dentro de espacios de alta dimensionalidad.

Las máquinas de vectores de soporte presentan diversas ventajas que han favorecido su aplicación en problemas de clasificación de alta dimensionalidad. Entre ellas destacan su eficacia en espacios con un gran número de variables, así como su capacidad para mantener un buen rendimiento incluso cuando el número de dimensiones supera al número de muestras disponibles. Además, los modelos SVM utilizan únicamente un subconjunto de las muestras de entrenamiento, denominadas vectores de soporte, para construir la frontera de decisión, lo que contribuye a una utilización eficiente de la memoria. Finalmente, estos métodos ofrecen una elevada flexibilidad gracias al uso de funciones kernel, que permiten modelar relaciones tanto lineales como no lineales entre los datos. Estos modelos buscan maximizar el margen de separación entre clases celulares, mejorando así la capacidad de generalización frente a nuevas observaciones.

Herramientas como scPred emplean clasificadores SVM entrenados sobre representaciones reducidas mediante análisis de componentes principales (PCA), lo que permite disminuir el ruido transcriptómico y reducir el riesgo de sobreajuste [90]. Dependiendo del tipo de kernel utilizado, las SVM pueden modelar tanto relaciones lineales como fronteras de decisión altamente complejas.

Aunque las SVM suelen ofrecer un buen rendimiento, su eficacia puede verse limitada en situaciones donde la dimensionalidad de los datos es extremadamente alta en relación con el número de muestras disponibles.

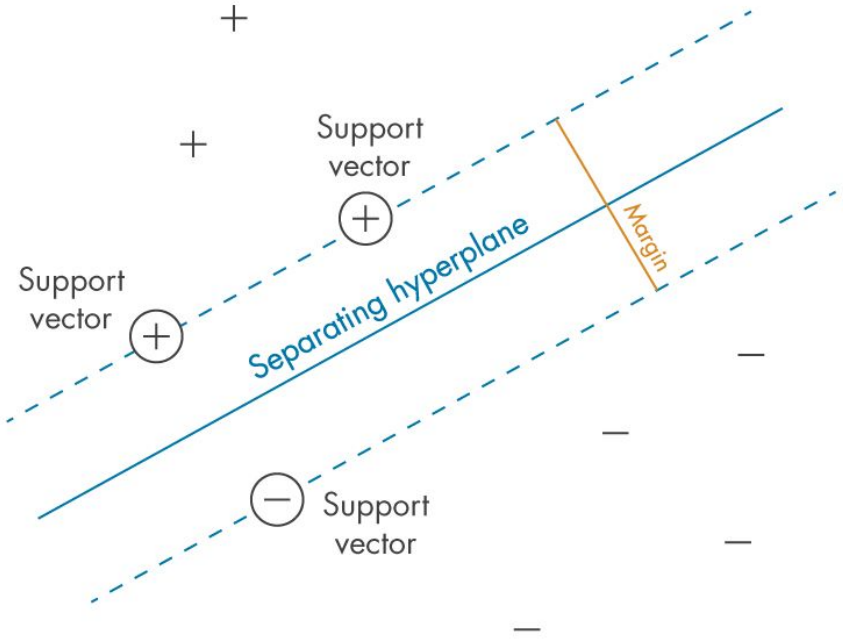


Figura 4.3: Representación del funcionamiento de una máquina de vectores de soporte (SVM). Figura extraída de [15]

Deep Learning

El aprendizaje profundo representa una evolución de los enfoques tradicionales de Machine Learning mediante el uso de arquitecturas neuronales profundas capaces de aprender automáticamente representaciones jerárquicas directamente a partir de los datos transcriptómicos [16].

Los métodos clásicos de aprendizaje automático suelen basarse en transformaciones relativamente simples del espacio de entrada, frecuentemente lineales, lo que limita su capacidad para modelar relaciones altamente complejas presentes en datos biológicos de alta dimensionalidad, como los perfiles transcriptómicos derivados de experimentos scRNA-seq [16]. En contraste, el aprendizaje profundo permite construir modelos computacionales formados por múltiples capas de procesamiento no lineal capaces de aprender representaciones de los datos con diferentes niveles de abstracción [94].

La principal diferencia entre las arquitecturas de Deep Learning y las redes neuronales artificiales tradicionales reside en la profundidad de las redes y en su capacidad para aprender automáticamente características relevantes a partir de los datos brutos. Mientras que las redes neuronales tradicionales suelen estar limitadas a un reducido número de capas ocultas y dependen en gran medida de representaciones específicas diseñadas para una tarea concreta, las arquitecturas profundas generan representaciones internas progresivamente más complejas y generalizables a medida que la información atraviesa sucesivas capas de procesamiento [16].

De este modo, cada capa de una red profunda aprende patrones de mayor nivel

de abstracción a partir de las representaciones generadas por las capas anteriores. Este aprendizaje jerárquico permite modelar relaciones no lineales altamente complejas y extraer automáticamente características relevantes sin necesidad de procesos manuales de ingeniería de variables [94].

Entre las arquitecturas más utilizadas destacan las redes neuronales multicapa (MLP), autoencoders, variational autoencoders (VAE), graph neural networks (GNN) y modelos adversariales [26].

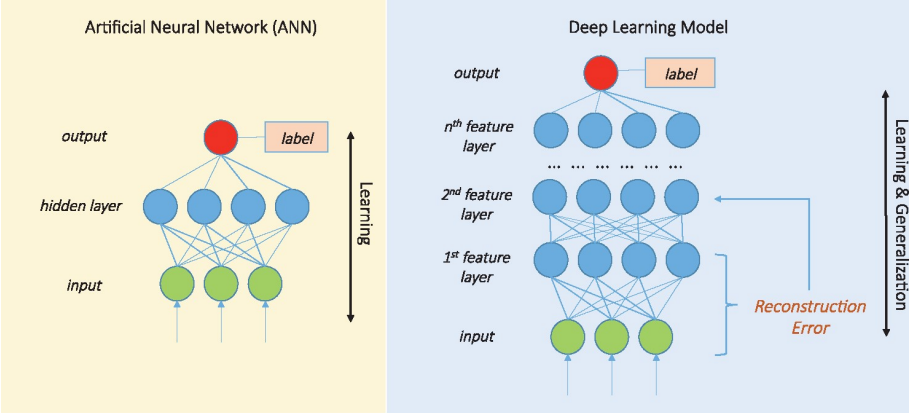


Figura 4.4: Comparación conceptual entre redes neuronales artificiales tradicionales y arquitecturas de aprendizaje profundo. Las arquitecturas profundas incorporan múltiples capas ocultas capaces de aprender representaciones jerárquicas y no lineales de los datos transcriptómicos. Figura extraída de [16].

Como consecuencia, durante los últimos años han surgido numerosas arquitecturas de Deep Learning específicamente diseñadas para tareas de anotación celular automática, integración de datasets, reducción de dimensionalidad y modelado de trayectorias celulares.

ACTINN

ACTINN (Automated Cell Type Identification using Neural Networks) constituye uno de los primeros modelos de Deep Learning desarrollados específicamente para la anotación automática de tipos celulares en datos scRNA-seq [95].

El modelo se basa en una red neuronal artificial multicapa completamente conectada entrenada mediante aprendizaje supervisado sobre datasets transcriptómicos previamente anotados. La arquitectura utiliza varias capas ocultas con funciones de activación no lineales y optimización mediante descenso por gradiente y retropropagación del error.

Uno de los principales objetivos de ACTINN es mejorar la capacidad de generalización entre diferentes plataformas de secuenciación y reducir el impacto de los efectos de lote. Para ello, el modelo incorpora estrategias de normalización y regularización orientadas a estabilizar el aprendizaje sobre datasets heterogéneos [95].

La arquitectura empleada está compuesta por una capa de entrada, tres capas ocultas y una capa de salida. La capa de entrada contiene un número de neuronas igual al número de genes del conjunto de entrenamiento, mientras que las capas

ocultas poseen 100, 50 y 25 neuronas, respectivamente. La capa de salida contiene tantas neuronas como tipos celulares presentes en el entrenamiento [95].

La propagación hacia adelante puede expresarse como:

$$x^{[i]} = g\left(W^{[i]}x^{[i-1]} + b^{[i]}\right)$$

donde $W^{[i]}$ representa la matriz de pesos, $b^{[i]}$ el sesgo y g la función de activación.

Para las capas ocultas se emplea la función ReLU:

$$\text{ReLU}(x) = \text{máx}(0, x)$$

mientras que en la capa de salida se utiliza la función *softmax*:

$$\text{softmax}(x_j) = \frac{e^{x_j}}{\sum_k e^{x_k}}$$

El entrenamiento se realiza minimizando una función de pérdida basada en entropía cruzada:

$$L(y, y') = -\sum_j y_j \log(y'_j)$$

donde y representa las etiquetas reales y y' las probabilidades predichas por la red. Además, ACTINN incorpora regularización L2 para reducir el sobreajuste [95].

Los resultados reportados por los autores muestran que ACTINN alcanza elevadas tasas de precisión incluso en escenarios con subtipos celulares estrechamente relacionados y datasets generados mediante distintas tecnologías de secuenciación.

ScDeepSort

ScDeepSort es un método de anotación celular automática basado en Graph Neural Networks (GNN) desarrollado específicamente para datos scRNA-seq [17]. A diferencia de los enfoques tradicionales basados únicamente en vectores de expresión génica, ScDeepSort modela explícitamente las relaciones estructurales entre células y genes mediante grafos bipartitos ponderados.

El modelo representa las células y genes como nodos dentro de una estructura gráfica, mientras que los niveles de expresión génica definen las conexiones entre ambos tipos de nodos. Posteriormente, una arquitectura basada en GraphSAGE permite propagar información a través del grafo y aprender representaciones embebidas capaces de capturar relaciones transcriptómicas complejas [17].

Una de las principales ventajas de ScDeepSort es que no requiere genes marcadores previamente definidos ni referencias externas explícitas durante la anotación. Además, el uso de redes neuronales sobre grafos permite integrar simultáneamente información global y local de la estructura transcriptómica.

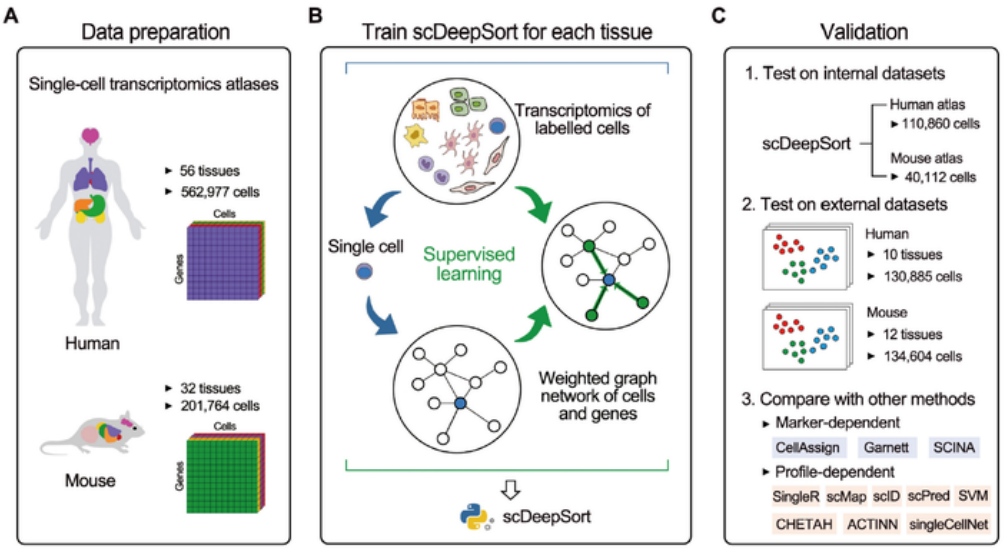


Figura 4.5: Marco conceptual general y validación de scDeepSort. (A) Se seleccionaron atlas de transcriptómica de células individuales humanas y de ratón de HCL y MCA como datos subyacentes para entrenar scDeepSort. (B) Para cada célula, se construyó una red gráfica de esta célula, sus genes y células vecinas para el aprendizaje supervisado de scDeepSort con etiquetas celulares conocidas de los atlas transcriptómicos para cada tejido. (C) Se emplearon conjuntos de datos internos de atlas humanos y de ratón y conjuntos de datos de prueba externos de datos de transcriptómica de células individuales que involucran múltiples tejidos para probar el rendimiento de scDeepSort. Se compararon los métodos de anotación dependientes de marcadores y perfiles con scDeepSort. Figura extraída de [17].

Los autores reportan que ScDeepSort alcanza elevados niveles de precisión tanto en datasets humanos como de ratón, mostrando además una buena capacidad de generalización entre distintos tejidos y plataformas de secuenciación [17].

Frameworks computacionales para aprendizaje profundo

El desarrollo de modelos de aprendizaje profundo ha sido facilitado por la aparición de frameworks especializados orientados al cálculo numérico de alto rendimiento y la aceleración mediante GPU. Entre las plataformas más ampliamente utilizadas destacan PyTorch [96], TensorFlow [97] y Keras [98], que proporcionan interfaces flexibles para el diseño y entrenamiento de redes neuronales profundas.

En el ámbito específico de aprendizaje sobre grafos, bibliotecas como Deep Graph Library (DGL) [99] y PyTorch Geometric (PyG) [100] han permitido extender arquitecturas profundas tradicionales hacia dominios relacionales complejos.

Tabla 4.2: Resumen de los marcos de trabajo ampliamente utilizados en aprendizaje profundo y aprendizaje sobre grafos. Tabla extraída de [1].

Framework	Categoría	Lenguaje	Disponibilidad
PyTorch	Deep Learning	Python / C++	https://github.com/pytorch/pytorch
TensorFlow	Deep Learning	Python / C++	https://github.com/tensorflow/tensorflow
Keras	Deep Learning	Python	https://github.com/keras-team/keras
DGL	Graph Learning	Python	https://github.com/dmlc/dgl
PyTorch Geometric (PyG)	Graph Learning	Python	https://github.com/pyg-team/pytorch_geometric

4.3. Retos actuales

A pesar del notable avance de los métodos para la anotación automática de tipos celulares, esta tarea continúa presentando importantes limitaciones metodológicas y biológicas. De acuerdo con los desafíos planteados por Lähnemann et al. [27], la ciencia de datos de célula única se enfrenta todavía a problemas abiertos relacionados con la incertidumbre de las mediciones, la alta dimensionalidad, la integración de datos y la definición de referencias celulares suficientemente estables. Estos aspectos afectan de forma directa a la anotación celular, ya que la asignación de una identidad biológica a cada célula depende tanto de la calidad de los datos como de la disponibilidad de modelos y referencias adecuados.

Uno de los principales retos procede de la propia naturaleza de los datos scRNA-seq. La cantidad limitada de material transcriptómico capturado por célula genera mediciones ruidosas, dispersas y con una elevada proporción de valores cero. Estos ceros pueden corresponder tanto a ausencia real de expresión como a fallos técnicos de detección, lo que dificulta distinguir entre señal biológica y ruido experimental. Como consecuencia, los perfiles de expresión utilizados para clasificar las células pueden estar incompletos o distorsionados, afectando especialmente a poblaciones poco abundantes, estados celulares intermedios o tipos celulares con marcadores poco específicos.

Otra limitación relevante es la definición del propio concepto de tipo celular. La anotación celular suele formularse como un problema de clasificación discreta, en el que cada célula se asigna a una única categoría. Sin embargo, muchos procesos biológicos presentan una organización continua, como la diferenciación, la activación celular o las transiciones entre estados funcionales. En estos casos, una etiqueta discreta puede simplificar en exceso la realidad biológica y ocultar gradientes transcriptómicos relevantes. Por ello, la elección del nivel de resolución resulta crítica: una anotación demasiado general puede perder subpoblaciones importantes,

mientras que una anotación excesivamente granular puede generar categorías poco robustas o difícilmente interpretables.

La dependencia de atlas y conjuntos de referencia constituye otro desafío central. Los métodos supervisados requieren datos previamente anotados, pero estas referencias pueden estar sesgadas hacia determinados tejidos, especies, tecnologías o condiciones experimentales. Además, no siempre contienen todos los tipos o estados celulares presentes en una nueva muestra. En consecuencia, una célula puede ser forzada a pertenecer a una clase existente aunque represente un estado no contemplado en el conjunto de entrenamiento. Este problema se agrava cuando se trabaja con tejidos patológicos o muestras tumorales, donde la diversidad celular puede diferir sustancialmente de la observada en los atlas disponibles.

También deben considerarse los efectos de lote y las diferencias entre plataformas experimentales. Variaciones en el protocolo de secuenciación, la profundidad de lectura, el procesamiento de la muestra o el laboratorio de origen pueden introducir diferencias técnicas que los modelos pueden confundir con variación biológica. Por este motivo, la integración de datos procedentes de distintos experimentos sigue siendo una cuestión crítica. Una anotación fiable debe ser capaz de generalizar entre conjuntos de datos heterogéneos sin eliminar señales biológicas reales ni introducir correspondencias artificiales entre poblaciones celulares.

Por otra parte, la escalabilidad representa una dificultad adicional. Los experimentos actuales pueden incluir miles o millones de células y decenas de miles de genes, lo que exige métodos consistentes, reproducibles y capaces de operar en espacios de alta dimensionalidad. Esta complejidad afecta tanto al entrenamiento de modelos supervisados como a la construcción de grafos, la selección de genes informativos, la reducción de dimensionalidad y la comparación sistemática entre herramientas.

La evaluación de los métodos de anotación celular continúa siendo un problema abierto. La comparación entre herramientas depende de la calidad de las etiquetas de referencia, de las estrategias de validación utilizadas y de las métricas empleadas para cuantificar el rendimiento. En este sentido, diversos trabajos han señalado la necesidad de utilizar evaluaciones más rigurosas y comparativas sistemáticas que permitan valorar adecuadamente la capacidad de generalización de los modelos y su comportamiento frente a poblaciones celulares heterogéneas [27].

Como señalan Miotto et al. [101], los modelos de aprendizaje profundo aplicados al ámbito biomédico presentan todavía importantes limitaciones relacionadas con la disponibilidad de datos, la interpretabilidad y la heterogeneidad de las muestras. Estas arquitecturas suelen requerir grandes volúmenes de datos anotados para entrenar modelos robustos, mientras que en muchos contextos biológicos las muestras disponibles son limitadas o presentan una elevada heterogeneidad. Asimismo, los datos de secuenciación unicelular son inherentemente ruidosos, dispersos y afectados por valores faltantes, lo que dificulta la construcción de representaciones latentes estables y generalizables.

Otro aspecto especialmente relevante es la interpretabilidad de los modelos. Aunque las arquitecturas profundas pueden alcanzar un elevado rendimiento predictivo, con frecuencia funcionan como modelos de caja negra, dificultando la

comprensión biológica de las decisiones tomadas por el sistema. En el ámbito biomédico, esta limitación adquiere una importancia crítica, ya que no solo resulta necesario obtener predicciones precisas, sino también comprender qué patrones transcriptómicos o marcadores celulares sustentan dichas predicciones. Por ello, el desarrollo de modelos interpretables y biológicamente consistentes constituye actualmente una de las principales líneas de investigación en el análisis computacional de datos de célula única.

4.4. Herramientas y frameworks

4.4.1. DANCE

DANCE se presenta como una biblioteca y plataforma de evaluación comparativa de aprendizaje profundo para facilitar la investigación y el desarrollo en el análisis de células individuales. DANCE proporciona un conjunto de herramientas integral para facilitar el desarrollo de algoritmos de análisis de células individuales y una comparación justa del rendimiento en diferentes conjuntos de datos de referencia. Actualmente, DANCE admite 3 módulos, 8 tareas, 32 modelos y 21 conjuntos de datos [18].

El proceso de análisis de células individuales con la plataforma DANCE incluye la recopilación de datos, la descarga de datos, el procesamiento de datos (preprocesamiento y construcción de gráficos) y el desarrollo de modelos en tareas posteriores específicas.

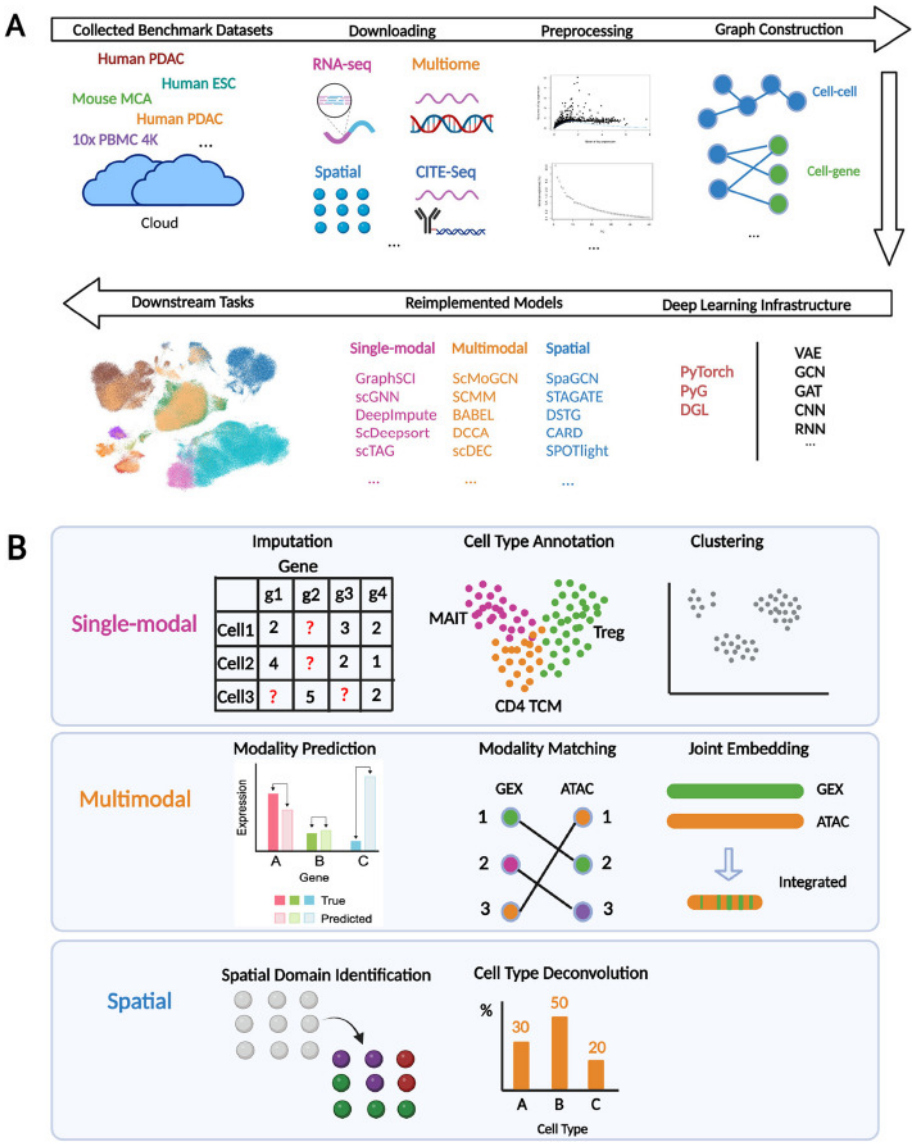


Figura 4.6: Perspectiva del usuario de la plataforma DANCE. a Descripción general del flujo de análisis ómico de células individuales con la plataforma DANCE. b Tareas posteriores compatibles actualmente en DANCE. Figura extraída de [18].

Actualmente , DANCE admite tres tareas en el módulo de modalidad única , tres tareas en el módulo de multimodalidad y dos tareas en el módulo de transcriptómica espacial.

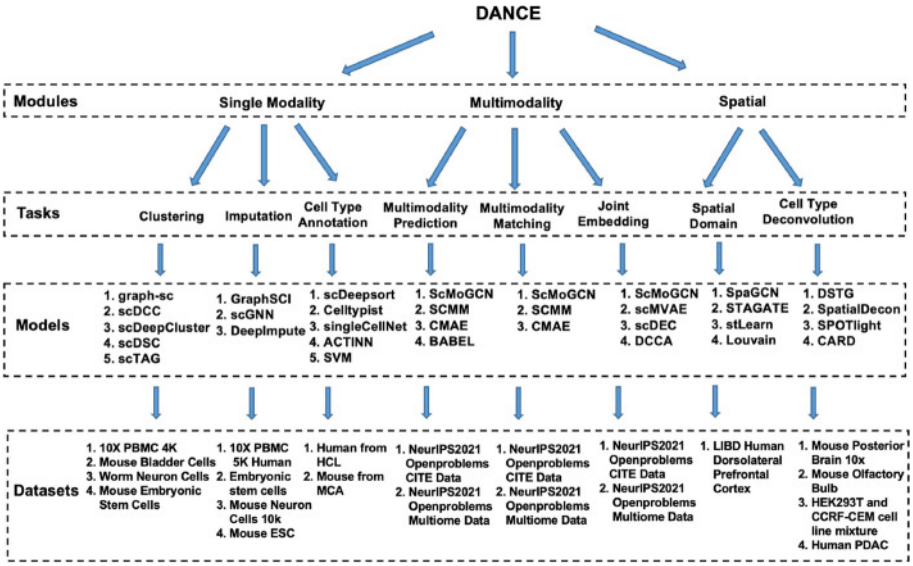


Figura 4.7: Resumen de los módulos, tareas, modelos y conjuntos de datos compatibles con el paquete DANCE. Figura extraída de [18].

Además, no solo funciona como una biblioteca de aprendizaje profundo para facilitar el desarrollo de modelos por parte de los usuarios, sino también como una plataforma de referencia para una evaluación integral. Entre los aspectos más relevantes de DANCE destacan la cobertura de módulos integral, su infraestructura de aprendizaje profundo e implementar puntos de referencia estandarizados.

La Figura 4.8 resume las principales diferencias entre DANCE y las bibliotecas y plataformas de análisis de células individuales existentes.

		Scanpy	Seurat	scvi-tools	DeepCell	Squidpy	DANCE
Comprehensive module coverage	Single modality	✓	✓	✓	✓	✗	✓
	Multimodality	✓	✓	✓	✗	✗	✓
	Spatial	✓	✓	✓	✗	✓	✓
Deep learning infrastructure	Classical deep learning	✗	✗	✓	✓	✓	✓
	GNNs	✗	✗	✗	✗	✓	✓
Standardized benchmarks	Benchmark datasets	✓	✓	✗	✓	✗	✓
	Task-specific algorithms	✓	✓	✗	✓	✗	✓
	Reproducible command lines	✗	✗	✗	✗	✗	✓

Figura 4.8: Comparativa de librerías para el análisis de célula única. Figura extraída de [18]).

El framework integra múltiples herramientas orientadas tanto al aprendizaje automático como al aprendizaje profundo, ofreciendo soporte para diferentes tareas bioinformáticas, entre las que destacan la anotación celular, imputación de datos, integración de datasets, análisis espacial y reconstrucción de redes regulatorias. Para ello, incorpora módulos específicos para la carga de datos, preprocesamiento,

construcción de grafos celulares, entrenamiento de modelos y evaluación mediante métricas estandarizadas [102].

Dentro del módulo de modalidad única se encuentra la anotación de tipos celulares, inspirada en la aplicación de estadísticas de propiedades celulares para inferir tipos celulares. A partir de la expresión génica de varios tipos celulares, se puede calcular el grado de similitud para cada célula con una matriz de expresión unicelular determinada. Con base en el resultado óptimo de similitud, se puede inferir el tipo celular. En DANCE, se admiten 5 modelos que establecen medidas para evaluar la similitud de los perfiles de expresión génica de células desconocidas con las matrices de expresión génica de tipos celulares conocidos. El rendimiento del modelo se evalúa mediante la precisión de la predicción [102].

Todos los modelos en DANCE se implementan en un entorno de desarrollo unificado basado en el lenguaje Python usando PyTorch, DGL y PyG como marcos base. Además, todos los modelos en DANCE tienen interfaces genéricas para su uso, entre ellas se encuentran la carga de datos, la especificación de funciones de preprocesamiento, la obtención de datos de entrenamiento y prueba, y la evaluación del modelo [102].

Finalmente, cabe destacar que DANCE es una plataforma de referencia estándar, flexible y extensible para acceder y evaluar métodos computacionales en un amplio espectro de conjuntos de datos de referencia para diversas tareas de análisis de células individuales. Asimismo, si bien DANCE admite tareas, modelos y conjuntos de datos de referencia limitados, su implementación es altamente modular.

4.4.2. Scanpy

Scanpy es un conjunto de herramientas escalable para analizar datos de expresión génica de células individuales, desarrollado conjuntamente con AnnData . Incluye métodos para el preprocesamiento, visualización, agrupamiento, inferencia de pseudotiempo y trayectoria, pruebas de expresión diferencial y simulación de redes reguladoras de genes. Además, su implementación basada en Python maneja eficientemente conjuntos de datos de más de un millón de células [103].

Scanpy integra las posibilidades de análisis de marcos establecidos basados en R y los proporciona de forma escalable y modular. Específicamente, ofece un preprocesamiento comparable a Seurat y Cell Ranger, visualización a través de t-SNE, mapas de difusión, agrupamiento similar a PhenoGraph, identificación de genes marcadores para clústeres a través de pruebas de expresión diferencial y ordenamiento pseudotemporal a través de pseudotiempo de difusión [103].

Con Scanpy se presenta la clase AnnData [19], con su correspondiente paquete AnnData, que almacena una matriz de datos con las anotaciones más generales posibles: anotaciones de observaciones (muestras, células) y variables (características, genes), así como anotaciones no estructuradas.Todas las herramientas estadísticas y de aprendizaje automático extraen información de una matriz de datos, que puede añadirse a un objeto ANNDATA sin alterar su estructura [103].

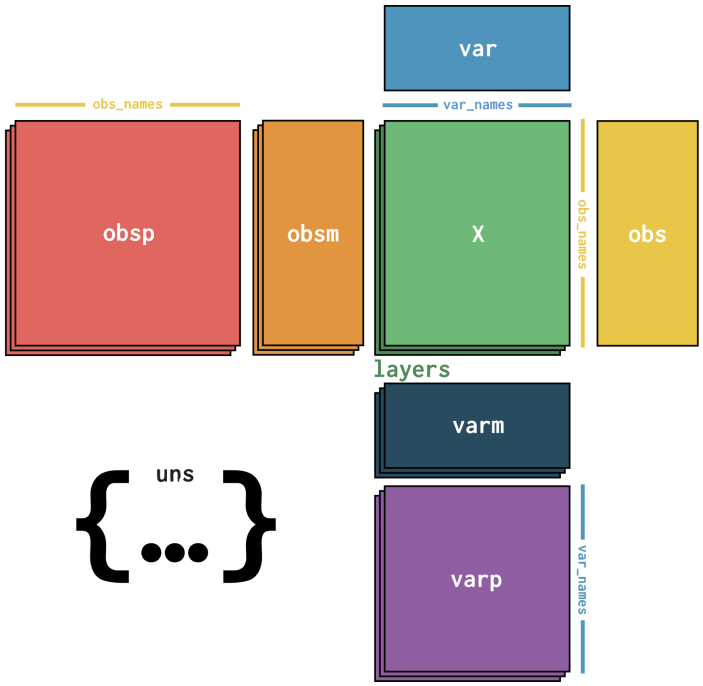


Figura 4.9: Estructura interna del objeto `AnnData` utilizado para el almacenamiento y análisis de datos de secuenciación de ARN de célula única. La matriz principal `X` contiene los valores de expresión génica, mientras que los distintos componentes auxiliares almacenan metadatos celulares (`obs`), información génica (`var`), representaciones embebidas (`obsm`), grafos de vecindad (`obsp`), capas adicionales (`layers`) y otra información no estructurada (`uns`). Figura extraída de [19].

Asimismo implementa un elevado número de algoritmos ampliamente utilizados en el análisis de célula única. Entre ellos destacan PCA para reducción de dimensionalidad lineal, UMAP y t-SNE para visualización no lineal, así como los algoritmos Louvain y Leiden para detección de comunidades y agrupamiento celular [56].

Otra característica relevante de Scanpy es su capacidad para trabajar con conjuntos de datos de gran tamaño. En comparación con otras herramientas previamente desarrolladas para volúmenes más reducidos de datos, Scanpy fue diseñado para escalar eficientemente a cientos de miles o millones de células mediante estructuras optimizadas.

5. Primer experimento

El presente capítulo describe y detalla la implementación y desarrrollo del primer estudio experimental. Esta fase se centra en el objetivo principal del trabajo: el análisis comparativo de modelos de anotación celular.

Se analiza el comportamiento de los modelos sobre el dataset Mouse Cell Atlas (MCA), y para ello se plantean dos enfoques diferenciados. El primero corresponde a la implementación del flujo proporcionado por la herramienta DANCE, es decir, la reproducibilidad de los modelos basados en anotación celular siguiendo los ejemplos y líneas de comando proporcionados por DANCE.

En el segundo, se sustituye la etapa de procesamiento por un pipeline explícito mediante la herramienta Scanpy. Esta modificación posibilita implementar un control más detallado sobre el control de calidad, filtrado celular y génico, normalización, transformación logarítmica, selección de genes altamente variables y reducción de dimensionalidad. Posteriormente, los datos procesados se utilizan como entrada para los mismos modelos de anotación celular.

Aunque DANCE incorpora ciertas transformaciones de procesamiento, estas se encuentran orientadas a la preparación de los datos para modelos específicos y carecen de un control explícito sobre las distintas etapas, pues se encuentran integradas dentro de los procedimientos de la propia librería. Por el contrario, el flujo de trabajo basado en Scanpy permite una definición detallada y transparente de cada fase del procesamiento.

Por tanto, el experimento se diseña como una comparación controlada entre:

- Parte 1: procesamiento proporcionado por DANCE junto con la evaluación de modelos incorporados en la propia librería.
- Parte 2: procesamiento mediante Scanpy junto con los mismos modelos incorporados en DANCE.

De esta forma, se mantiene la evaluación sobre el mismo conjunto de modelos, aislando y comparando dos enofques de procesamiento distintos.

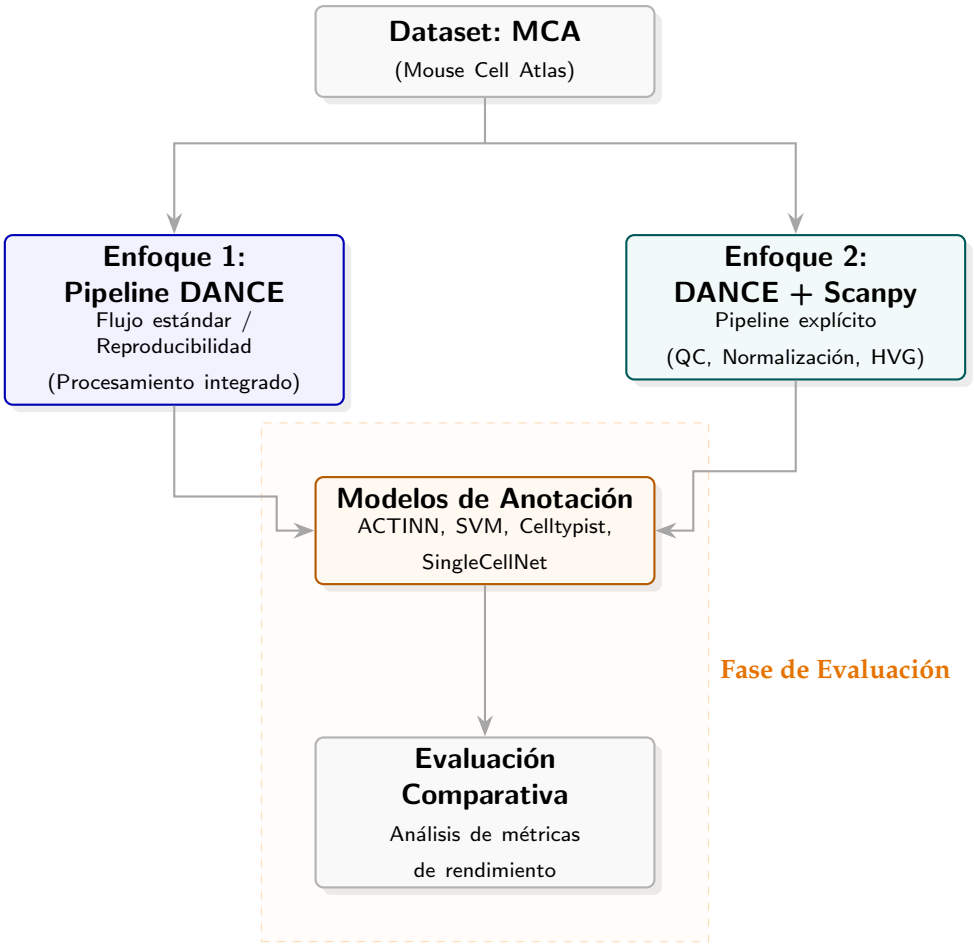


Figura 5.1: Diagrama del flujo experimental del Experimento 1.

5.1. Conjunto de datos

El conjunto de datos analizado en este experimento es el Mouse Cell Atlas (MCA), uno de los repositorios más destacados en la transcriptómica de célula única. Específicamente, se ha elegido el subconjunto que concierne al tejido cerebral de ratón (mouse brain).

Este conjunto de datos incluye perfiles de expresión génica que se han adquirido por medio de la secuenciación de RNA a nivel de célula única, lo cual posibilita el análisis individualizado de la actividad transcriptómica en miles de células. En tejidos como el cerabro esta resolución es de particular importancia, donde coexisten varios tipos de células con funciones distintas y, en numerosos casos, con estados funcionales dinámicos.

```
Inspección de benchmarks disponibles en DANCE
Número total de benchmarks: 276
```

	Benchmark	Categoría
0	test_mouse_Brain2695_celltype.csv	Mouse / MCA
1	test_mouse_Brain2695_data.csv	Mouse / MCA
2	test_mouse_Kidney203_celltype.csv	Mouse / MCA
3	test_mouse_Kidney203_data.csv	Mouse / MCA
4	test_mouse_Spleen1759_celltype.csv	Mouse / MCA
5	test_mouse_Spleen1759_data.csv	Mouse / MCA
6	train_mouse_Brain3285_celltype.csv	Mouse / MCA
7	train_mouse_Brain3285_data.csv	Mouse / MCA
8	train_mouse_Brain753_celltype.csv	Mouse / MCA
9	train_mouse_Brain753_data.csv	Mouse / MCA
10	train_mouse_Kidney4682_celltype.csv	Mouse / MCA
11	train_mouse_Kidney4682_data.csv	Mouse / MCA
12	train_mouse_Spleen1970_celltype.csv	Mouse / MCA
13	train_mouse_Spleen1970_data.csv	Mouse / MCA

Figura 5.2: Conjuntos de datos de ratón (mouse) disponibles dentro de la herramienta DANCE, correspondientes a distintos tejidos, entre ellos el cerebro (brain), rodilla (kidney) o bazo (spleen).

Dentro de DANCE, los datos del MCA no aparecen como una sola entidad monolítica, en cambio, están organizados en varios benchmarks estructurados por tejido (Figura 5.2). Después de inspeccionar el repositorio interno y debido a varios criterios, se ha elegido el subconjunto de los datos que corresponde al tejido cerebral de ratón (mouse brain).

Primero, su tamaño y complejidad lo hacen apropiado para la evaluación de modelos de anotación celular. En segundo lugar, debido a la variedad de tipos celulares existentes y a la complejidad biológica del tejido cerebral. Finalmente, el cerebro constituye uno de los tejidos más representativos y ampliamente estudiado dentro de los datos scRNA-seq.

5.1.1. Configuración

La configuración del dataset mediante la clase `CellTypeAnnotationDataset` se especificica explícitamente los subconjuntos de entrenamiento y prueba. En particular, se utilizan dos subconjuntos para entrenamiento y uno para evaluación:

- Entrenamiento: 753, 3285
- Test: 2695

Tabla 5.1: Configuración del dataset elegido en el experimento.

Parámetro	Valor	Descripción
Especie	*Mus musculus*	Organismo de estudio.
Tejido	Brain	Tejido cerebral.
Origen	Mouse Cell Atlas	Referencia del dataset de scRNA-seq.
Train IDs	753, 3285	Subconjuntos empleados para el entrenamiento.
Test ID	2695	Subconjunto empleado para la evaluación.
Validación	0.0	No se emplea partición de validación adicional.

5.1.2. Estructura

Una vez cargado, el dataset se representa internamente mediante un objeto de tipo `AnnData`. Este formato permite incorporar la matriz de expresión génica con los metadatos asociados a las observaciones y variables, además de favorecer el estudio flexible de los datos y facilitar su integración en herramientas especialzadas como `Scanpy`.

En esta estructura, la matriz principal `X` contiene los niveles de expresión génica con dimensiones $n_{\text{obs}} \times n_{\text{vars}}$, donde las filas corresponden a células individuales y las columnas a genes. Esta representación se caracteriza por presentar por un elevado número de genes y una dispersión significativa de los datos.

Los metadatos asociados a las células y a los genes se almacenan en las estructuras `obs` y `var`, respectivamente, mientras que otras representaciones se organizan en `obsm` y `uns`.

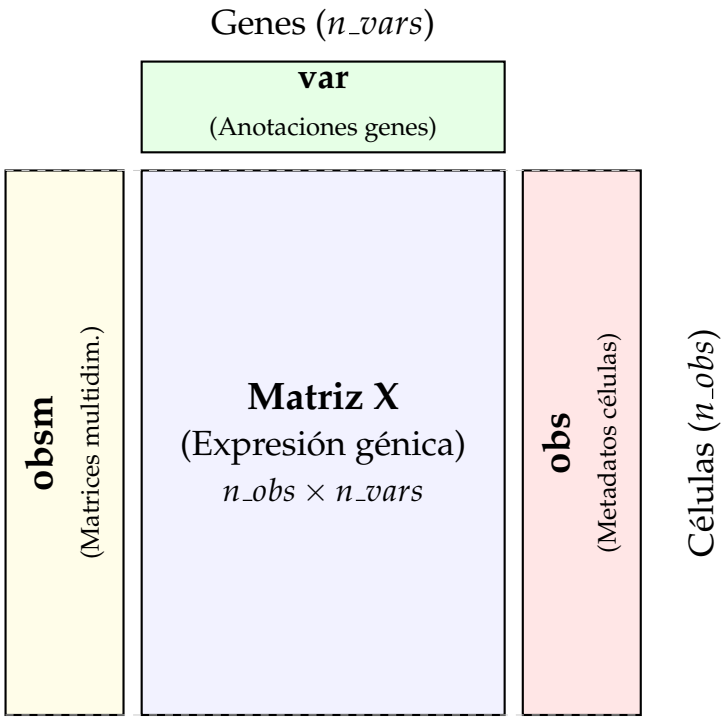


Figura 5.3: Representación del objeto AnnData y la organización de metadatos. Basada en [20].

Como se observa en la Figura 5.3, la estructura se divide en:

- **Matriz X:** almacena los conteos de expresión génica con dimensiones 6733×19856, correspondientes a 6733 células y 19856 genes. En este caso, la matriz se encuentra en formato denso (`numpy.ndarray`).
- **obs:** contiene los metadatos asociados a las células. Sin embargo, en la carga inicial del dataset mediante DANCE, este campo se encuentra vacío.
- **var:** destinado a las anotaciones de los genes, que igualmente no están presentes en esta fase inicial del preprocesado.
- **obsm:** estructura que almacena representaciones adicionales. En este experimento, contiene la clave `cell_type`, donde se encuentran codificadas las etiquetas de tipo celular utilizadas como variable objetivo en los modelos de clasificación.

Exploración de la anotación original

El carácter de etiquetado es un aspecto del diseño experimental de DANCE. Según el protocolo de benchmarking determinado por Ding et al. [104], las anotaciones originales de Han et al. [105] han sido simplificadas en una estructura binaria para evaluar la capacidad de discriminación de los modelos bajo condiciones de desbalanceo.

El dataset MCA incorpora la anotación de los tipos celulares, utilizada como referencia en las tareas de clasificación. Esta información aparece codificada en

`obsm['cell_type']`.

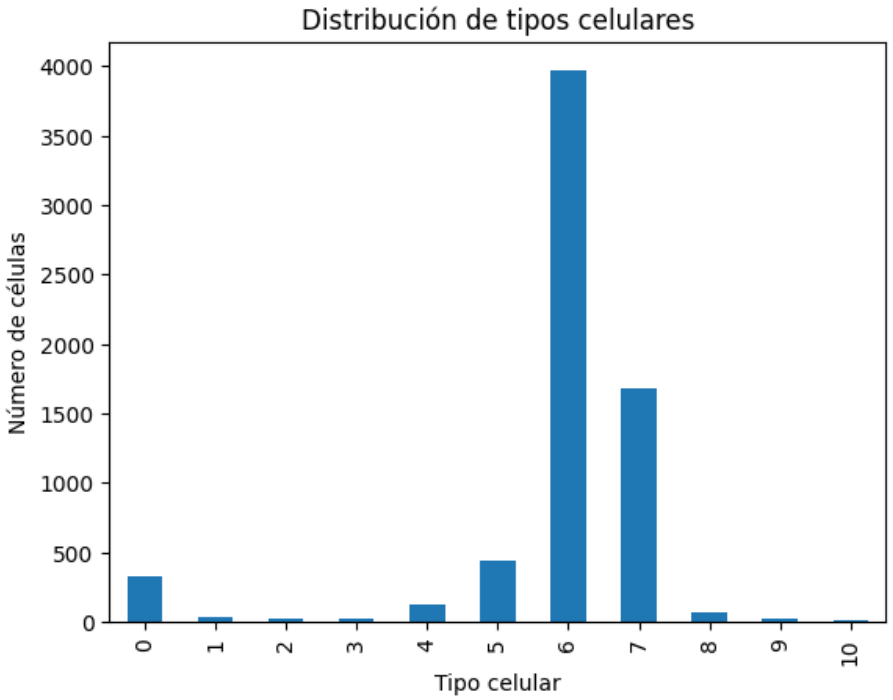


Figura 5.4: Distribución de los 11 tipos celulares del conjunto de datos.

Como se ilustra en la Figura 5.5, el dataset presenta una distribución asimétrica:

- **Neurons (Clase 0):** Población mayoritaria que representa el núcleo del tejido cerebral.
- **Non-neurons (Clase 1):** Grupo minoritario que integra linajes de soporte como glía y células vasculares.

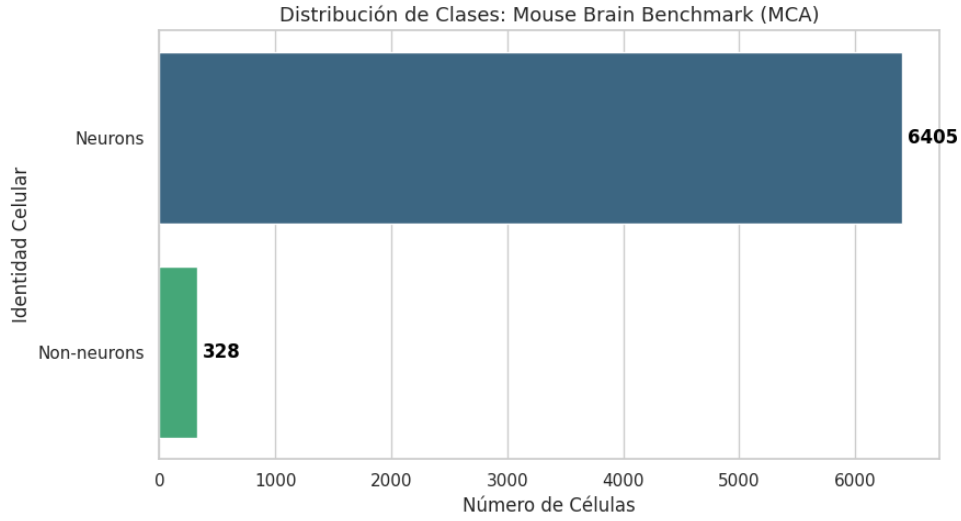


Figura 5.5: Distribución de las poblaciones celulares según su correspondencia a células neuronales o no neuronales.

Esta exploración muestra un desbalanceo significativo entre los tipos celulares, una característica habitual en datos de scRNA-seq, donde determinadas poblaciones muestran una representación considerablemente mayor que otras.

Algunas de las propiedades más relevantes de los datos de scRNA-seq son la dispersión, la heterogeneidad celular, la variabilidad técnica y la alta dimensionalidad, entre otras. Estas características permiten la aplicación de técnicas de procesamiento antes de su evaluación en modelos de aprendizaje automático

En este trabajo, dichos métodos de procesamiento se examinan a través de dos perspectivas distintas detalladas en las siguientes secciones.

5.2. Primera parte: evaluación de modelos de anotación celular con preprocesado nativo de DANCE sobre Mouse from MCA

En esta primera fase experimental se analiza el rendimiento de distintos modelos de anotación celular utilizando exclusivamente el flujo de trabajo proporcionado por el framework DANCE.

La principal finalidad de esta aproximación es reproducir el trabajo proporcionado por DANCE y comprender su funcionamiento, examinando los diferentes modelos de acuerdo con las configuraciones y sugerencias que ofrece la propia librería. Asimismo, este planteamiento permite analizar la utilidad del framework, su estructura de procesamiento y cómo integra, dentro de un entorno unificado, las diferentes fases de evaluación de modelos y preparación de datos.

Por tanto, se llevará a cabo un análisis y comparación del rendimiento de los modelos bajo condiciones estándar, sin introducir modificaciones externas en las etapas de procesamiento de datos.

El flujo experimental seguido para cada modelo se estructura en las siguientes etapas:

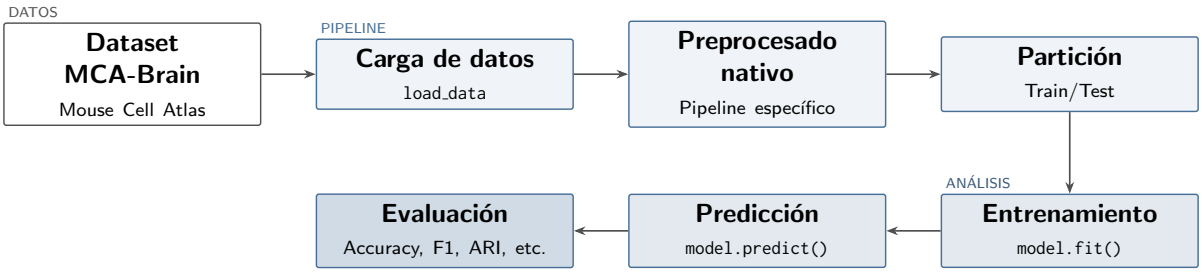


Figura 5.6: Flujo de trabajo de la primera parte del experimento.

5.2.1. Procesamiento

DANCE implementa un sistema de procesamiento basado en entornos modulares y configurables, diseñado para adaptar las transformaciones de los datos a las necesidades específicas de cada tarea y modelo de aprendizaje automático. Dicho sistema organiza el procesamiento en distintas etapas, incluyendo filtrado génico, normalización, selección de características y construcción de representaciones celulares. Cada una de estas etapas puede configurarse mediante diferentes transformaciones modificables, facilitando flujos específicos para los distintos clasificadores de anotación celular.

Entre las transformaciones disponibles se incluyen métodos de normalización como `ScTransform`, `Log1P` o `NormalizeTotal`, estrategias de selección de genes altamente variables, así como técnicas de reducción de dimensionalidad y representación celular, como `WeightedFeaturePCA`, `CellPCA` o `CellSVD`. Además, DANCE almacena la representación generada en canales específicos utilizados posteriormente como entrada por los clasificadores, normalmente definidos mediante objetos de configuración como `SetConfig`.

No obstante, en el caso concreto de los benchmarks de anotación celular utilizados en DANCE, la propia librería afirma que los datos del repositorio `CellTypeAnnotation` se ecuentran previamente normalizados.

Aunque DANCE proporciona múltiples configuraciones posibles de procesamiento, en este trabajo se reproducen específicamente los tutoriales oficiales asociados a cada modelo de anotación celular. Por tanto, las transformaciones utilizadas dependen de la implementación concreta de cada benchmark reproducido (Tabla 5.2).

Tabla 5.2: Resumen de los flujos de procesamiento según el modelo a partir de los tutoriales oficiales de DANCE.

Modelo	Configuración reproducida	Procesamiento
ACTINN	`normalize=False` `filter_genes=True`	Aplicación de filtrado génico sin normalización adicional, dado que el benchmark de DANCE considera los datos previamente normalizados.
CellTypist	`preprocessing_pipeline()`	El procesamiento se encuentra integrado dentro de la implementación proporcionada por DANCE para CellTypist. Las transformaciones concretas aplicadas no se especifican explícitamente en el tutorial reproducido.
SingleCellNet	`normalize=False` `num_top_genes=10` `num_top_gene_pairs=25`	Procesamiento específico basado en selección de genes y construcción de pares génicos discriminativos. No se aplica normalización adicional por defecto.
SVM	`dense_dim=400`	Construcción de una representación celular reducida mediante técnicas de selección de características y reducción de dimensionalidad antes del entrenamiento del clasificador.

Las transformaciones se encapsulan mediante la clase `Compose` de DANCE y se aplican directamente durante la carga del dataset mediante el método `load_data`.

5.2.2. Entrenamiento de modelos

A partir del objeto `AnnData` descrito previamente, DANCE transforma los datos en representaciones adecuadas para el entrenamiento de los modelos. En particular:

- La matriz de expresión génica (`adata.X`) se emplea como entrada principal.
- Las etiquetas de tipo celular, almacenadas en `adata.obsm[cell_type]`, se procesan y se convierten en la variable objetivo del modelo.
- Se generan subconjuntos diferenciados de entrenamiento y test de acuerdo con la partición definida en la configuración del dataset.

Se evalúan distintos modelos de anotación celular implementados en el

framework DANCE. En particular, se analizan los siguientes: **ACTINN, SVM, Celltypist y SingleCellNet**.

Todos los modelos se entrenan utilizando sus configuraciones por defecto, sin modificaciones adicionales, con el fin de garantizar la reproducibilidad del experimento y la comparabilidad entre resultados.

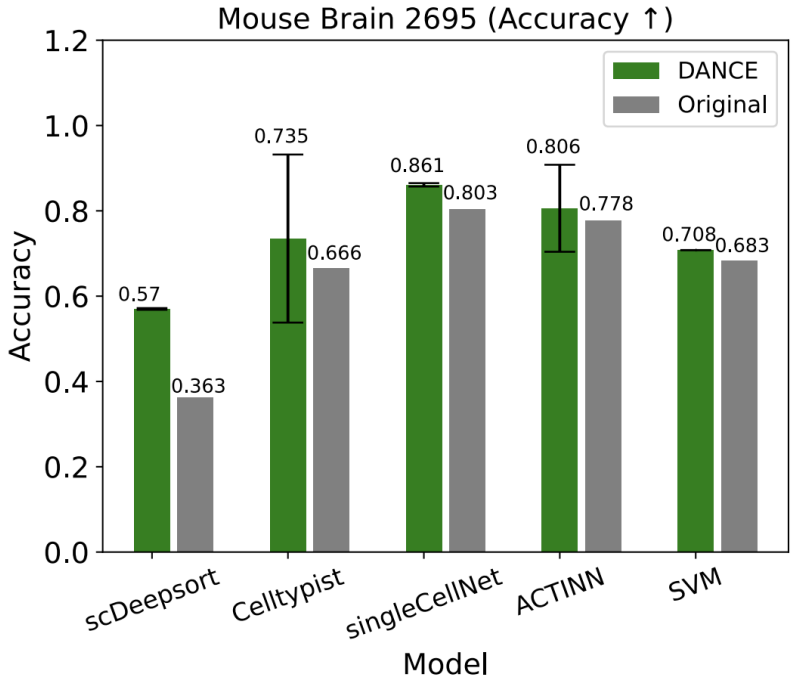
5.2.3. Resultados

Se ha optado por la **precisión (accuracy)** como el indicador general del porcentaje de células clasificadas correctamente. Sin embargo, debido a que los datos de single-cell RNA-seq muestran un desbalance significativo entre las clases celulares, existe la posibilidad de que esta métrica esté sesgada hacia las clases predominantes.

Visualización de los resultados

En la Figura 5.7, la herramienta oficial DANCE reporta la precisión obtenida por cada uno de los modelos evaluados y los compara con los resultados de las publicaciones originales.

Figura 5.7: Comparación del rendimiento entre la implementación de los modelos en DANCE y los resultados reportados en las publicaciones originales para tareas de clustering y anotación de tipos celulares. Los resultados obtenidos con DANCE corresponden al valor medio tras 20 ejecuciones con distintas semillas aleatorias, mientras que los valores originales han sido extraídos directamente de los artículos de referencia [18].



Asimismo, en la Tabla 5.3 se muestra la precisión obtenida por cada uno de los modelos evaluados en la experimentación realizada en el presente trabajo.

Tabla 5.3: Rendimiento de los modelos de anotación celular en el dataset Mouse Brain.

Modelo	**Accuracy**
Celltypist	0.8831
ACTINN	0.8757
SingleCellNet	0.8601
SVM	0.7065

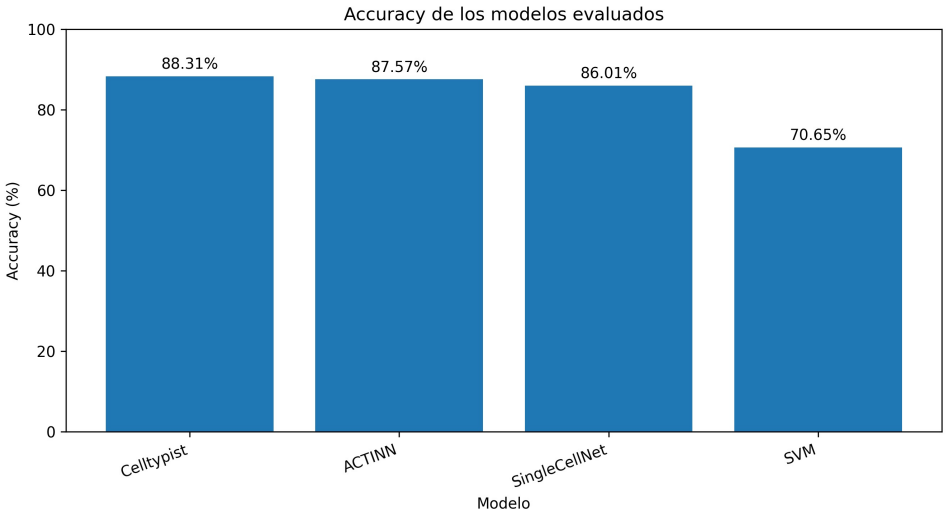


Figura 5.8: Comparación del rendimiento de los modelos en el dataset Mouse Brain.

Si comparamos los resultados reportados por la herramienta DANCE con los resultados obtenidos en el trabajo, vemos que los resultados de precisión son muy similares, lo que confirma la correcta reproducibilidad del entrenamiento.

Se puede apreciar que el modelo Celltypist es el que alcanza un mejor rendimiento global, con un valor de precisión superior al 88 %, muy seguido por **ACTINN**. Los dos modelos son capaces de capturar patrones complejos en los datos de expresión génica.

La Figura 5.9 muestra el F1-score macro.

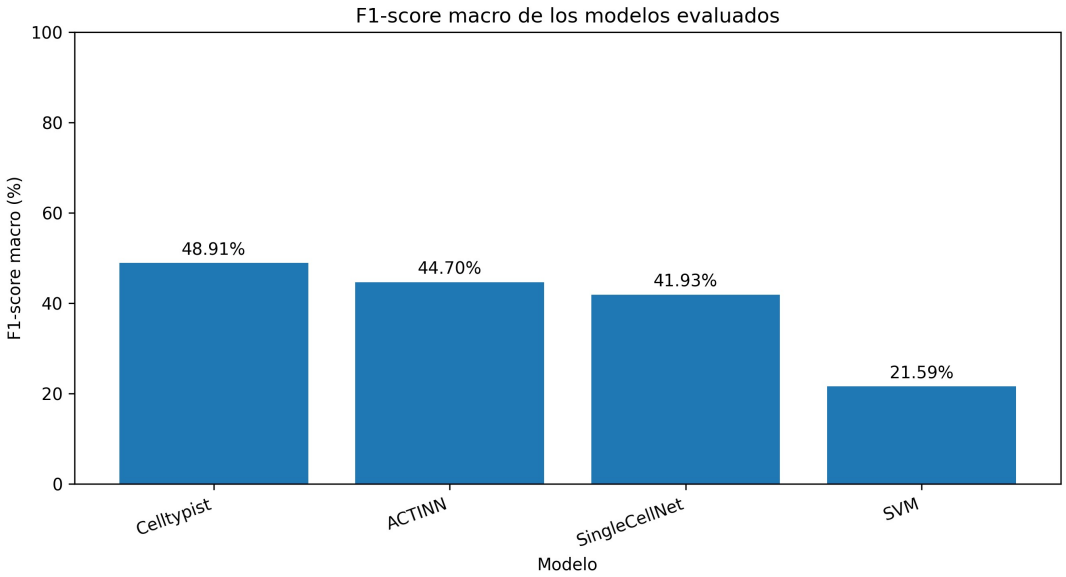


Figura 5.9: Comparación del F1-score macro entre los modelos evaluados.

Análisis de errores mediante matrices de confusión

Las matrices de confusión se construyen a partir de las predicciones generadas por cada modelo sobre el conjunto de test. En ellas, las columnas representan los valores predichos de una clase determinada, mientras que las filas representan los valores reales de una clase determinada.

Este tipo de representación es útil para analizar de forma detallada los patrones de error del modelo, identificando el número de predicciones correctas e incorrectas para todas las clases.

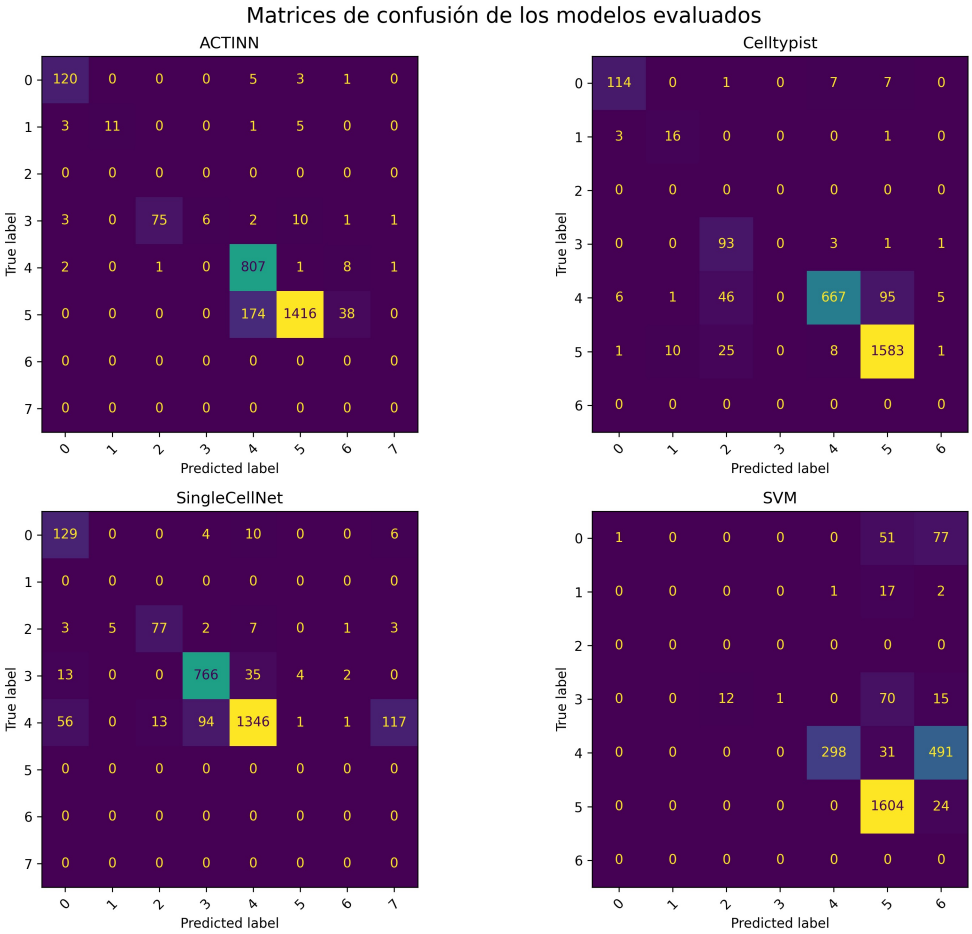


Figura 5.10: Matrices de confusión de los modelos evaluados.

Análisis de errores mediante PCA

Con el objetivo de analizar el comportamiento del modelo en el espacio de características y explorar la estructura interna de los datos, se ha aplicado un Análisis de Componentes Principales (PCA) sobre el conjunto de test. Dicha representación permite observar la distribución global de las células y comprobar la localización de las predicciones.

La Figura 5.11 muestra la proyección en dos dimensiones del espacio de datos, diferenciando entre células correctamente clasificadas e incorrectamente clasificadas por el modelo Celltypist.

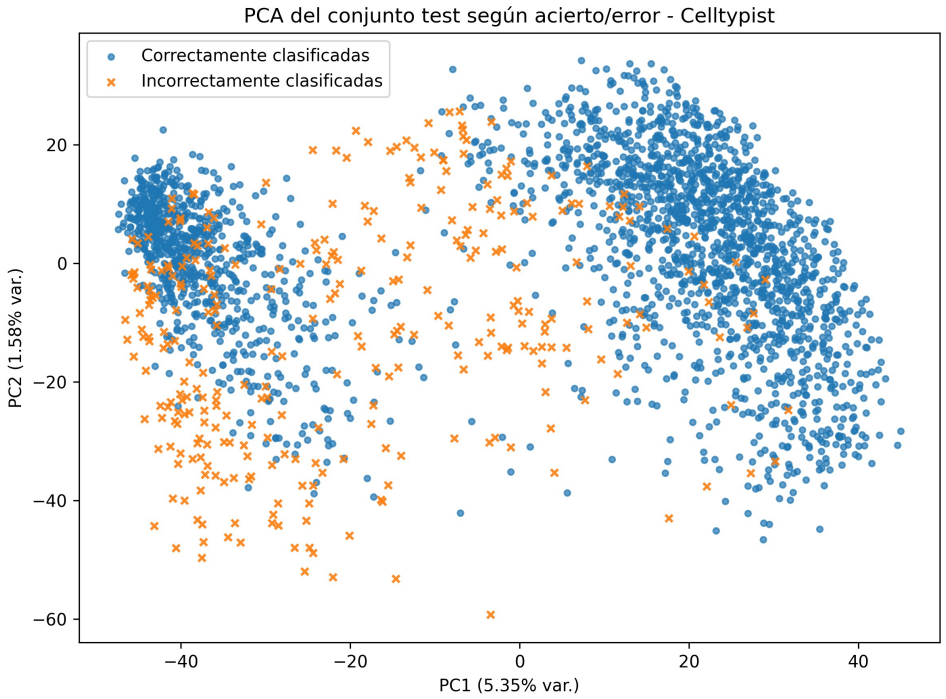


Figura 5.11: Proyección PCA del conjunto de test diferenciando aciertos y errores del modelo Celltypist.

5.3. Segunda parte: evaluación de modelos de anotación celular con preprocesado de Scanpy sobre Mouse from MCA

La diversidad en los entornos configurables presentes en DANCE ha llevado a crear un segundo flujo experimental. A diferencia de DANCE, donde cada modelo incorpora sus propias transformaciones, esta segunda parte se reproduce un tutorial de Scanpy sobre procesamiento de datos scRNA-seq con la finalidad de comprender y tener más control sobre las distintas partes del análisis.

Este planteamiento tiene dos metas: (i) evaluar cómo el procesamiento afecta el rendimiento de los modelos, y (ii) estudiar cada etapa del análisis con más detalle y conociendo con excatitud qué transformaciones se aplican a los datos. Esto permite ver de forma más transparente cómo las decisiones tomadas afectan los resultados.

5.3.1. Transformación de los datos

Una vez los datos han sido cargados y estructurados mediante un objeto de tipo `AnnData`, se procede a la transformación de los datos almacenados en la variable

'cell_type'. La anotación de los tipos celulares utilizada como referencia en la clasificación celular está codificada dentro de dicha variable.

Forma de adata.obsm['cell_type']: (6733, 11)

	Astrocyte	Astroglial cell	Granulocyte	Hypothalamic ependymal cell	Macrophage	Microglia	Myelinating oligodendrocyte
mouse_Brain753_C_1	0.0	0.0	0.0	0.0	0.0	1.0	0.0
mouse_Brain753_C_2	0.0	0.0	0.0	0.0	0.0	1.0	0.0
mouse_Brain753_C_3	0.0	0.0	0.0	0.0	0.0	1.0	0.0
mouse_Brain753_C_4	0.0	0.0	0.0	0.0	0.0	1.0	0.0
mouse_Brain753_C_5	0.0	0.0	0.0	0.0	0.0	1.0	0.0

Figura 5.12: Estructura de la clase obsm['cell_type'].

Como se ha indicado al principio del capítulo, la estructura presenta una dimensión 6733×11, lo que indica la presencia de 6733 células distribuidas en 11 tipos celulares distintos. La representación sigue un esquema de codificación one-hot, en el que cada célula se asocia a una única clase.

Para su utilización en el análisis con Scanpy, se transforma esta representación en una variable categórica única por célula, almacenada en obs['cell_type']. Esta transformación ayuda a mostrar la distribución de los diferentes tipos celulares de manera más accesible. También permite utilizar etiquetas en las visualizaciones y comparar los resultados originales con los clusters obtenidos mediante métodos no supervisados.

	cell_type
mouse_Brain753_C_1	5
mouse_Brain753_C_2	5
mouse_Brain753_C_3	5
mouse_Brain753_C_4	5
mouse_Brain753_C_5	5
...	...
mouse_Brain2695_C_2691	3
mouse_Brain2695_C_2692	3
mouse_Brain2695_C_2693	3
mouse_Brain2695_C_2694	3
mouse_Brain2695_C_2695	3

6733 rows × 1 columns

Figura 5.13: Transformación de la estructura obsm['cell_type'] a formato categórico.

5.3.2. Procesamiento

Se implementa un método de procesamiento explícito mediante la librería Scanpy, ampliamente consolidada en el análisis de datos de transcriptómica de célula única. En este caso se define de forma detallada cada una de las transformaciones aplicadas.

El flujo de trabajo seguido se inspira en las prácticas estándar del análisis de scRNA-seq de Scanpy, adaptándose a las características específicas del dataset empleado. A continuación, se presenta la Tabla 5.4 que incluye el resumen del procesado aplicado.

Tabla 5.4: Resumen del flujo de procesamiento implementado en Scanpy.

Etapa	Implementación	Finalidad metodológica
Inspección inicial	Revisión de dimensiones, tipo de matriz, rango de valores y suma de expresión por célula.	Verificar el estado inicial del objeto `AnnData` y conservar una copia de trabajo sin modificar los datos originales cargados desde DANCE.
Control de calidad	Cálculo de métricas mediante `calculate_qc_metrics`: `n_genes_by_counts`, `total_counts`, genes ribosomales y hemoglobina.	Caracterizar la complejidad transcriptómica de las células e identificar posibles observaciones atípicas o sesgos técnicos.
Filtrado inicial	Aplicación de `filter_cells(min_genes=100)` y `filter_genes(min_cells=3)`.	Eliminar células de baja complejidad y genes escasamente expresados, manteniendo un filtrado permisivo para evitar pérdida excesiva de variabilidad biológica.
Detección de dobletes	Aplicación del algoritmo `Scrublet`, generando `doublet_score` y `predicted_doublet`.	Identificar posibles perfiles celulares híbridos derivados de dobletes experimentales y evaluar su distribución sobre la estructura global del dataset.
Normalización	No se aplica normalización adicional.	Preservar la distribución original de los datos, ya que proceden de `CellTypeAnnotationDataset` y DANCE indica que se encuentran previamente normalizados.
Selección de HVGs	Selección de los 2.000 genes altamente variables mediante `highly_variable_genes(n_top_genes=2000, flavor="seurat")`.	Reducir la dimensionalidad del problema y conservar genes con mayor capacidad para capturar heterogeneidad transcriptómica.
PCA	Aplicación de `sc.tl.pca` sobre la matriz restringida a genes altamente variables.	Obtener una representación compacta de la variabilidad principal del conjunto de datos para análisis posteriores.
Grafo de vecinos	Construcción del grafo KNN mediante `sc.pp.neighbors(n_pcs=30)`.	Modelar relaciones locales de similitud entre células a partir del espacio PCA.
UMAP	Aplicación de `sc.tl.umap`.	Generar una proyección bidimensional para explorar visualmente la organización celular y posibles efectos técnicos.
Clustering	Aplicación de Leiden mediante `sc.tl.leiden(flavor="igraph", n_iterations=2)`.	Identificar agrupaciones celulares transcriptómicamente similares a partir del grafo de vecinos.
Anotación celular	Comparación con `cell_type`, análisis de genes marcadores, tablas de contingencia, ARI y NMI.	Interpretar biológicamente los clusters obtenidos y evaluar su concordancia con la anotación original del dataset.

Además, se detallan las propiedades generales del conjunto de datos antes del

procesado:

- Número de células: 6733
- Número de genes: 19856
- Dimensión de la matriz: (6733 $\times$ 19856)
- Tipo de matriz: densa
- Rango de valores: [0.0, 8.21]
- Media global: 0.12

Control de calidad

El primer paso consiste en la evaluación de la calidad de las observaciones mediante el cálculo de métricas estándar. Estas métricas permiten identificar células de baja calidad y detectar posibles artefactos técnicos.

En particular, las métricas calculadas son: el número total de conteos por célula, el número de genes detectados, así como la proporción de expresión asociada a determinados grupos génicos (genes ribosomales y de hemoglobina).

Su visualización mediante diagramas de caja y diagramas de violín facilita la detección de valores atípicos, células con baja expresión o células con un número reducido de genes detectados

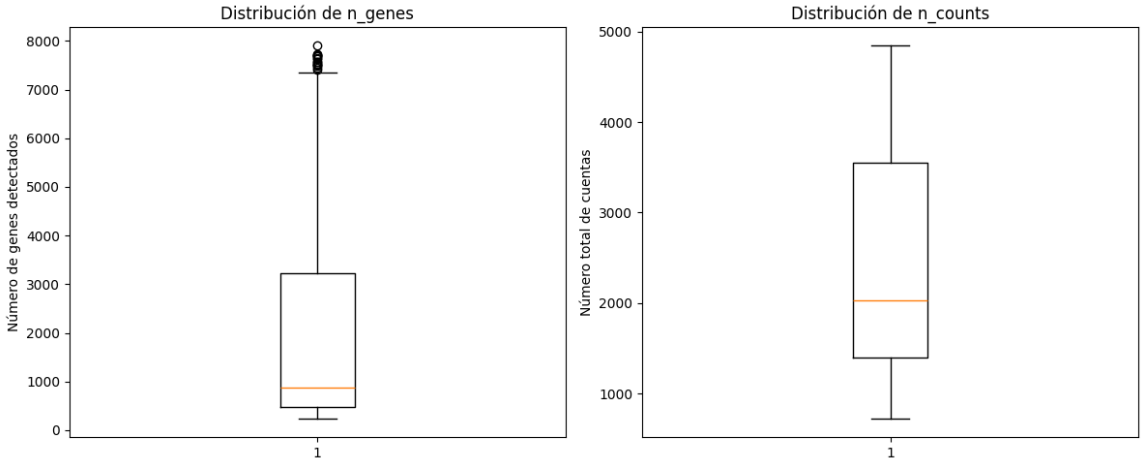


Figura 5.14: Distribución de métricas de calidad celular representadas mediante diagramas de caja (boxplots). En el panel izquierdo se muestra el número de genes detectados por célula (n genes), mientras que en el panel derecho se representa el número total de conteos o lecturas (n counts).

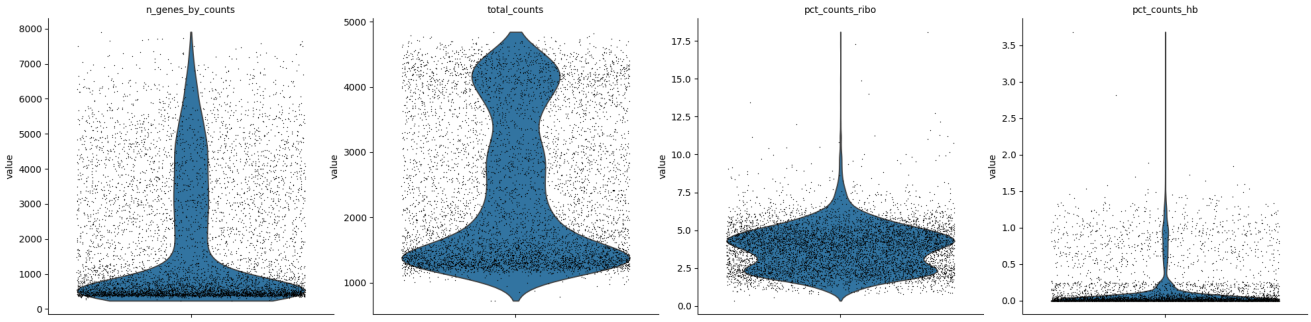


Figura 5.15: Distribución de métricas de calidad celular representadas mediante diagramas de violín.

Adicionalmente, se analiza la relación entre dichas métricas.

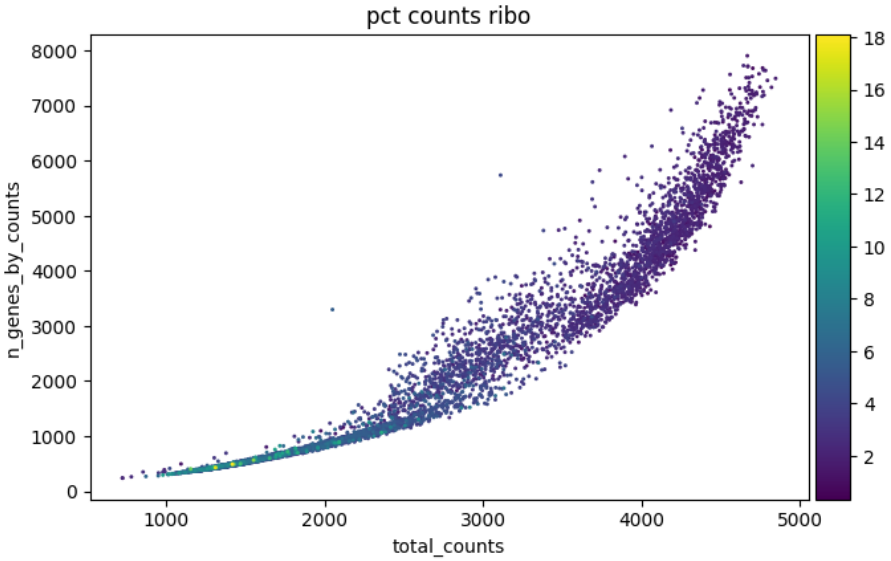


Figura 5.16: Diagrama de dispersión que relaciona el número total de conteos con el número de genes detectados por célula, coloreado según el porcentaje de expresión de genes ribonucleicos (pct counts ribo).

Adicionalmente, se aplica un filtrado inicial mediante reglas poco estrictas. En particular, se eliminan aquellas células con menos de 100 genes identificados así como los genes que se expresan en menos de 3 células. Dicho filtro se lleva a cabo con el objetivo de reducir datos con escasa relevancia informativa.

Como parte del control de calidad, se aborda la detección de dobletes, es decir, observaciones que corresponden a la captura simultánea de dos células. Para su identificación, se emplea el algoritmo Scrublet, implementado en Scanpy, que predice la probabilidad de que cada observación corresponda a un doblete mediante la comparación con dobletes simulados.

Normalización y estabilización de la varianza

Una vez completada la fase de control de calidad, se procede a la normalización de los datos.

No obstante, dado que los datos utilizados proceden directamente de la clase `CellTypeAnnotationDataset` de DANCE, y el propio framework indica que dichos datasets se consideran previamente normalizados, no se ha aplicado una etapa adicional de normalización.

Selección de genes altamente variables

Debido al elevado número de genes presente en el conjunto de datos, se realiza una reducción de dimensionalidad mediante la selección de genes altamente variables. Este mecanismo ayuda a encontrar genes cuya variabilidad entre células es especialmente elevada.

En este trabajo se emplea la función `highly variable genes` de Scanpy sobre la matriz ya normalizada y transformada logarítmicamente, utilizando el criterio estándar inspirado en Seurat. Siguiendo una práctica habitual en análisis de transcriptómica de célula única, se seleccionan los 2.000 genes más variables.

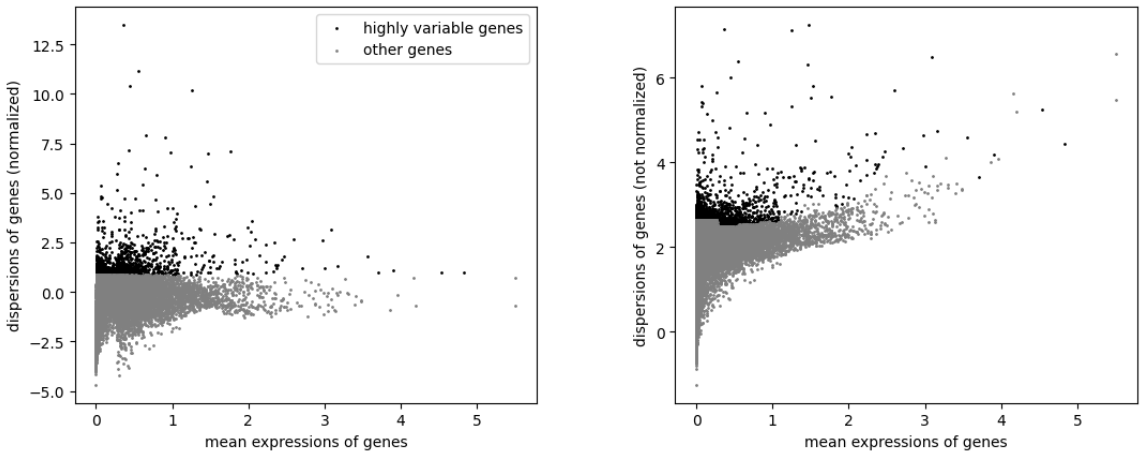


Figura 5.17: Representación de la selección de genes altamente variables. A la izquierda se muestra la dispersión normalizada frente a la expresión media de los genes, mientras que a la derecha se representa la dispersión no normalizada.

Reducción de la dimensionalidad mediante PCA

Sobre el conjunto de genes seleccionados se aplica un análisis de componentes principales (PCA), con el objetivo de proyectar los datos en un espacio de menor dimensión que capture la mayor parte de la variabilidad.

Se analiza la proporción de varianza explicada por los distintos componentes principales con el fin de determinar el número adecuado de dimensiones a considerar.

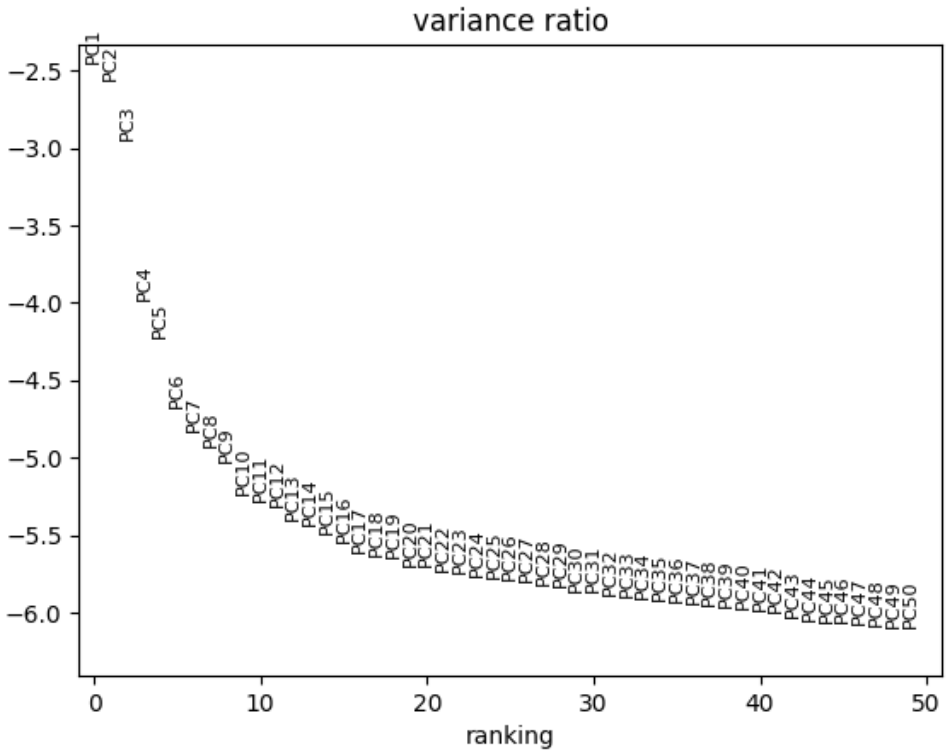


Figura 5.18: Proporción de varianza explicada por los primeros componentes principales obtenidos mediante PCA.

Asimismo, se inspecciona la distribución de determinadas métricas de calidad en el espacio definido por los primeros componentes principales.

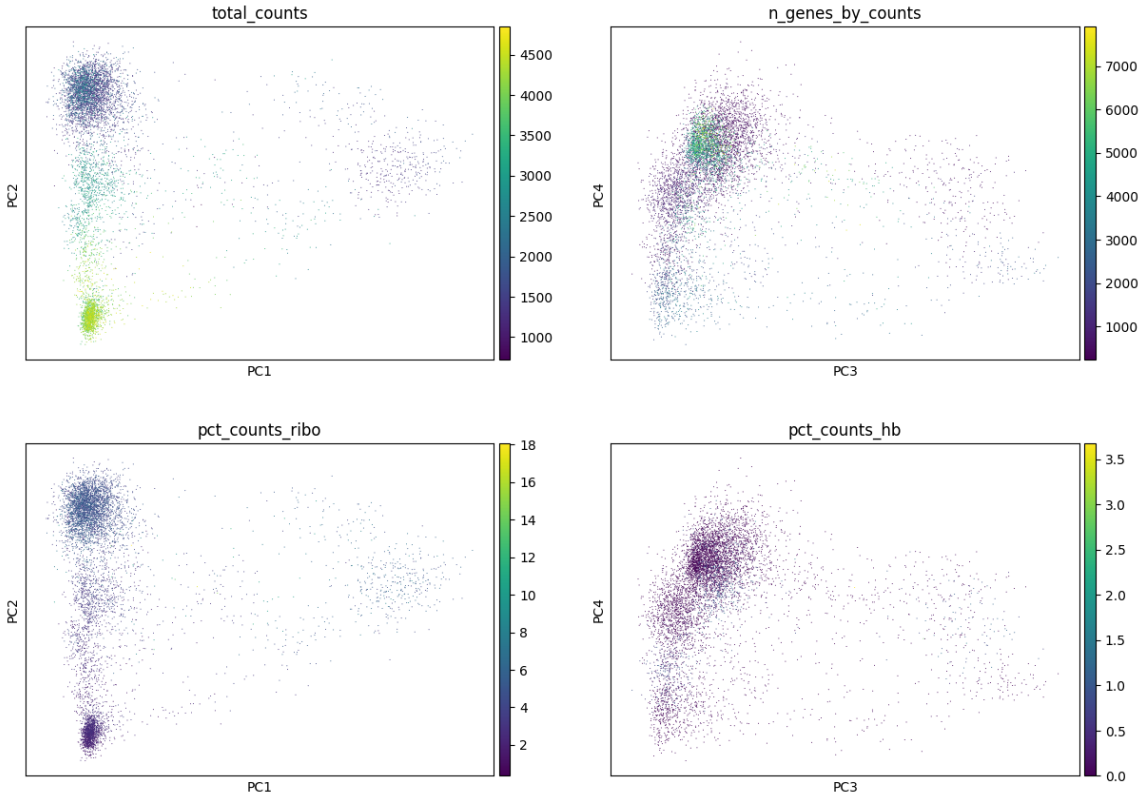


Figura 5.19: Distribución de distintas métricas de calidad celular sobre el espacio definido por los primeros componentes principales. Se representan variables relacionadas con el número total de conteos, el número de genes detectados y los porcentajes asociados a genes ribosomales y hemoglobínicos.

En la Figura 5.19 se puede observar que ciertas métricas de calidad muestran patrones de distribución diferenciados dentro del espacio PCA. Esto indica que hay variabilidad técnica y biológica entre las distintas poblaciones celulares.

Construcción del grafo de vecinos y visualización mediante UMAP

Se construye un grafo de vecinos mediante la función `neighbors`, que calcula, para cada célula, sus vecinos más próximos en el espacio definido por la PCA. Este grafo constituye la base para etapas posteriores como la visualización y el clustering.

A continuación, se aplica UMAP (Uniform Manifold Approximation and Projection), una técnica de reducción de dimensionalidad no lineal. UMAP permite proyectar las células en un espacio bidimensional preservando, en la medida de lo posible, la estructura local del grafo de vecindad, lo que facilita la exploración visual del conjunto de datos. La proyección se colorea según distintas métricas de calidad y variables descriptivas, con el objetivo de comprobar si la estructura observada pudiera estar influida por factores técnicos.

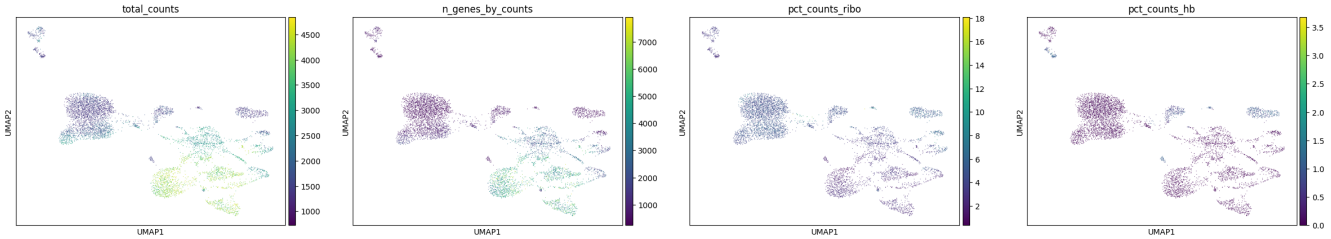


Figura 5.20: Representación UMAP del conjunto de datos coloreada según distintas métricas de calidad celular y variables descriptivas. Se muestran el número total de conteos (`total_counts`), el número de genes detectados (`n_genes_by_counts`) y los porcentajes asociados a genes ribosomales (`pct_counts_ribo`) y hemoglobínicos (`pct_counts_hb`).

5.3.3. Clustering

En este trabajo se emplea el algoritmo Leiden. A diferencia de otros enfoques, este algoritmo opera directamente sobre el grafo de vecinos previamente construido.

Gracias a este algoritmo se pueden detectar poblaciones celulares potencialmente correspondientes a distintos tipos celulares o estados funcionales, estableciendo una aproximación no supervisada.

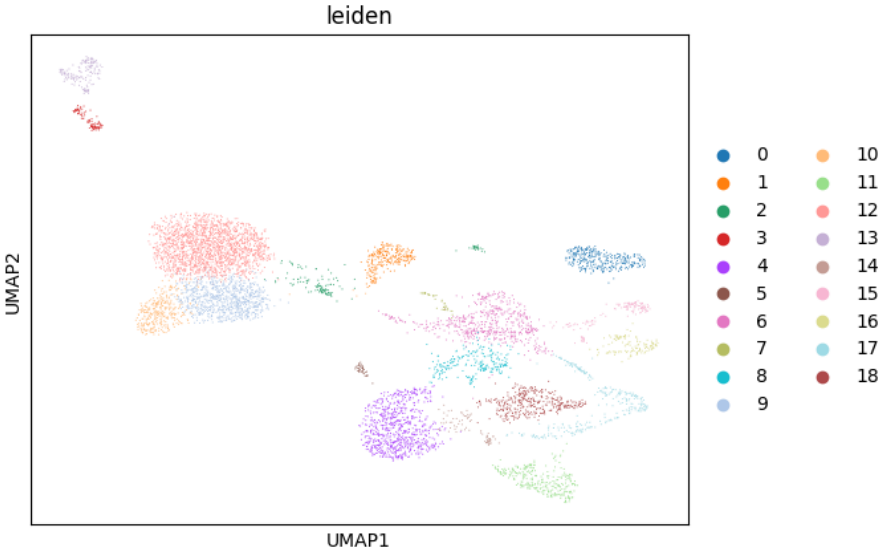


Figura 5.21: Representación UMAP coloreada según los clústeres obtenidos mediante el algoritmo Leiden. Se emplea la resolución estándar de Scanpy (`resolution = 1`), obteniéndose un total de 19 clústeres diferenciados.

Asimismo, se proyecta la anotación original sobre el espacio UMAP generado después del procesamiento, lo cual facilita evaluar la organización de los tipos celulares conocidos en el espacio.

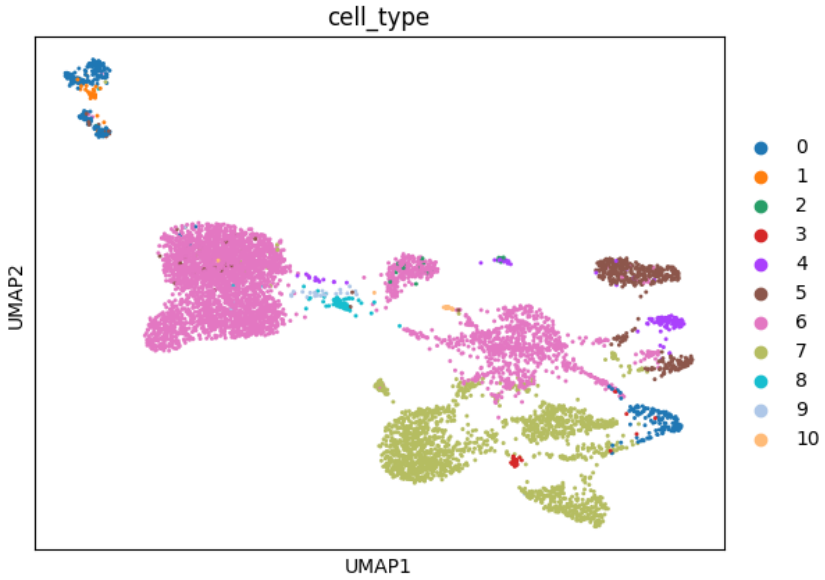


Figura 5.22: Representación UMAP coloreada según la anotación celular original del conjunto de datos.

Identificación de genes diferencialmente expresados

Una vez caracterizados los clusters, se identifican los genes más representativos de cada agrupación mediante un análisis de expresión diferencial, empleando el test de Wilcoxon implementado en Scanpy.

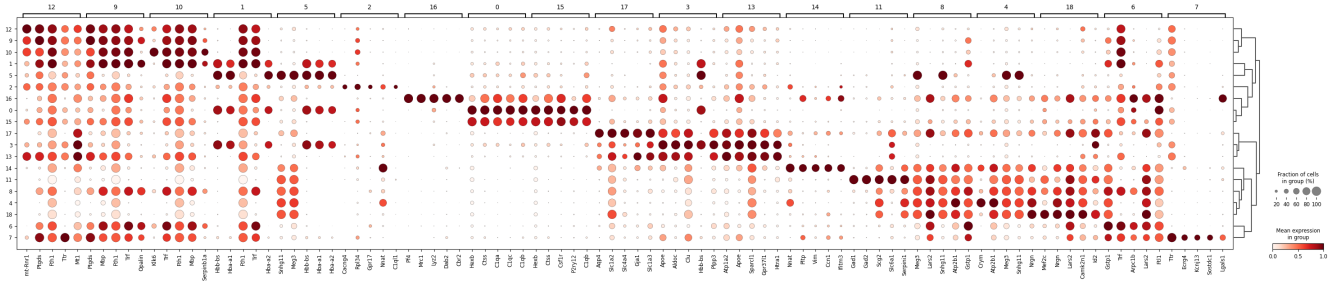


Figura 5.23: Genes diferencialmente expresados por clúster obtenido mediante el test de Wilcoxon implementado en Scanpy. Se muestran los genes más representativos de cada agrupación identificada mediante Leiden.

Adicionalmente, y para una mejor interpretación, la Figura (5.24) muestra los principales genes marcadores por cluster.

	cluster_0	cluster_1	cluster_2	cluster_3	cluster_4	cluster_5	cluster_6	cluster_7	cluster_8
0	Hexb	Hbb-bs	Cacng4	Apoe	Crym	Snhg11	Gstp1	Ttr	Meg3
1	Ctss	Hba-a1	Rpl34	Aldoc	Atp2b1	Meg3	Trf	Ecrg4	Lars2
2	C1qa	Fth1	Gpr17	Clu	Meg3	Hbb-bs	Arpc1b	Kcnj13	Snhg11
3	C1qc	Trf	Nnat	Hbb-bs	Snhg11	Hba-a1	Lars2	Sostdc1	Atp2b1
4	C1qb	Hba-a2	C1ql1	Plpp3	Nrgn	Hba-a2	Ftl1	Lgals1	Gstp1
5	Hbb-bs	Mbp	H2-D1	Sparcl1	Serpini1	Hbb-bt	Rps27rt	Fxyd1	Nrgn
6	Sparc	Il33	Marcks	Gpr37l1	Scg2	Snhg14	Opalin	Prlr	Mef2c
7	Ctsd	Opalin	B2m	Atp1a2	Cnr1	Cit	Chn2	Igfbp2	Arpc1b
8	P2ry12	Ptgds	Scrg1	Mt1	Ramp1	Coro6	Ctsl	Ctsl	Ftl1
9	B2m	Hbb-bt	Bcan	Htra1	Nnat	C1qb	Plxnb3	Ftl1	Opalin

Figura 5.24: Resumen de los principales genes diferencialmente expresados asociados a cada clúster identificado mediante Leiden.

Interpretación biológica de los clusters

La interpretación biológica de los clústeres identificados permite relacionar los grupos obetenidos mediante métodos no supervisados con posibles tipos de células o estados funciones específicos.

Sin embargo, dado el objetivo y alcance de presente trabajo, no se procede a la investigaión de dicha interpretación. En consecuencia se plantea como una posible amplicación del estudio.

5.3.4. Entrenamiento de modelos

Los modelos considerados para la evaluación han sido **SVM, ACTINN, SingleCellNet y Celltypist**, todos ellos entrenados y evaluados sobre el mismo conjunto de datos garantizando la comparabilidad de los resultados.

Tabla 5.5: Resumen del entrenamiento de modelos de DANCE utilizando el preprocesamiento propio implementado en Scanpy.

Modelo	Entrada utilizada	Configuración implementada
ACTINN	Matriz de expresión restringida a los genes altamente variables, `adata_hvg.X`	Se emplean los datos preprocesados en Scanpy sin aplicar el pipeline interno de DANCE. Las etiquetas `cell_type` se codifican en formato *one-hot*, requerido por ACTINN, y se mantiene la partición original entrenamiento/prueba del benchmark.
SVM	Matriz de expresión restringida a los genes altamente variables, `adata_hvg.X`	El clasificador SVM se entrena directamente sobre la matriz HVG obtenida tras el procesamiento en Scanpy, sin aplicar la reducción `WeightedFeaturePCA` del pipeline original de DANCE. Las etiquetas se codifican como enteros categóricos.
CellTypist	Matriz de expresión restringida a los genes altamente variables, `adata_hvg.X`	Se entrena CellTypist sobre la matriz HVG procesada en Scanpy, con `majority_voting=False`, `max_iter=200`, `n_jobs=10` y `use_SGD=True`. No se utiliza PCA como entrada.
SingleCellNet	Matriz de expresión restringida a genes altamente variables, `adata_hvg.X`	Se mantiene la configuración `num_trees=1000`, `stratify=True` y `num_rand=100`.

5.3.5. Resultados

En esta sección se presentan los resultados obtenidos tras la evaluación de los distintos modelos de anotación celular.

En primer lugar, la Tabla 5.6 incluye las principales métricas de evaluación para cada modelo, incluyendo accuracy, balanced accuracy, F1-score macro y ARI.

Tabla 5.6: Resultados obtenidos por los modelos de anotación celular utilizando el flujo de procesamiento implementado en Scanpy.

Modelo	ACC	BACC	$F1_{macro}$	ARI
SVM	0.7829	0.3904	0.3756	0.5129
ACTINN	0.8063	0.3915	0.3647	0.6090
CellTypist	0.3525	0.3195	0.2842	0.2254
SingleCellNet	0.3532	0.2738	0.2505	0.0833

Tal y como se observa en la Tabla 5.6, el modelo ACTINN alcanza la mayor accuracy, seguido de SVM.

Visualización de los resultados

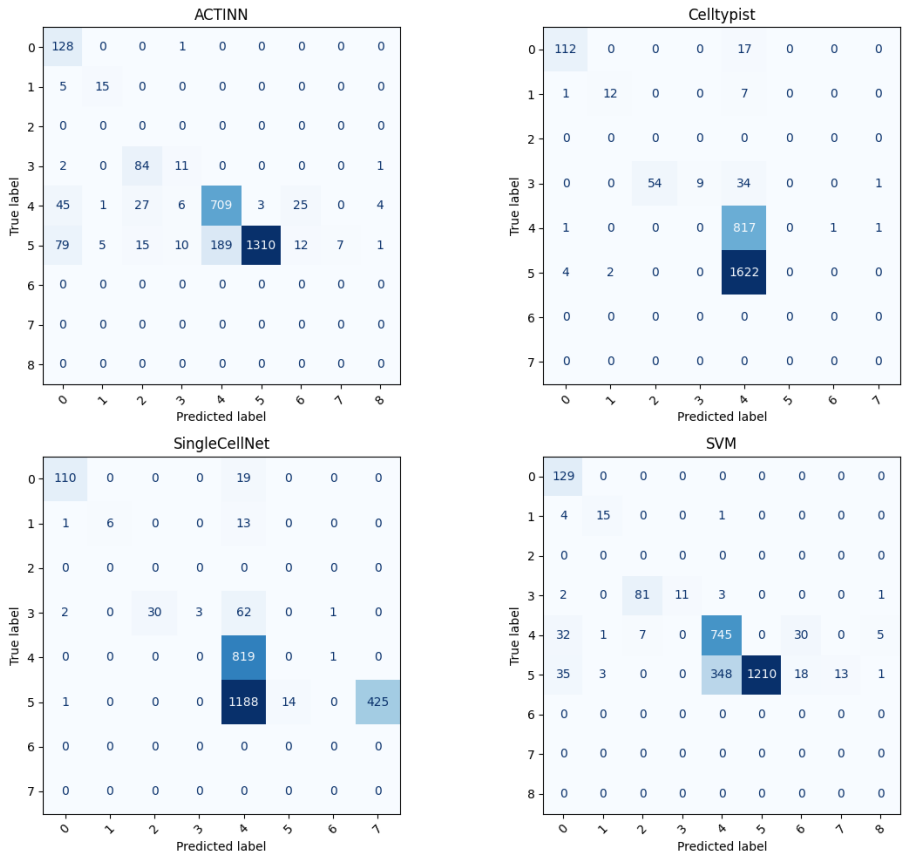


Figura 5.25: Matrices de confusión de los modelos evaluados.

5.4. Discusión

Los experimentos realizados permiten concluir que DANCE constituye una herramienta especialmente útil para la reproducción de benchmarks de anotación celular, ya que integra datasets, modelos y pipelines de procesamiento dentro de un mismo framework experimental.

Asimismo, la naturaleza modular de DANCE ha permitido desacoplar los modelos de sus pipelines originales de procesamiento y reutilizarlos posteriormente sobre un flujo homogéneo implementado mediante Scanpy.

Uno de los resultados más relevantes observados en este trabajo es la elevada influencia del pipeline de procesamiento sobre el rendimiento de los modelos de anotación celular.

Tabla 5.7: Comparación de la métrica Accuracy entre los experimentos realizados con el flujo de trabajo de DANCE y el procesamiento de datos con Scanpy.

Modelo	Accuracy DANCE	Accuracy Scanpy	Diferencia
SVM	0.7065	0.7829	**+0.0764**
ACTINN	0.8757	0.8063	-0.0694
CellTypist	0.8831	0.3525	-0.5306
SingleCellNet	0.8601	0.3262	-0.5339

La comparación entre ambos enfoques experimentales indica diferencias relevantes en la forma en la que se construye la representación de entrada utilizada por cada modelo.

En la primera parte del experimento, se aplica inicialmente un procesamiento común mediante DANCE, basado en normalización por profundidad de secuenciación (`normalize_total`), transformación logarítmica (`log1p`) y filtrado de genes mediante percentiles de expresión (`FilterGenesPercentile`). Posteriormente, cada modelo incorpora además su propia estrategia específica de preparación de datos. Por el contrario, en la segunda parte del experimento, los datos se cargan inicialmente sin transformaciones y el procesamiento se desarrolla de forma explícita mediante Scanpy.

En el caso de **SVM**, el rendimiento mejora al utilizar el procesamiento basado en Scanpy. Mientras que en DANCE el modelo emplea una representación reducida mediante PCA de 400 componentes, en la segunda aproximación se entrena sobre la matriz de 2.000 genes altamente variables obtenida tras el control de calidad y filtrado, lo que favorece el comportamiento del clasificador.

Por su parte, **ACTINN** mantiene un rendimiento elevado en ambos escenarios. En DANCE, el modelo utiliza su propio flujo específico con filtrado interno de genes, mientras que en la aproximación basada en Scanpy recibe directamente la matriz de

genes altamente variables (`adata_hvg.X`). Aunque esta representación difiere parcialmente de la originalmente diseñada para el método, la red neuronal conserva una elevada capacidad de adaptación frente a cambios en el espacio de entrada.

En **CellTypist** se observa una disminución del rendimiento respecto a la configuración original proporcionada por DANCE. Esto podría deberse a que el modelo fue diseñado para trabajar sobre matrices normalizadas mediante *library-size normalization*, escaladas típicamente a 10.000 cuentas por célula y posteriormente transformadas mediante *log1p*, además de emplear habitualmente modelos preentrenados sobre referencias celulares extensas. En este trabajo, sin embargo, CellTypist se entrena directamente sobre la matriz de genes altamente variables generada mediante Scanpy, lo que podría modificar parcialmente la representación transcriptómica esperada por el clasificador.

Finalmente, **SingleCellNet** utiliza en ambos experimentos información basada en genes reales y no sobre componentes principales. No obstante, el modelo depende de la construcción de pares génicos discriminativos (`num_top_genes=10`, `num_top_gene_pairs=25`) y de relaciones relativas de expresión entre genes. Aunque en la aproximación basada en Scanpy se emplea igualmente la matriz de genes altamente variables (`adata_hvg.X`), la reducción previa del espacio transcriptómico y las diferencias derivadas del procesamiento modifican las relaciones génicas utilizadas por el clasificador.

6. Segundo experimento

6.1. Introducción

El glioblastoma (GBM), en su forma *isocitrate dehydrogenase* (IDH), constituye una de las neoplasias malignas más agresivas del sistema nervioso central [106], caracterizada por su elevada agresividad y resistencia y una elevada resistencia a las terapias actuales [106]. Uno de los principales factores que subyacen a este comportamiento clínico es la extensa heterogeneidad intratumoral y una desregulación generalizada del empalme de ARN [107], resultado de la interacción entre alteraciones genéticas, mecanismos epigenéticos y señales del microambiente [108].

Tradicionalmente, la heterogeneidad del glioblastoma se ha abordado mediante estudios de expresión génica a nivel de tejido completo, lo que ha permitido identificar distintos subtipos transcripcionales, como proneural, clásico y mesenquimal [109, 110]. Sin embargo, trabajos posteriores han demostrado que estos subtipos no constituyen entidades discretas, sino que pueden coexistir dentro de un mismo tumor, variar espacialmente entre distintas regiones y evolucionar a lo largo del tiempo o en respuesta al tratamiento [111, 112, 110]. Esta evidencia pone de manifiesto la necesidad de analizar la heterogeneidad tumoral a resolución celular.

La secuenciación de ARN de célula única (scRNA-seq) es una herramienta fundamental para el estudio de la arquitectura celular de los tumores, permitiendo analizar la expresión génica célula a célula, proporcionando una resolución adecuada para estudiar la complejidad tumoral y caracterizando los estados transcripcionales de células individuales tanto en condiciones fisiológicas como patológicas [113, 114].

No obstante, la aplicación de estas técnicas al glioblastoma ha resultado especialmente compleja debido a la elevada heterogeneidad y plasticidad de sus células tumorales [115, 111]. En este sentido, el trabajo de Neftel et al. (2019) propone un modelo integrador en el que las células malignas del glioblastoma no se agrupan en subtipos discretos, sino que se distribuyen en un conjunto limitado de **cuatro estados celulares principales**: estados similares a progenitores neuronales (NPC-like), progenitores oligodendrogliales (OPC-like), astrocíticos (AC-like) y mesenquimales (MES-like) [108]. Dichos estados presentan un alto grado de plasticidad, permitiendo transiciones entre ellos y contribuyendo a la complejidad funcional del tumor. Asimismo, no representan subtipos celulares completamente discretos, sino programas dinámicos influenciados por factores genéticos, epigenéticos y por el microambiente tumoral [108].

Adicionalmente, observaron que la distribución relativa de estos estados celulares dentro de cada tumor se encuentra modulada por alteraciones genéticas específicas, como amplificaciones o mutaciones en genes como EGFR, PDGFRA, CDK4 o NF1, lo que establece una conexión directa entre la genética tumoral y los estados celulares [108].

En este sentido, el presente experimento tiene como finalidad analizar la aplicabilidad de diferentes estrategias de aprendizaje automático sobre datos de transcriptómica de célula única correspondientes a glioblastoma, evaluando su capacidad para identificar y reproducir la estructura celular presente en el dataset SCP393. A diferencia del estudio original de Neftel et al. (2019), que combina múltiples fuentes de datos y validaciones experimentales, en este trabajo se pretende evaluar distintos modelos basados en técnicas de Machine Learning y Deep Learning, así como en explorar, controlar y analizar el conjunto de datos y las distintas etapas de procesamiento mediante herramientas de scverse, en particular la librería Scanpy [103].

Dada la heterogeneidad biológica característica de este tipo tumoral y las diferencias existentes entre las tecnologías de secuenciación empleadas, el estudio se ha planteado mediante dos enfoques metodológicos diferenciados.

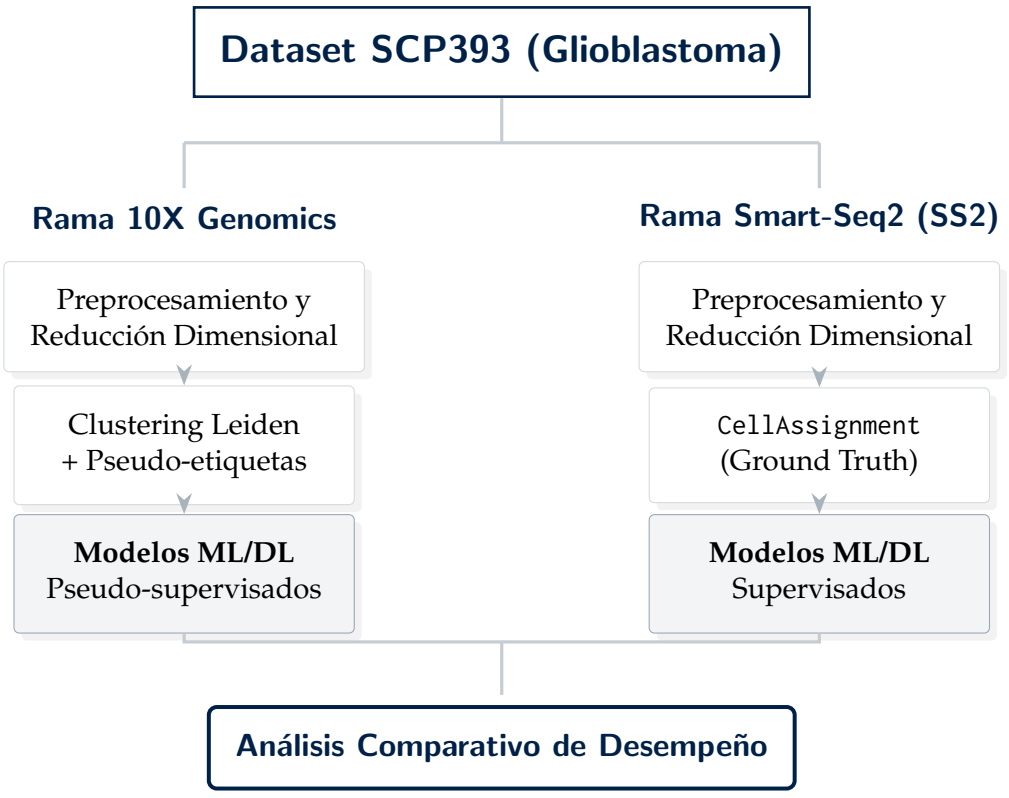


Figura 6.1: Diseño experimental asociado al dataset SCP393. Se distinguen dos ramas: clasificación pseudo-supervisada sobre el conjunto 10X y análisis supervisado sobre el conjunto Smart-seq2.

Por un lado, el subconjunto SmartSeq2 permite desarrollar un escenario de aprendizaje supervisado, utilizando las anotaciones celulares disponibles en la variable `CellAssignment` como referencia biológica. Este enfoque posibilita evaluar el rendimiento de distintos modelos de clasificación celular bajo condiciones supervisadas.

Por otro lado, el subconjunto 10X Genomics presenta una situación distinta debido a la ausencia de anotaciones celulares. En primer lugar, se han empleado algoritmos de

clustering sobre los datos procesados para identificar agrupaciones celulares similares. Posteriormente, dichas agrupaciones se utilizan como pseudoetiquetas con el objetivo construir un desarrollo experimental supervisado orientado a evaluar la capacidad de los modelos para aprender y reproducir la organización celular deducida a partir de los datos.

6.2. Datos de gliobastoma

Los datos utilizados proceden del estudio publicado por Neftel et al. [108], titulado *"An Integrative Model of Cellular States, Plasticity, and Genetics for Glioblastoma"*. Como se ha mencionado previamente, en dicho trabajo los autores proponen un modelo integrador para caracterizar la diversidad celular del glioblastoma mediante el análisis combinado de datos transcriptómicos, genéticos y funcionales obtenidos a partir de múltiples muestras tumorales.

Asimismo, los datos se obtuvieron a través del repositorio público Single Cell Portal del Broad Institute, concretamente del estudio SCP393. Este estudio incluye distintos subconjuntos experimentales generados mediante dos tecnologías de secuenciación diferentes:

- Datos generados mediante tecnología 10X Genomics.
- Datos obtenidos mediante SmartSeq2 (SS2).

Ambos subconjuntos presentan características experimentales y estructuras de anotación distintas, lo que da lugar a dos escenarios metodológicos diferenciados dentro del presente trabajo.

Por un lado, el subconjunto 10X proporciona una matriz de expresión de alta dimensionalidad sin anotaciones celulares directamente alineables. Por otro lado, el subconjunto SmartSeq2 incorpora anotaciones biológicas asociadas a cada célula.

Tabla 6.1: Comparación del desarrollo experimental entre los subconjuntos 10X y SmartSeq2 empleados en el Segundo Experimento.

Característica	Subconjunto 10X	Subconjunto SmartSeq2 (SS2)
Tecnología de secuenciación	10X Genomics	SmartSeq2
Formato principal de los datos	Matriz dispersa de conteos (`.mtx`)	Matriz de expresión procesada (`logTPM`)
Disponibilidad de anotaciones celulares	No disponibles de forma alineable	Disponibles mediante `CellAssignment`
Tipo de enfoque	Exploratorio y pseudo-supervisado	Supervisado
Ground truth utilizado	Clusters inferidos mediante Leiden	Anotaciones biológicas reales
Tipo de aprendizaje	No supervisado + pseudo-supervisado	Supervisado
Objetivo experimental	Evaluar modelos la estructura transcriptómica e inferir agrupaciones celulares	Evaluar modelos de clasificación celular utilizando etiquetas biológicas

6.3. Análisis exploratorio y clasificación pseudo-supervisada sobre el subconjunto 10X de glioblastoma

6.3.1. Planteamiento

En esta primera parte del experimento de glioblastoma se ha trabajado con el subconjunto generado mediante tecnología 10X Genomics del estudio SCP393, correspondiente a datos de secuenciación de ARN de célula única en glioblastoma. A diferencia del subconjunto SmartSeq2 analizado posteriormente, este conjunto de datos no dispone de anotaciones celulares directamente alineables con la matriz de expresión utilizada.

Como consecuencia, el subconjunto 10X no puede utilizarse directamente para plantear un problema supervisado de anotación celular con una referencia biológica real. Por ello, primero se lleva a cabo un análisis exploratorio no supervisado mediante un flujo completo de procesamiento, y en segundo lugar, los clusters obtenidos mediante el algoritmo de Leiden se utilizan como pseudo-etiquetas para construir un problema de clasificación supervisada.

El objetivo es evaluar si distintos modelos de Machine Learning y Deep Learning son capaces de reproducir la estructura transcriptómica de forma no supervisada. Por tanto, el experimento resulta útil en contextos donde no se dispone de etiquetas celulares externas.

6.3.2. Carga e inspección de los datos

En este estudio deben reconstruirse manualmente a partir de los archivos originales proporcionados por el portal del Broad Institute. Los archivos utilizados para la reconstrucción del objeto de análisis son los siguientes:

- `IDHwtGBM.processed.10X.counts.mtx`: matriz de expresión génica en formato disperso, generada mediante tecnología 10X Genomics.
- `genes1.tsv`: archivo con los identificadores génicos correspondientes a las variables de la matriz.
- `cells1.proc.tsv`: archivo con los identificadores celulares o *barcodes*.

Construcción del objeto Anndata

El objeto `AnnData` constituye la estructura central para el análisis de datos de scRNA-seq, permitiendo representar de forma unificada la matriz de expresión junto con la información asociada a sus dimensiones.

Para su construcción se emplean los archivos correspondientes a la matriz de expresión y a los identificadores de genes y células. La matriz, almacenada en formato Matrix Market, se carga mediante la función `read_mtx` de Scanpy. Debido a que este formato organiza los datos con los genes en filas y las células en columnas, se aplica una transposición para obtener la orientación estándar utilizada en `AnnData`, donde las observaciones corresponden a células y las variables a genes.

A continuación, los identificadores génicos y celulares se asignan a los atributos `var_names` y `obs_names`, respectivamente, a partir de los archivos auxiliares asociados a la matriz de expresión. Como resultado, se obtiene un objeto `AnnData` con una dimensionalidad de 12 074 células y 32 738 genes.

De este modo, el dataset queda representado de forma estructurada:

- **adata.X** contiene la matriz de expresión génica en formato disperso, con dimensiones $12\,074 \times 32\,738$ (células $\times$ genes).
- **adata.obs_names** almacena los identificadores de las 12 074 células (por ejemplo, `102_1`, `102_2`, ...).
- **adata.var_names** almacena los identificadores de los 32 738 genes (por ejemplo, `ENSG00000243485`, ...).

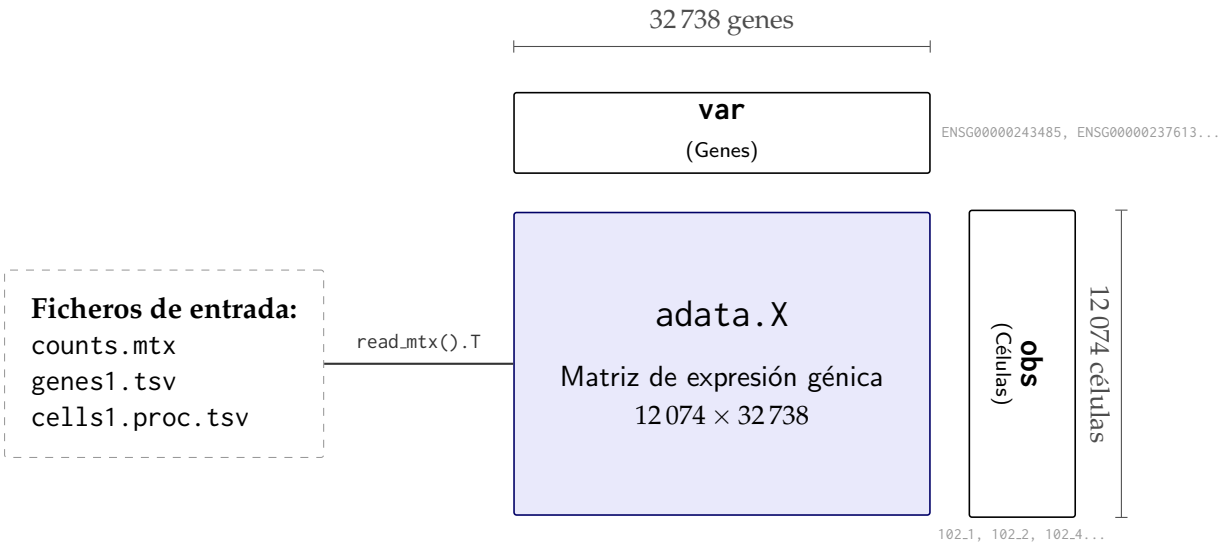


Figura 6.2: Esquema del objeto `AnnData` sobre el subconjunto 10X. La matriz central `X` contiene los datos de expresión, mientras que las estructuras blancas laterales (`obs` y `var`) contienen los metadatos de células y genes respectivamente.

Métricas de calidad celular

A partir del objeto `AnnData` inicial, se calculan métricas de control de calidad mediante la función `calculate_qc_metrics()`. Entre las métricas obtenidas se encuentran:

- El número de genes detectados por célula (`n_genes_by_counts`).
- El número total de conteos por célula (`total_counts`).

En otros contextos, es habitual considerar adicionalmente la proporción de genes mitocondriales, ribosomales o de hemoglobina. No obstante, en el presente conjunto de datos los genes se encuentran identificados mediante códigos Ensembl, sin anotaciones adicionales que permitan identificar dichas categorías de forma directa. Por este motivo, el análisis se centra en las métricas globales derivadas de la matriz de expresión.

A continuación, se representan las métricas de calidad. La Figura 6.3 muestra la distribución del número de genes detectados por célula y el número total de conteos (counts).

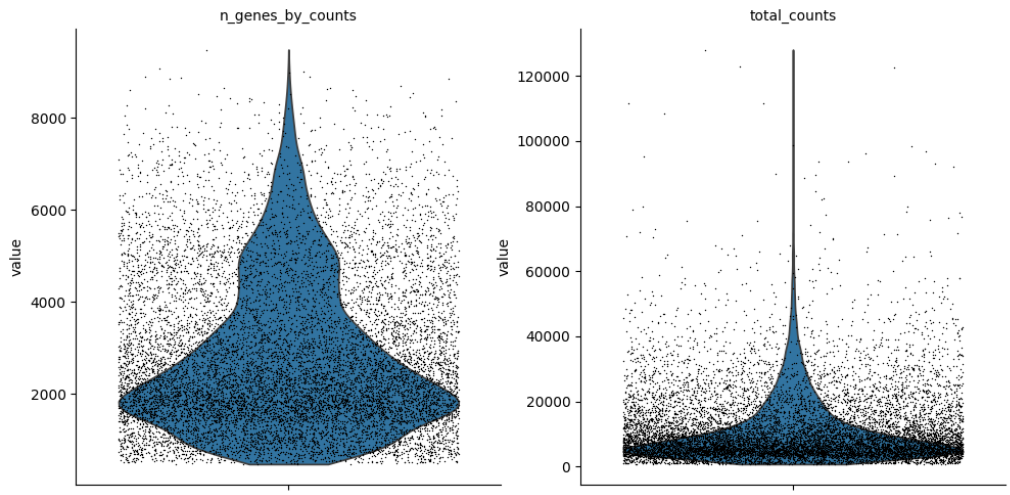


Figura 6.3: Distribución del número de genes detectados por célula y el número total de conteos.

La Figura 6.4 muestra la relación entre el número total de conteos y el número de genes detectados por célula.

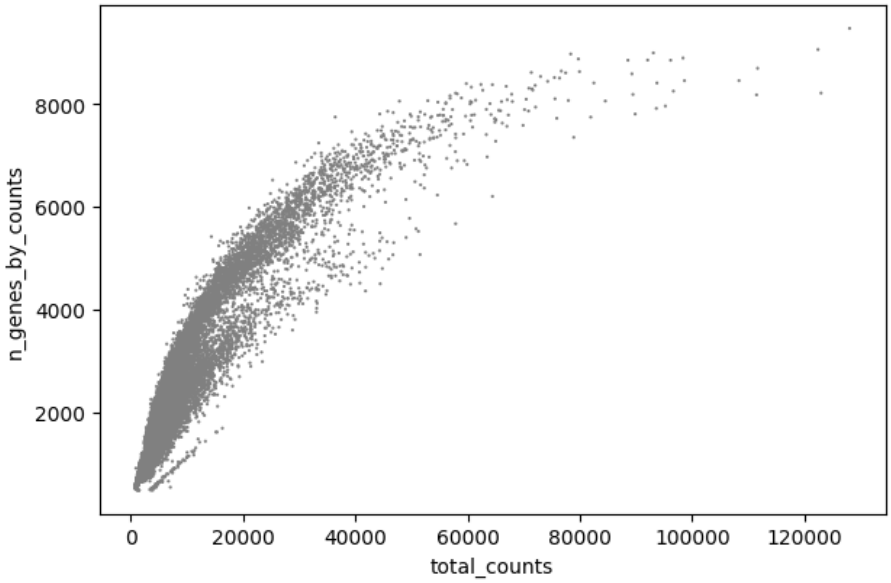


Figura 6.4: Relación entre el número total de conteos y número de genes detectados.

Por último, se evalúa el grado de dispersión de la matriz de expresión, obteniéndose un valor (sparsity) aproximado del 91,4 %. Este comportamiento es característico de los datos de scRNA-seq, en los que una gran proporción de entradas corresponde a valores nulos debido tanto a la baja expresión de muchos genes como a limitaciones técnicas en la detección.

6.3.3. Procesamiento

El procesamiento del subconjunto 10X no se ha planteado únicamente con el objetivo de obtener una representación de la estructura transcriptómica del dataset, reduciendo el ruido técnico y preservando posibles subpoblaciones celulares relevantes, sino también con la finalidad de explorar y comprender en detalle las distintas etapas del procesamiento de datos de scRNA-seq. Todo ello permite mantener un mayor control sobre los datos, analizar el impacto de cada transformación aplicada y profundizar en el funcionamiento de los flujos de procesamiento empleados, especialmente en un dataset tan heterogéneo como el glioblastoma.

A partir de la matriz de expresión inicial, se ha implementado diversas transformaciones basadas en la librería Scanpy, incluyendo etapas de control de calidad, filtrado celular y génico, detección de dobletes, selección de genes altamente variables y reducción de dimensionalidad mediante PCA, UMAP y t-SNE.

Además, se ha llevado a cabo una fase de aprendizaje no supervisado basada en clustering mediante el algoritmo de Leiden. De este modo, las agrupaciones obtenidas mediante clustering actúan como referencia para el entrenamiento y evaluación de distintos modelos.

Control de calidad

En el contexto de datos generados mediante tecnologías basadas en gotas, como 10X Genomics, esta fase adquiere especial relevancia debido a la posible presencia de ARN ambiental, dobles capturas celulares y variabilidad en la eficiencia de secuenciación.

En este tipo de experimentos basados en gotas, parte del ARN libre presente en la disolución puede incorporarse a las gotas y ser secuenciado junto con el material genético de las células capturadas. Este fenómeno, conocido como ARN ambiental (ambient RNA), introduce una señal de fondo que no refleja la expresión génica real de cada célula.

Existen herramientas específicas, como SoupX o DecontX, destinadas a estimar y corregir esta contaminación. Sin embargo, su aplicación requiere disponer de la matriz cruda de gotas generada por pipelines como Cell Range. Dado que en el presente trabajo únicamente se dispone de una matriz de expresión ya procesada en formato `.mtx`, no es posible aplicar dichas correcciones de forma rigurosa. En consecuencia, el análisis continúa sobre la matriz disponible, dejando constancia de esta limitación metodológica.

Por tanto, en primer lugar se aplica un filtrado inicial con el objetivo de eliminar observaciones con poca información relevante. En particular, se eliminan: (i) las células con menos de 100 genes detectados y (ii) los genes detectados en menos de 3 células.

Adicionalmente, se introduce un criterio de filtrado inspirado en el trabajo de Neftel et al. (2019) [108], quienes emplean umbrales relativos sobre el número de

genes detectados por célula para excluir observaciones con valores extremos dentro de cada tumor.

Debido a que en el presente dataset no se dispone de metadatos compatibles que permitan dividir las células por muestra de origen, este criterio se adapta utilizando la media global del conjunto de datos. En particular, se conservan aquellas células cuyo número de genes detectados se encuentra dentro del intervalo definido por la mitad y el doble de la media global.

Este procedimiento elimina las observaciones con una complejidad transcriptómica anómalamente baja o elevada.

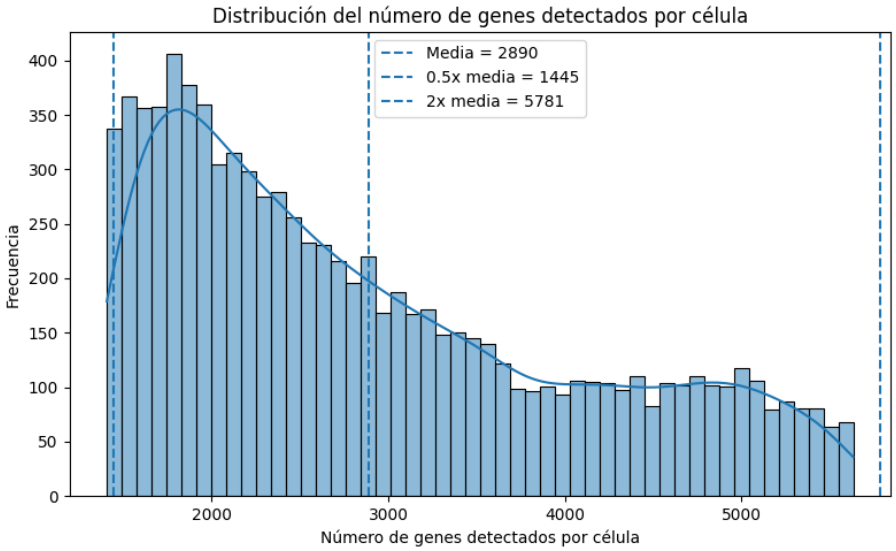


Figura 6.5: Distribución del número de genes detectados por célula.

La Figura 6.5 muestra la distribución del número de genes detectados por célula, junto con los umbrales utilizados para el filtrado basado en complejidad transcriptómica. Se observa una distribución asimétrica con una cola hacia valores elevados. Las células con un número reducido de genes detectados se asocian típicamente a baja calidad o a capturas incompletas, mientras que aquellas con valores anómalamente elevados pueden corresponder a dobles capturas celulares.

Finalmente, se aplica un filtro adicional sobre las variables con el fin de eliminar genes escasamente representados. En particular, se conservan únicamente aquellos genes detectados en al menos 20 células.

Por otra parte, es posible que dos células queden encapsuladas bajo un mismo barcode, dando lugar a perfiles de expresión híbridos conocidos como dobles (doublets). Para ello, se emplea el método Scrublet, que estima la probabilidad de que una observación corresponda a un doblete mediante la comparación con perfiles simulados. Como resultado, se obtienen las variables `doublet_score` y `predicted_doublet` para cada observación.

Normalización de los datos

Tras las etapas de control de calidad y filtrado, se procede a la normalización de la matriz de expresión génica.

En este análisis se emplea una normalización mediante la función `normalize_total()` de Scanpy, escalando cada observación a un total de 10^4 conteos. Posteriormente, se aplica una transformación logarítmica mediante `log1p`, con el objetivo de reducir la influencia de valores extremos y estabilizar parcialmente la varianza de los datos. La transformación aplicada puede expresarse de forma general como:

$$x'_{ij} = \log(1 + \tilde{x}_{ij})$$

donde $\tilde{x}_{ij}$ representa el valor normalizado del gen j en la célula i.

Selección de genes altamente variables

Tras la normalización, el conjunto de datos continúa presentando una elevada dimensionalidad, con varios miles de genes por observación, muchos de los cuales muestran niveles de expresión bajos o escasa variabilidad entre células.

Por ello, se introduce una etapa de selección de características, la cual se lleva a cabo mediante la identificación de genes altamente variables (Highly Variable Genes, HVGs), utilizando la función `pp.highly_variable_genes()`. Este método identifica aquellos genes cuya variabilidad excede la esperada en función de su nivel medio de expresión, priorizando genes potencialmente informativos.

En este trabajo se seleccionan los 2000 genes más variables, un valor estándar ampliamente adoptado en análisis de datos de transcriptómica de célula única.

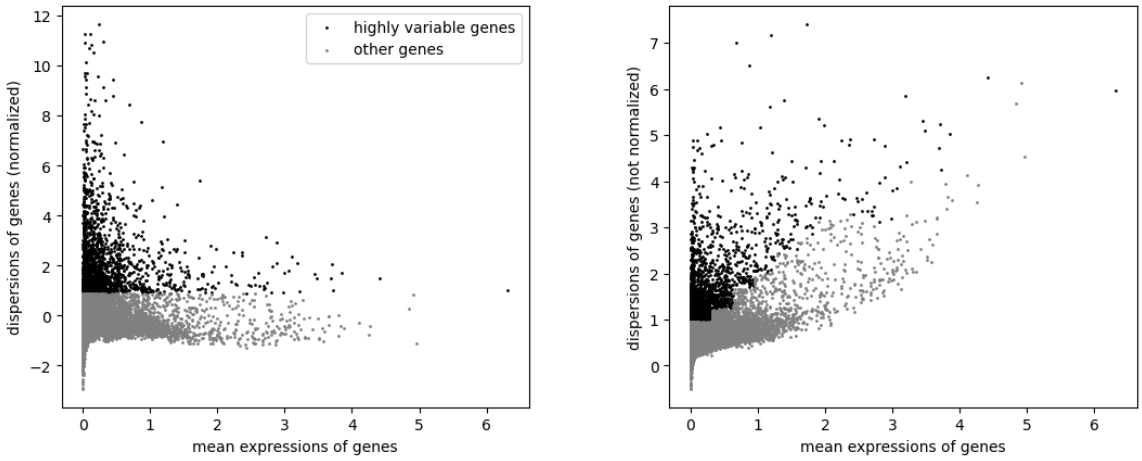


Figura 6.6: Representación de la selección de genes altamente variables. A la izquierda se muestra la dispersión normalizada frente a la expresión media de los genes, mientras que a la derecha se representa la dispersión no normalizada.

Como resultado, se obtiene una matriz de expresión reducida. En particular, el conjunto de datos resultante presenta una dimensión de $(8978, 2000)$, correspondiente a 8978 células y 2000 genes.

Reducción de dimensionalidad

En esta fase se pretende proyectar los datos en un espacio de menor dimensión que mantenga la estructura biológica, facilitando la identificación de poblaciones celulares, la visualización de los datos y la aplicación de técnicas posteriores como clustering o anotación celular.

Como primer paso, se aplica el Análisis de Componentes Principales (PCA), una técnica lineal que transforma los datos originales en un nuevo espacio de variables no correlacionadas, denominadas componentes principales, ordenadas en función de la varianza que explican. En este trabajo, el PCA se aplica sobre el subconjunto de genes altamente variables.

Además, se analiza la proporción de varianza explicada por cada componente mediante la representación gráfica correspondiente.

En la práctica, se suelen considerar entre 10 y 50 componentes principales, en función de la complejidad del dataset y del punto en el cual la varianza adicional explicada por nuevas componentes se vuelve marginal. En este trabajo, se seleccionan 40 componentes principales, que se emplearán para la construcción del grafo de vecinos.

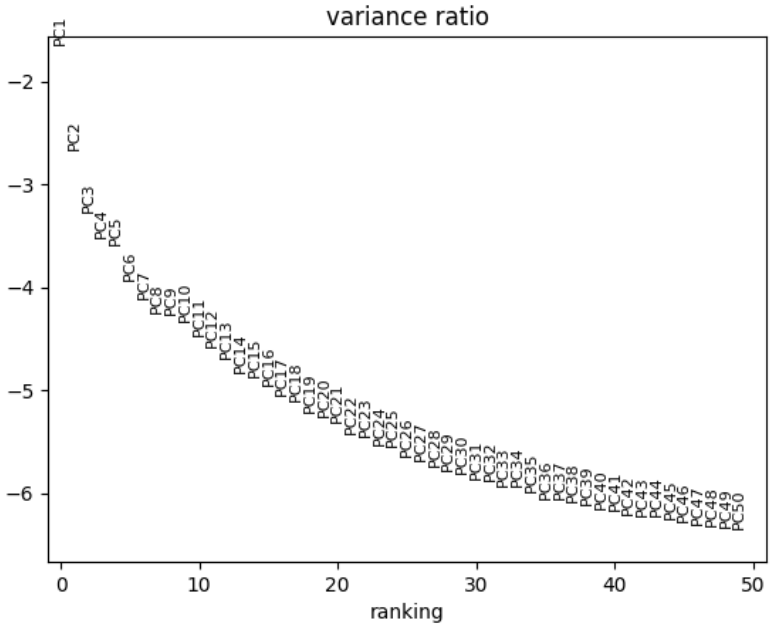


Figura 6.7: Proporción de varianza explicada por los primeros componentes principales obtenidos mediante PCA.

A partir de la representación de las células en el espacio de componentes principales, se construye un grafo de vecinos que modela la similitud entre

observaciones. Con el objetivo de visualizar la estructura del dataset, se emplea el método UMAP (Uniform Manifold Approximation and Projection), el cual permite representar los datos en un espacio bidimensional.

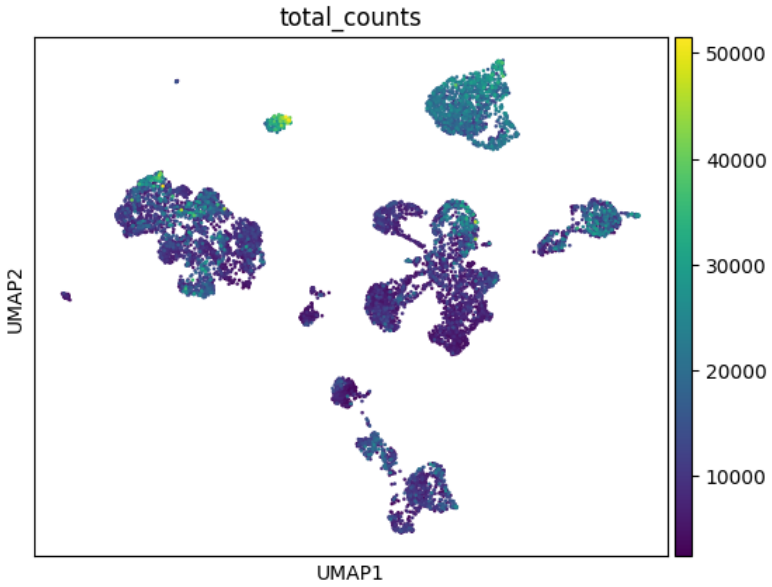


Figura 6.8: Representación UMAP del subconjunto 10X tras la construcción del grafo de vecinos sobre el espacio PCA.

Como alternativa a UMAP, se aplica también el método t-SNE (t-distributed Stochastic Neighbor Embedding), otra técnica de reducción de dimensionalidad no lineal ampliamente utilizada en el análisis de datos de transcriptómica de célula única.

Aunque t-SNE suele proporcionar representaciones similares en términos de separación de grupos, presenta un mayor coste computacional y tiende a preservar principalmente la estructura local.

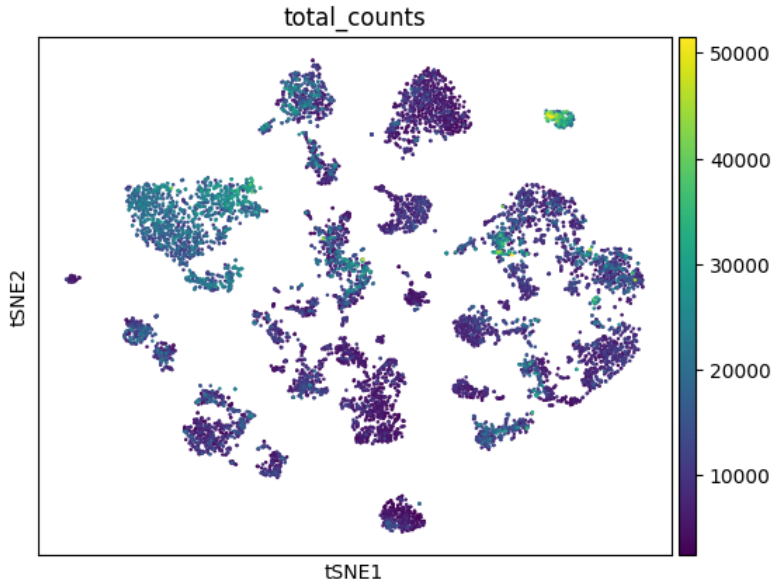


Figura 6.9: Representación mediante t-SNE del subconjunto 10X.

Finalmente, se visualizan diversas métricas de calidad sobre la proyección UMAP. En particular, se analiza el número total de conteos por célula, el número de genes detectados y la probabilidad de doblete.

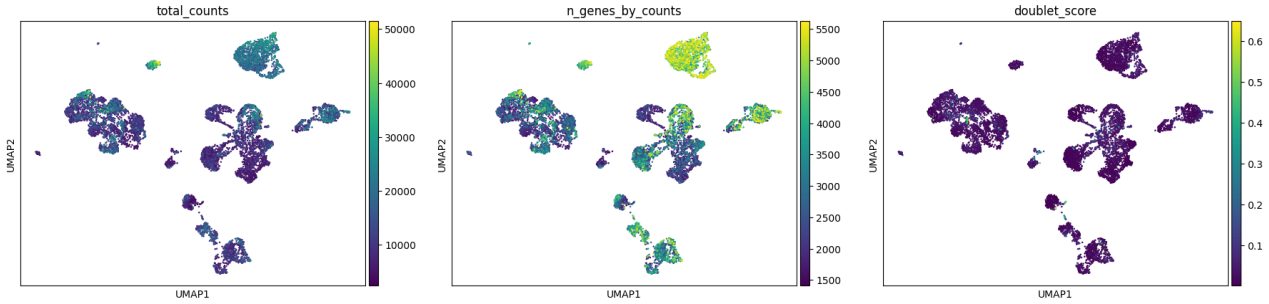


Figura 6.10: Proyección UMAP coloreada según distintas métricas de calidad celular: número total de conteos (`total_counts`), número de genes detectados (`n_genes_by_counts`) y probabilidad estimada de doblete (`doublet_score`).

6.3.4. Clustering

Una vez realizada la etapa de procesamiento, se ha aplicado el algoritmo Leiden para identificar agrupaciones de células con perfiles transcriptómicos similares.

El clustering se define como una etapa de aprendizaje no supervisado, cuyo objetivo es agrupar células con perfiles de expresión génica similares, permitiendo deducir posibles identidades celulares, estados biológicos o subpoblaciones presentes en el glioblastoma.

Se han explorado distintas resoluciones del algoritmo Leiden, incluyendo valores de 0,25, 0,5 y 1,0. El parámetro de resolución controla la granularidad del clustering:

valores bajos producen un número menor de agrupaciones más generales, mientras que valores más altos generan un mayor número de clusters y permiten detectar subestructuras más finas.

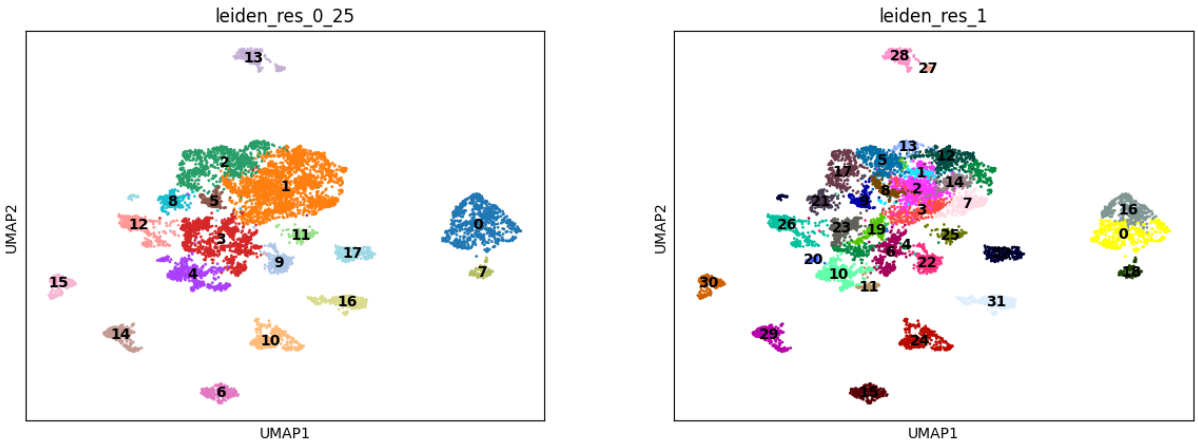


Figura 6.11: Algoritmo Leiden sobre la proyección UMAP utilizando distintas resoluciones (`resolution`=0.25 y 1.0). Se observa cómo el incremento de la resolución produce una subdivisión progresiva de las agrupaciones celulares.

Los clusters obtenidos se ha visualizado sobre la proyección UMAP.

Por otra parte, cabe mencionar que el algoritmo Leiden permite realizar análisis de sub-clustering sobre subconjuntos específicos de células, es decir, subdivide clústeres grandes o generales en subgrupos más pequeños y homogéneos. No obstante, este tipo de análisis puede generar resultados inestables, afectar el rendimiento o inlcuso subdividir grupos naturales en comunidades cada vez más pequeñas que carecen de significado estructural.

En este experimento, el análisis se centra en el clustering global del dataset, dejando el sub-clustering como posible extensión del estudio.

Finalmente, se ha decidido no realizar una anotación biológica de los clusters. Aunque se exploró inicialmente la posibilidad de identificar genes característicos por cluster, la asignación de identidades celulares requiere una interpretación biológica más profunda, incluyendo la conversión de identificadores Ensembl a símbolos génicos, contraste con marcadores conocidos y validación mediante estudios específicos. Por ello, este proceso se plantea como una línea futura de trabajo.

6.3.5. Entrenamiento de modelos

Como se ha explicado anteriormente, debido a la falta de anotaciones celulares biológicas, se ha planteado una estrategia pseudo-supervisada basada en clustering. Los clusters obtenidos mediante el algoritmo Leiden se han utilizado como pseudo-etiquetas para el entrenamiento de modelos supervisados.

Del mismo modo, las pseudo-etiquetas no representan tipos celulares reales anotados experimentalmente, sino agrupaciones transcriptómicas inferidas

automáticamente a partir de la estructura interna del conjunto de datos. Así, cada célula recibe como clase el identificador del cluster Leiden al que pertenece, por ejemplo `0`, `1`, `2`, etc.

Tabla 6.2: Ejemplo de asignación de pseudoetiquetas Leiden a células individuales.

Célula	Etiqueta Leiden
102_1	0
102_2	0
102_5	0
102_7	2
102_8	2

El objetivo de este método no consiste en predecir identidades celulares biológicas, sino en evaluar la capacidad de distintos modelos de aprendizaje automático y aprendizaje profundo para reproducir la organización transcriptómica detectada mediante clustering no supervisado.

Formalmente, el problema puede expresarse como el aprendizaje de una función:

$$f(X_i) \rightarrow y_i$$

donde X_i representa el perfil de expresión génica de la célula i, mientras que y_i corresponde al cluster Leiden asignado a dicha célula.

Datos empleados

El entrenamiento se ha realizado utilizando la matriz de expresión almacenada en el objeto `adata_hvg`. Como variable objetivo se han utilizado las etiquetas correspondientes al clustering Leiden calculado durante la fase de análisis exploratorio.

Con el objetivo de garantizar una evaluación homogénea y comparable entre modelos, se ha realizado una partición entrenamiento/test utilizando un 80 % de las células para entrenamiento y un 20 % para evaluación. Adicionalmente, las etiquetas Leiden fueron codificadas numéricamente mediante `LabelEncoder`.

Modelos evaluados

Se han evaluado cinco modelos representativos ampliamente utilizados en aprendizaje automático y anotación celular.

- **SVM**. Se ha utilizado un clasificador lineal implementado mediante `LinearSVC` de la librería `scikit-learn`. El entrenamiento se ha realizado sobre la matriz de expresión previamente procesada, incorporando una etapa de escalado mediante `MaxAbsScaler`. Además, se ha empleado ponderación automática de clases (`class_weight="balanced"`) para reducir el efecto del desbalanceo entre clústeres.
- **Random Forest**. El modelo Random Forest se ha implementado mediante la librería `scikit-learn`, utilizando un conjunto de 300 árboles de decisión y paralelización mediante múltiples núcleos (`n_jobs=-1`). Al igual que en SVM, se ha utiliado ponderación automática de clases para mejorar el comportamiento frente a pseudoetiquetas desbalanceadas.
- **ACTINN**. ACTINN se obtuvo a partir de la implementación oficial disponible en GitHub[1]. Fue necesario adaptar parcialmente el código fuente para garantizar su compatibilidad con TensorFlow 2.x. Para su ejecución, las matrices de entrenamiento y prueba se han exportado al formato HDF5 requerido por la herramienta, manteniendo la orientación genes $\times$ células especificada en la documentación oficial.
- **CellTypist**. CellTypist[2] se ha instalado mediante `pip` utilizando la implementación oficial en Python. El entrenamiento se ha realizado directamente sobre objetos `AnnData`, empleando las pseudoetiquetas Leiden como variable objetivo. Previamente, las matrices de expresión fueron normalizadas a 10 000 conteos por célula y transformadas mediante `log1p`, siguiendo las recomendaciones metodológicas de la propia librería.
- **SingleCellNet**. SingleCellNet se ha implementado mediante `PySingleCellNet` [3], versión compatible con `Scanpy` y `AnnData` de la herramienta original desarrollada en R. Durante su utilización fue necesario aplicar pequeñas modificaciones relacionadas con dependencias de visualización y adaptar las etiquetas Leiden al formato categórico requerido internamente por Scanpy.

Todos los modelos fueron evaluados utilizando las mismas métricas: accuracy, balanced accuracy, F1-macro y ARI.

6.3.6. Resultados

La Tabla 6.3 muestra los resultados obtenidos por los distintos modelos evaluados utilizando etiquetas derivadas del clustering Leiden.

[1] https://github.com/mafeiyang/ACTINN
[2] https://www.celltypist.org/
[3] https://github.com/CahanLab/PySingleCellNet

Tabla 6.3: Resultados de clasificación sobre el subconjunto 10X de glioblastoma.

Modelo	ACC	$F1_{macro}$	ARI	NMI
SVM	0.9627	0.9564	0.9270	0.9500
Random Forest	0.9543	0.9430	0.9164	0.9415
CellTypist	0.9538	0.9420	0.9127	0.9407
ACTINN	0.9499	0.9375	0.9112	0.9339
SingleCellNet	0.9337	0.8836	0.8820	0.9202

Visualización de los resultados

Se han calculado las matrices de confusión para cada clasificador con el objetivo de analizar los patrones de error del modelo, identificando el número de predicciones correctas e incorrectas para todas las clases.

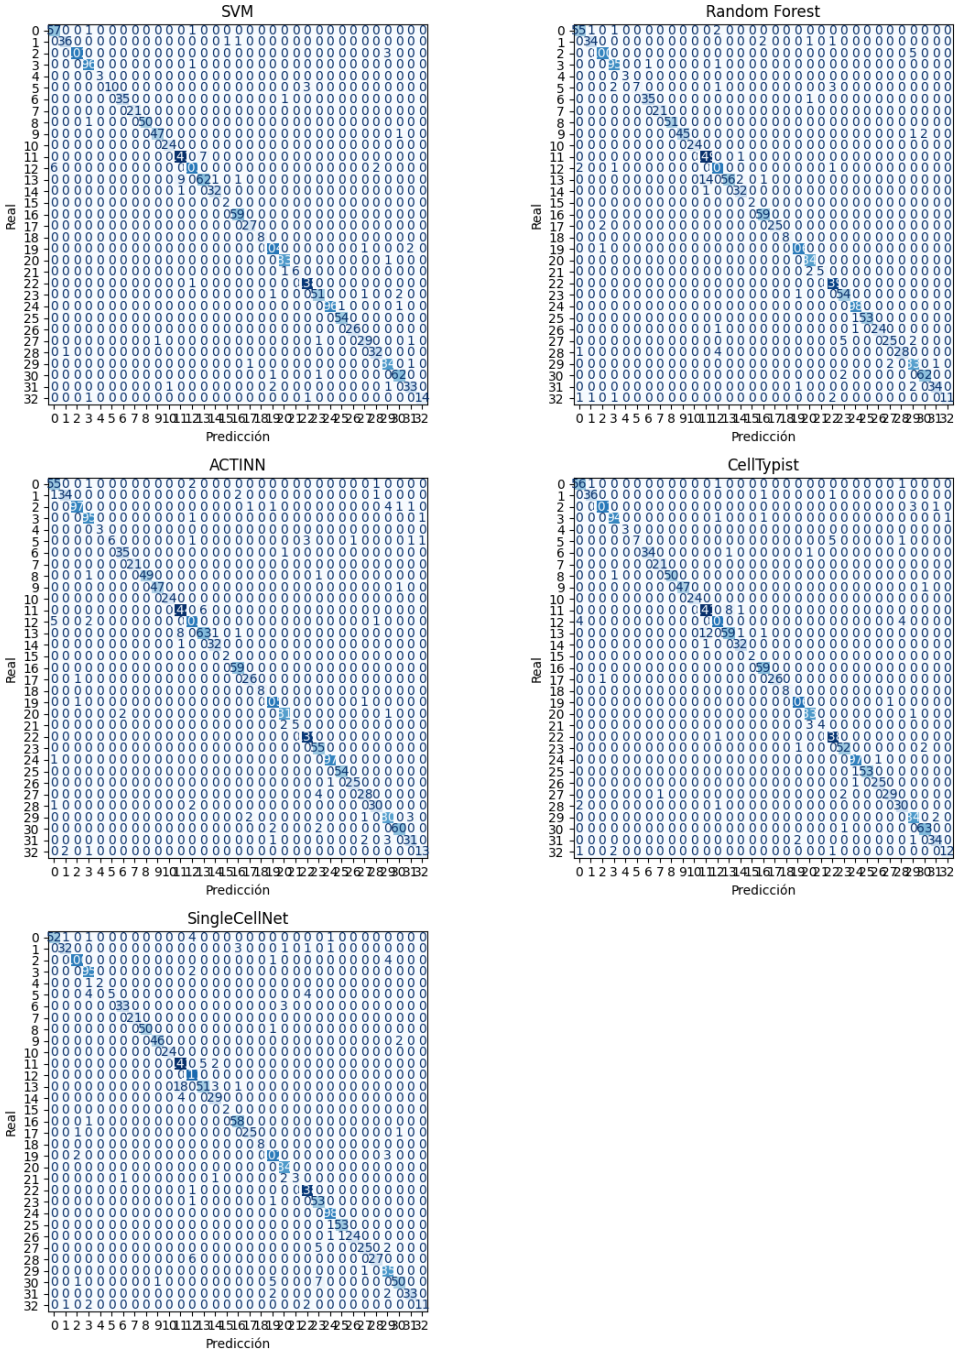


Figura 6.12: Matrices de confusión de los modelos evaluados.

6.4. Anotación supervisada sobre el subconjunto SmartSeq2 de glioblastoma

6.4.1. Planteamiento

Tras el flujo experimental realizado sobre el subconjunto 10X del dataset SCP393, esta segunda parte se centra en el estudio del subconjunto generado mediante tecnología Smart-seq2. A diferencia del caso anterior, este subconjunto dispone de metadatos compatibles con la matriz de expresión génica, permitiendo incorporar anotaciones celulares reales mediante la variable `CellAssignment`.

El objetivo principal de este experimento consiste en evaluar distintos modelos de anotación celular supervisada sobre un conjunto de datos complejo y heterogéneo como son los datos de glioblastoma. Para ello, se construye un flujo completo de procesamiento, seguido de la aplicación y evaluación de diferentes modelos de clasificación previamente evaluados en el trabajo.

6.4.2. Carga e inspección de los datos

Se procede a la carga de la matriz de expresión génica y de los metadatos celulares asociados al subconjunto Smart-seq2. Los archivos utilizados son:

- `IDHwtGBM.processed.SS2.logTPM.txt`: contiene la matriz de expresión génica.
- `IDHwt.GBM.Metadata.SS2.txt`: contiene la información fenotípica y biológica asociada a cada célula.

Construcción del objeto Anndata

La matriz de expresión se encontraba organizada inicialmente con los genes en filas y las células en columnas, por lo que fue necesario transponerla para adaptarla al formato estándar de `AnnData`, donde las observaciones corresponden a células y las variables a genes.

Matriz de expresión:
(23686, 7930)

GENE	MGH101-P1-A04	MGH101-P1-A05	MGH101-P1-A07	MGH101-P1-A09	MGH101-P1-A10
A1BG	0.0	0.000000	0.0	0.000000	0.000000
A1BG-AS1	0.0	0.000000	0.0	0.000000	0.000000
A1CF	0.0	0.000000	0.0	0.000000	0.000000
A2M	0.0	5.327184	0.0	8.698337	8.205094
A2M-AS1	0.0	0.000000	0.0	0.000000	0.000000

Figura 6.13: Fragmento de la matriz de expresión génica original del subconjunto Smart-seq2 antes de la construcción del objeto `AnnData`.

Antes de construir el objeto final, se ha realizado una comprobación explícita de la correspondencia entre los identificadores celulares presentes en la matriz de expresión y los incluidos en el fichero de metadatos, lo cual confirmó la existencia de 7930 células comunes entre ambos archivos, garantizando que cada perfil transcriptómico estuviera correctamente asociado a sus anotaciones biológicas.

Tras la alineación de los identificadores, los datos han sido integrados en un objeto `AnnData`, incorporando la matriz de expresión en `X`, los metadatos celulares en `obs`, los nombres de los genes en `var_names` y los identificadores celulares en `obs_names`.

En esta fase también se han inspeccionado las variables disponibles en los metadatos, prestando especial atención a `CellAssignment`, `GBMType` y `Sample`. La variable `CellAssignment` ha sido seleccionada como referencia supervisada principal, ya que contiene la asignación celular proporcionada por los autores del estudio y permite definir las clases del problema de clasificación.

De este modo, en esta segunda parte del experimento, el dataset queda representado de forma estructurada mediante un objeto `AnnData` en el que la matriz de expresión y los metadatos celulares presentan identificadores compatibles:

- **`adata.X`** contiene la matriz de expresión génica, con dimensiones $7\,930 \times 23\,686$ (células $\times$ genes).
- **`adata.obs_names`** almacena los identificadores de las 7 930 células, procedentes del subconjunto Smart-seq2, por ejemplo `MGH101-P1-A04`, `MGH101-P1-A05`, ...
- **`adata.var_names`** almacena los nombres de los 23 686 genes, por ejemplo `A1BG`, `A1BG-AS1`, `A1CF`, `A2M`, ...
- **`adata.obs`** incorpora los metadatos celulares asociados a cada célula, incluyendo variables como `Sample`, `GBMType`, `CellAssignment`, `GenesExpressed` y distintos programas celulares asociados al glioblastoma.

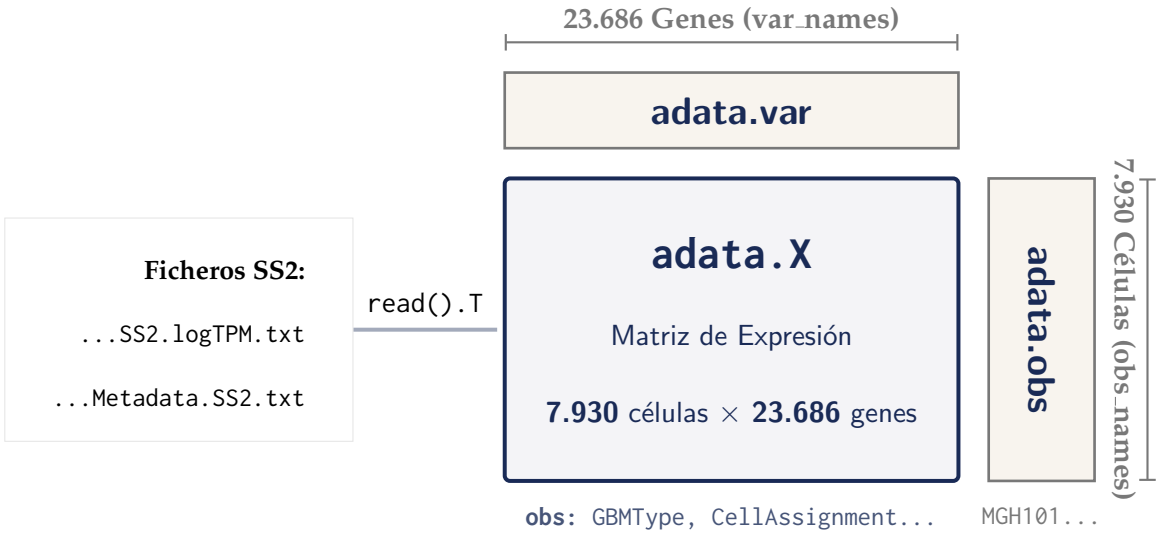


Figura 6.14: Esquema del objeto `AnnData` para el dataset Smart-seq2. Se destaca la integración de la matriz de expresión génica con los metadatos celulares (`obs`) y las anotaciones genómicas (`var`).

Métricas de calidad celular

Una vez cargado el objeto `AnnData` y completada la inspección inicial del dataset, se procede al cálculo de métricas de control de calidad (QC) sobre cada célula.

Para ello, se emplea la función `sc.pp.calculate_qc_metrics()` de la librería `Scanpy`, que incorpora automáticamente diferentes métricas descriptivas dentro de la estructura `adata.obs`. Las métricas calculadas son:

- `total_counts`: número total de lecturas o conteos detectados por célula.
- `n_genes_by_counts`: número de genes distintos detectados en cada célula.
- `pct_counts_in_top_50_genes`: porcentaje de expresión concentrado en los 50 genes más expresados de cada célula.

La métrica `total_counts` proporciona una estimación global de la profundidad de secuenciación asociada a cada célula, mientras que `n_genes_by_counts` permite evaluar la complejidad transcriptómica observada. Por otro lado, un porcentaje excesivamente elevado de expresión en un conjunto reducido de genes puede indicar perfiles celulares de baja calidad o con ruido técnico.

A continuación, se realiza un análisis estadístico descriptivo de dichas variables con el objetivo de estudiar su distribución global dentro del dataset y detectar posibles valores extremos.

Tabla 6.4: Resumen estadístico de las principales métricas de control de calidad celular.

Estadístico	total_counts	n_genes_by_counts
Count	7930.000000	7930.000000
Mean	14519.811558	5735.108953
Std	2839.279830	1422.089176
Min	4976.759348	3003.000000
25 %	12586.779318	4639.250000
50 %	14759.215134	5661.000000
75 %	16586.500544	6752.000000
Max	24183.826465	11890.000000

Posteriormente, se representan gráficamente las principales métricas mediante diagramas de violín.

En particular, el análisis de `n_genes_by_counts` y `total_counts` resulta especialmente relevante para detectar células potencialmente anómalas, ya que valores extremadamente bajos suelen asociarse a perfiles celulares incompletos o de baja calidad.

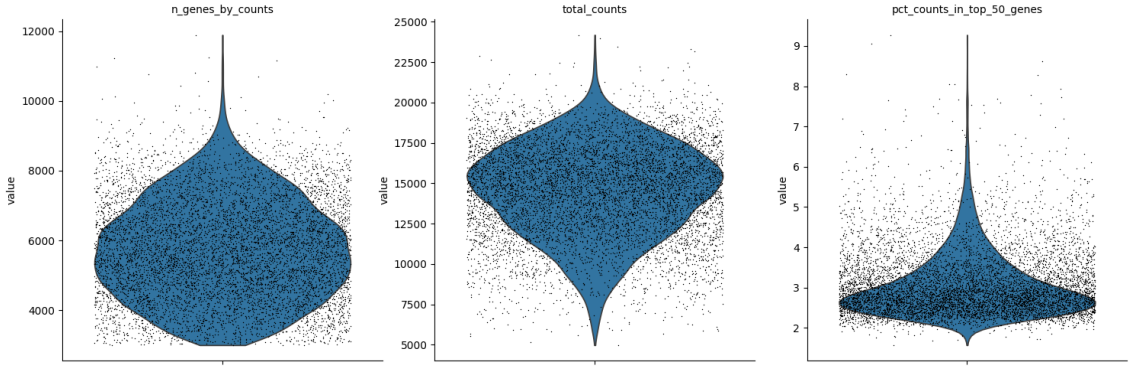


Figura 6.15: Diagramas de violín de las métricas de calidad celular calculadas sobre el subconjunto Smart-seq2: número de genes detectados por célula (`n_genes_by_counts`), número total de conteos (`total_counts`) y porcentaje de expresión concentrado en los 50 genes más expresados (`pct_counts_in_top_50_genes`).

Finalmente, se estudia la relación existente entre el número total de conteos y el número de genes detectados por célula mediante un gráfico de dispersión.

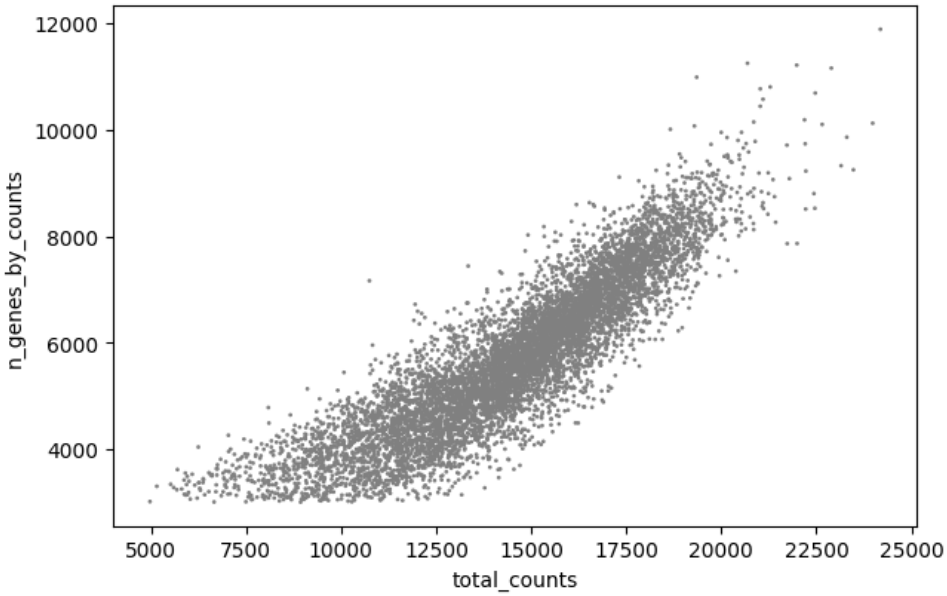


Figura 6.16: Relación entre el número total de conteos y el número de genes detectados por célula.

6.4.3. Procesamiento

Una vez construida la estructura `AnnData`, se ha aplicado un flujo completo de procesamiento utilizando la librería Scanpy.

En primer lugar, se aplica un filtrado básico para eliminar células con un número reducido de genes detectados y genes escasamente representados en el conjunto de datos. Adicionalmente, se conservaron únicamente aquellos genes detectados en al menos 20 células, reduciendo así el impacto de genes extremadamente poco frecuentes.

A continuación, se realiza una detección de dobletes mediante el algoritmo Scrublet. Este procedimiento asigna a cada célula una puntuación de doblete (`doublet_score`) basada en su similitud con perfiles transcriptómicos simulados. Las células clasificadas como potenciales dobletes fueron posteriormente eliminadas.

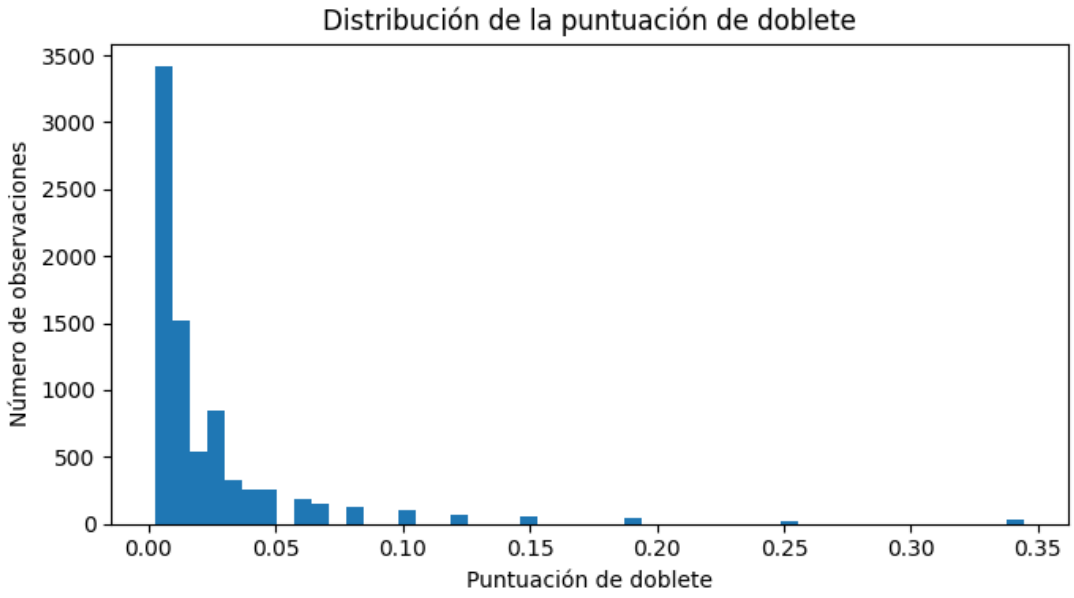


Figura 6.17: Distribución de la puntuación de doblete (`doublet_score`) sobre el subconjunto Smart-seq2. La mayoría de las células presentan valores bajos, mientras que un reducido conjunto de observaciones muestra puntuaciones elevadas compatibles con posibles dobletes.

En cuanto a la normalización, el subconjunto Smart-seq2 empleado en este experimento ya se encontraba previamente procesado y normalizado por los autores. Por lo tanto, no fue necesario aplicar etapas adicionales de normalización o transformación logarítmica.

Tras el control de calidad, se procede a la selección de características mediante la identificación de genes altamente variables (HVGs). Para ello, se seleccionaron los 2 000 genes con mayor variabilidad transcriptómica.

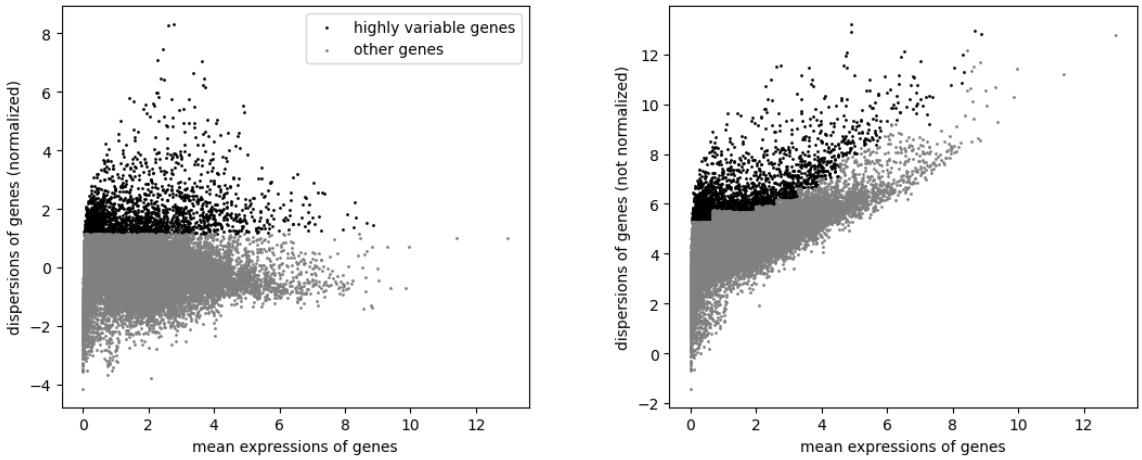


Figura 6.18: Representación de la selección de genes altamente variables. A la izquierda se muestra la dispersión normalizada frente a la expresión media de los genes, mientras que a la derecha se representa la dispersión no normalizada.

Posteriormente, se aplica un análisis de componentes principales (PCA) sobre el

subconjunto de HVGs con el objetivo de reducir la dimensionalidad de los datos y capturar las principales fuentes de variabilidad biológica. A partir de esta representación reducida se construye un grafo de vecinos utilizando `k-nearest neighbors`.

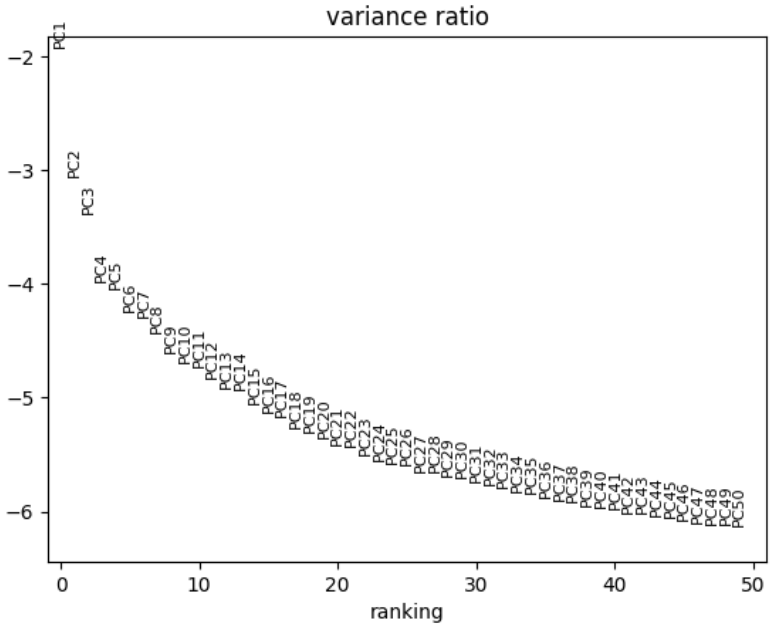


Figura 6.19: Proporción de varianza explicada por los primeros componentes principales obtenidos tras aplicar PCA sobre el subconjunto de genes altamente variables (HVGs).

Finalmente, se crearon representaciones bidimensionales mediante UMAP y t-SNE para facilitar la exploración visual de la estructura transcriptómica del dataset. Además, se ha generado una representación UMAP coloreada por `CellAssignment`.

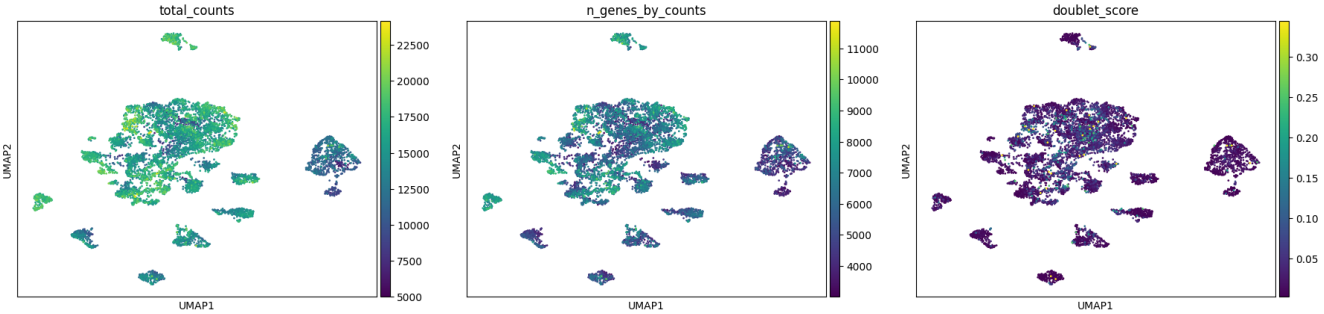


Figura 6.20: Proyección UMAP del subconjunto Smart-seq2 coloreada según distintas métricas de calidad celular: número total de conteos (`total_counts`), número de genes detectados por célula (`n_genes_by_counts`) y puntuación de doblete (`doublet_score`).

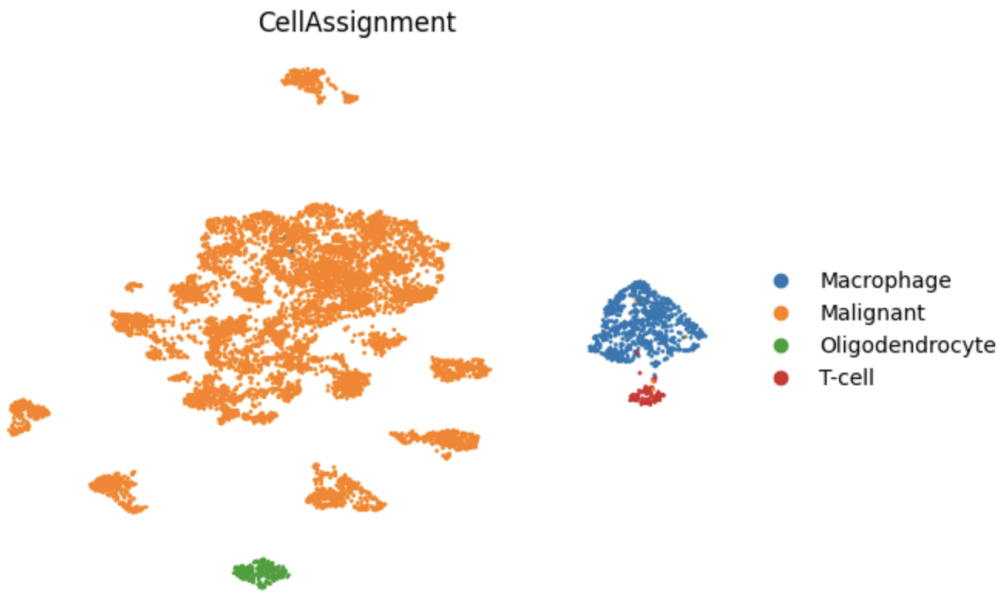


Figura 6.21: Proyección UMAP del subconjunto Smart-seq2 coloreada según la anotación biológica original `CellAssignment`.

6.4.4. Clustering

Aunque el objetivo principal de esta parte del experimento era la clasificación supervisada, también se aplicó clustering mediante el algoritmo de Leiden sobre el grafo de vecinos construido. Este análisis tuvo una función exploratoria, permitiendo comparar la estructura no supervisada de los datos.

Con el objetivo de analizar el efecto de la granularidad del clustering, se evaluaron distintas resoluciones del algoritmo, desde valores bajos que generan agrupaciones más generales hasta configuraciones más finas que producen un mayor número de clusters.

Los resultados fueron visualizados sobre la representación UMAP, permitiendo comparar visualmente la estructura celular obtenida bajo diferentes resoluciones.

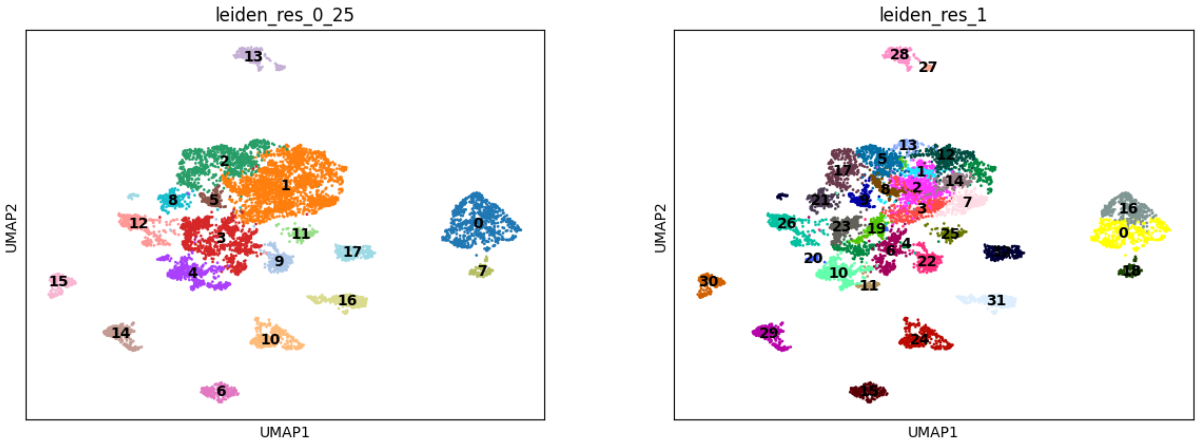


Figura 6.22: Resultados del clustering mediante Leiden representados sobre el espacio UMAP utilizando distintas resoluciones (`resolution`=0.25 y `resolution`=1.0). El incremento de la resolución produce una subdivisión progresiva de las agrupaciones celulares y una mayor granularidad en la estructura identificada.

6.4.5. Entrenamiento de modelos

Una vez completado el pipeline de preprocesamiento sobre el subconjunto Smart-seq2, se procedió al entrenamiento y evaluación de distintos modelos de clasificación supervisada orientados a la anotación automática de tipos celulares en datos de secuenciación de célula única.

Como referencia biológica se utilizó la variable `CellAssignment`, incluida en los metadatos originales del dataset y correspondiente a la anotación celular real de cada observación. Como entrada para los modelos se empleó el objeto `adata_hvg`, construido a partir de los genes altamente variables seleccionados durante el preprocesamiento.

Para garantizar una comparación homogénea entre modelos, se realizó una partición estratificada de los datos en conjuntos de entrenamiento y prueba, utilizando un 80 % de las células para entrenamiento y el 20 % restante para evaluación. Las etiquetas celulares fueron posteriormente codificadas numéricamente mediante `LabelEncoder`.

Modelos evaluados

- **SVM.** El modelo SVM se ha implementado mediante la librería `scikit-learn`, utilizando la clase `LinearSVC`. Previamente al entrenamiento, los datos fueron escalados mediante `MaxAbsScaler` y se ha aplicado ponderación balanceada de clases (`class_weight="balanced"`) para reducir el impacto del desbalanceo entre tipos celulares.
- **Random Forest.** El clasificador Random Forest se ha implementado igualmente mediante `scikit-learn`, utilizando un conjunto de 300 árboles de decisión.

- **ACTINN.** ACTINN se instaló a partir de la implementación oficial disponible en GitHub[4]. Sin embargo, fueron necesarios algunos ajustes de compatibilidad de versiones y librerías. Posteriormente, los datos de entrenamiento y prueba se transformaron al formato requerido por la herramienta (`genes` $\times$ `células`), generando los archivos de expresión y etiquetas necesarios para su ejecución.
- **CellTypist.** CellTypist se instaló directamente desde la librería oficial disponible en PyPI[5]. Para su utilización, los datos fueron adaptados al formato esperado por la herramienta, aplicando una normalización a 10.000 conteos por célula seguida de una transformación `log1p`.
- **SingleCellNet.** La implementación de SingleCellNet se ha utilizado mediante la librería `PySingleCellNet`, instalada desde su repositorio oficial en GitHub[6]. El clasificador se entrenó empleando genes discriminativos y pares génicos seleccionados automáticamente por la propia herramienta.

6.4.6. Resultados

Una vez entrenados los distintos modelos, se procedió a evaluar su rendimiento sobre el conjunto de prueba utilizando las métricas descritas previamente. La Tabla 6.5 resume los resultados obtenidos para cada clasificador.

Tabla 6.5: Resultados de clasificación sobre el subconjunto SmartSeq2 de glioblastoma

Modelo	ACC	BACC	F1	ARI	NMI
SVM	0.9994	0.9943	0.9970	0.9969	0.9918
CellTypist	0.9987	0.9941	0.9961	0.9936	0.9829
SingleCellNet	0.9987	0.9941	0.9961	0.9936	0.9829
ACTINN	0.9987	0.9812	0.9902	0.9939	0.9841
Random Forest	0.9981	0.9795	0.9893	0.9906	0.9751

[4] https://github.com/mafeiyang/ACTINN
[5] https://www.celltypist.org/
[6] https://github.com/CahanLab/PySingleCellNet

Visualización de los resultados

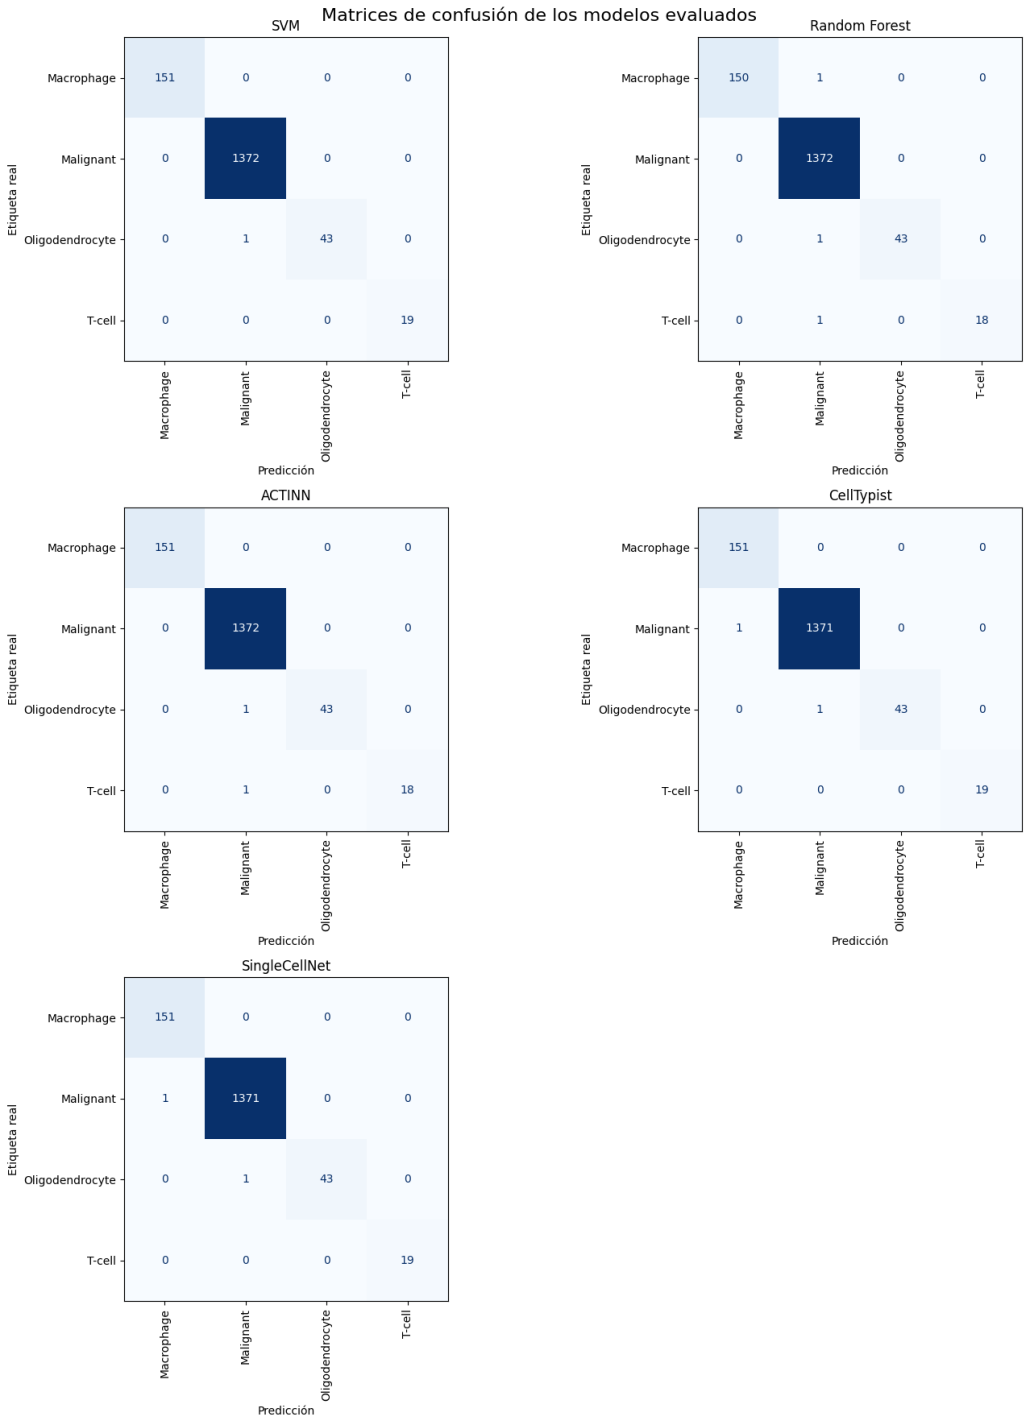


Figura 6.23: Matrices de confusión de los modelos evaluados.

6.5. Discusión

En primer lugar, el análisis del subconjunto 10X Genomics ha revelado las dificultades asociadas al trabajo con datos de célula única cuando no se dispone de

una referencia biológica directamente alineable con la matriz de expresión. Este planteamiento puede resultar eficaz desde un punto de vista exploratorio, ya que permite comprobar si los modelos son capaces de aprender la estructura transcriptómica inferida de manera no supervisada. Sin embargo, las pseudoetiquetas no equivalen a tipos celulares reales, sino a grupos detectados a partir del grafo de vecinos. Además, dichas pseudoetiquetas dependen enormemente del procesamiento y los modelos pueden llegar a aprender los sesgos del clustering.

Los resultados obtenidos sobre el subconjunto 10X muestran un rendimiento elevado en todos los modelos evaluados. SVM obtuvo el mejor resultado global, con una accuracy de 0.9627. Estos resultados indican que la estructura generada por Leiden es altamente reproducible por modelos supervisados, y que los resultados reflejan principalemente la capacidad de los modelos para reproducir las pseudoetiquetas generadas y aprender la estructura transcriptómica asociada a las mismas.

En segundo lugar y a difencia del caso anterior, el subconjunto Smart-seq2 ha permitido entrenar modelos en un entorno supervisado al disponer de anotaciones celulares mediante la variable `CellAssignment`.

Los resultados sobre Smart-seq2 fueron muy altos para todos los modelos, con valores de accuracy superiores a 0.998 en todos los casos. SVM alcanzó el mejor rendimiento global, con una accuracy de 0.9994. La elevada similitud entre las métricas sugiere que las clases definidas por `CellAssignment` presentan una separación transcriptómica muy marcada dentro del espacio de características seleccionado.

Como limitación principal, en el subconjunto 10X no se ha realizado una anotación biológica de los clusters, ya que ello requeriría un análisis adicional de genes marcadores, conversión de identificadores Ensembl y validación con estudios o expertos. Además, cabe mencionar que la utilización de pseudoetiquetas introduce una dependencia directa respecto al algoritmo Leiden y al parámetro de resolución seleccionado.

7. Conclusiones

El presente trabajo ha tenido como principal objetivo estudiar el problema de la anotación automática de tipos celulares en datos de secuenciación de ARN de célula única (scRNA-seq) mediante el estudio y evaluación de distintas técnicas de Machine Learning y Deep Learning. Durante su desarrollo, se ha llevado a cabo tanto la evaluación de modelos de clasificación como la implementación de las distintas etapas que componen el análisis de datos transcriptómicos de célula única.

Los experimentos realizados han permitido analizar la utilidad de frameworks y herramientas especializadas como DANCE o Scanpy en el contexto de la anotación celular automática, proporcionando un entorno estructurado para la integración de datasets, transformaciones y modelos. En particular, se pudo verificar que el rendimiento de los modelos depende en gran medida de las transformaciones aplicadas sobre los datos. En este sentido, se ha visto que operaciones como la normalización, la selección de genes altamente variables o la generación de distintas representaciones transcriptómicas pueden influir de forma significativa en la capacidad de discriminación de los clasificadores.

7.1. Trabajos futuros

Como líneas de trabajo futuro, una de las posibles extensiones consistiría en ampliar la evaluación experimental con un mayor número de datasets procedentes de distintas tecnologías de secuenciación y tejidos biológicos, lo que permitiría analizar con mayor profundidad la capacidad de los modelos.

Otra posible línea futura sería profundizar en el estudio de métodos diseñados específicamente para datos de single-cell, como las arquitecturas basadas en Graph Neural Networks, o los enfoques relacionados con tecnologías multimodales capaces de integrar simultáneamente la información transcriptómica, espacial o epigenética.

Utilizar e incorporar otras herramientas y entornos ampliamente utilizados en el análisis de datos single-cell, como Seurat, sería otra posible extensión del estudio. Dicho procedimiento permitiría evaluar diferencias en los flujos de trabajo, integración de datos, estrategias de anotación y reproducibilidad de resultados entre distintos ecosistemas bioinformáticos.

Asimismo, se podría ampliar en estrategias de anotación biológica en escenarios donde no se dispone de etiquetas celulares, explorando con mayor detalle métodos basados en agrupamiento celular y anotación de clústeres. Del mismo modo, también sería conveniente trabajar en enfoques más avanzados de aprendizaje no supervisado, particularmente en el estudio e interpretación biológica del los clusters, su fiabilidad y rendimiento.

Finalmente, otra posible extensión sería realizar un análisis más exhaustivo de interpretabilidad de modelos, que permita identificar qué genes contribuyen en

mayor medida a la decisión de clasificación de cada método.

8. Anexos

8.1. Anexo A. Repositorio de Github

Se adjunta el enlace al repositorio de GitHub en el que se encuentra todo el código desarrollado a lo largo de este trabajo.

Enlace: *Enlace al repositorio omitido para preservar el anonimato de la candidatura.*

8.2. Anexo B. Entorno de ejecución

Durante las primeras fases del desarrollo experimental, los cuadernos Jupyter Notebook fueron ejecutados de forma local sobre un equipo **MacBook Air con chip Apple M1 (2020)**, 16 GB de memoria RAM y sistema operativo macOS. Este entorno permitió realizar las primeras pruebas de implementación y exploración inicial de los datasets.

No obstante, conforme aumentó la complejidad de los experimentos y el volumen de datos procesados, comenzaron a aparecer limitaciones relacionadas principalmente con el tiempo de ejecución, consumo de memoria y compatibilidad entre determinadas librerías.

Debido a ello, finalmente se optó por trasladar el desarrollo experimental a **Google Colab**, aprovechando la disponibilidad de recursos computacionales en la nube y acceso a aceleración mediante GPU. Gracias a ello, se facilitó considerablemente la ejecución de los experimentos, además de simplificar la instalación de determinadas dependencias y mejorar la reproducibilidad de los cuadernos utilizados a lo largo del trabajo.

A pesar de sus ventajas, Google Colab también presentó alguna limitación durante el desarrollo experimental, especialmente relacionadas con desconexiones automáticas.

8.3. Anexo C. Dependencias del entorno de ejecución

Uno de los principales retos encontrados durante el desarrollo experimental ha estado relacionado con la configuración y compatibilidad del entorno de trabajo utilizado para la ejecución de los distintos modelos y librerías especializadas en análisis de datos scRNA-seq. En particular, la integración de herramientas como DANCE, Scanpy, PyTorch, DGL o CellTypist ha requerido numerosos ajustes de

versiones y dependencias debido a incompatibilidades entre librerías y cambios introducidos entre distintas versiones de los frameworks.

En este sentido, cabe mencionar que algunos trabajos previos y benchmarks utilizados como referencia presentan varios años de antigüedad, lo que provoca que determinadas implementaciones, dependencias o flujos de trabajo hayan quedado parcialmente desactualizados respecto al ecosistema actual de librerías bioinformáticas y frameworks. En muchos casos, las versiones originales utilizadas en dichos trabajos ya no son compatibles, o bien las propias herramientas han evolucionado, incorporando nuevas estructuras de datos o modificaciones en los procedimientos. Como consecuencia, la reproducción exacta de algunos experimentos no siempre refleja completamente las condiciones reales de trabajo existentes en la actualidad.

En particular, la utilización de la herramienta DANCE requirió tanto del empleo de entornos de ejecución y dependencias específicas, como de la adaptación de determinadas versiones y componentes del código original del framework.

La Tabla 8.1 detalla todas las dependencias, versiones utilizadas y consideraciones de compatibilidad correspondientes al entorno de ejecución empleado en el Experimento 1.

Tabla 8.1: Dependencias y versiones utilizadas en el entorno de ejecución del Experimento 1 basado en DANCE.

Librería/Dependencia	Versión / Configuración
Python	3.11.13
NumPy	1.26.4
SciPy	1.12.0
pandas	2.2.2
Scanpy	1.10.1
AnnData	0.10.8
scikit-learn	1.5.1
Numba	0.60.0
llvmlite	0.43.0
PyTorch	2.2.2
torchvision	0.17.2
DGL	1.1.3
igraph	Versión compatible
leidenalg	Versión compatible
h5py	3.11.0
mudata	0.2.3
KDEpy	1.1.9
statsmodels	≥ 0.14
scikit-misc	Versión compatible
tables	Versión compatible
omegaconf	Versión compatible
Repositorio DANCE	Clonación desde el repositorio oficial de GitHub
Parche de compatibilidad	Aplicado sobre el código fuente de DANCE, sustituyendo `from sklearn.utils import issparse` por `from scipy.sparse import issparse`

Asimismo, durante el Experimento 2 la instalación de ciertos modelos necesitaba la implementación de adaptaciones y ajustes de compatibilidad.

Por ejemplo, en el caso de ACTINN, la implementación original fue desarrollada para Python 3.6 y TensorFlow 1.x, por lo que fue necesario modificar parcialmente el código para permitir su ejecución sobre TensorFlow 2.x mediante mecanismos de compatibilidad y sustitución de funciones obsoletas. De forma similar, ciertas herramientas también requirieron ajustes relacionados con dependencias o estructuras de datos.

Tabla 8.2: Dependencias y versiones utilizadas en el Experimento 2.

Librería/Dependencia	**Versión / Configuración**
Python	3.11
pip, setuptools, wheel	Actualizadas al inicio del entorno
NumPy	1.26.4
SciPy	1.12.0
pandas	2.2.2 / 2.1.4
Matplotlib	3.8.4
Seaborn	0.13.2
Scanpy	1.10.1
AnnData	0.10.8
scikit-learn	1.5.1
h5py	3.11.0
igraph	Versión compatible
leidenalg	Versión compatible
statsmodels	≥ 0.14
KDEpy	1.1.9
jedi	$\geq 0.19.1$
tables	Versión compatible
PyTorch	2.2.2 (CPU)
torchvision	0.17.2 (CPU)
DGL	1.1.3
CellTypist	1.6.3
ACTINN	Repositorio oficial adaptado para TensorFlow 2.x
TensorFlow	Uso mediante `tensorflow.compat.v1`
PySingleCellNet	Instalación desde el repositorio oficial de GitHub

9. Glosario de términos

- **MLP (Multilayer Perceptron):** arquitectura de red neuronal formada por múltiples capas completamente conectadas que permiten aprender relaciones no lineales entre las variables de entrada y salida.
- **Autoencoder:** tipo de red neuronal artificial de aprendizaje no supervisado. Su objetivo principal es aprender a comprimir datos y luego reconstruirlos con la mayor fidelidad posible.
- **VAE (Variational Autoencoder):** tipo de modelo de inteligencia artificial (aprendizaje profundo) que aprende a comprimir datos complejos y, lo más importante, a generar datos nuevos y realistas (como imágenes o sonidos) basándose en lo que ha aprendido.
- **GNN (Graph Neural Network):** tipo de red neuronal diseñada para trabajar con estructuras en forma de grafo. En datos de célula única, permiten modelar relaciones de vecindad o similitud entre células a través de grafos celulares.
- **Modelos adversariales:** arquitecturas basadas en el entrenamiento competitivo entre dos redes neuronales, generalmente un generador y un discriminador. Se emplean en tareas como generación de datos sintéticos, integración de datos y corrección de efectos de lote.
- **RNN (Recurrent Neural Network):** tipo de red neuronal diseñada para procesar datos secuenciales o dependientes del tiempo. Estas arquitecturas incorporan conexiones recurrentes que permiten conservar información de estados anteriores, siendo especialmente útiles en tareas relacionadas con series temporales, procesamiento del lenguaje natural o modelado dinámico de procesos biológicos.
- **Embedding:** representación numérica de baja dimensionalidad que preserva relaciones estructurales o semánticas presentes en los datos originales.
- **Espacio latente:** representación comprimida de los datos generada por modelos de aprendizaje automático o profundo, utilizada para capturar patrones relevantes y reducir la dimensionalidad.
- **Pseudotiempo:** representación de procesos biológicos dinámicos que ordena células según posibles trayectorias de diferenciación o transición celular.
- **Batch effect (efecto de lote):** variación técnica no biológica introducida por diferencias experimentales entre muestras, plataformas, protocolos o laboratorios.
- **Etocástico:** todo proceso, modelo o fenómeno cuyo comportamiento está sujeto al azar o la probabilidad.

Bibliografía

[1] Dylan Molho, Jiayuan Ding, Wenzhuo Tang, Zhaoheng Li, Hongzhi Wen, Yixin Wang, Julian Venegas, Wei Jin, Renming Liu, Runze Su, Patrick Danaher, Robert Yang, Yu Leo Lei, Yuying Xie, and Jiliang Tang. Deep learning in single-cell analysis. *ACM Trans. Intell. Syst. Technol.*, 15(3), March 2024. ISSN 2157-6904. doi: 10.1145/3641284. URL https://doi.org/10.1145/3641284.

[2] SC Discoveries. 10x genomics multiome vs scrna-seq and scatac-seq, 2024. URL https://www.scdiscoveries.com/blog/10x-genomics-multiome-vs-scrna-seq-and-scatac-seq/.

[3] Chee-Huat Linus Eng, Michael Lawson, Qian Zhu, et al. Transcriptome-scale super-resolved imaging in tissues by rna seqfish+. *Nature*, 568(7751):235–239, 2019. doi: 10.1038/s41586-019-1049-y.

[4] Robert A. Amezquita, Aaron T. L. Lun, Etienne Becht, Vince J. Carey, Lindsay N. Carpp, Ludwig Geistlinger, Federico Marini, Kevin Rue-Albrecht, Davide Risso, Charlotte Soneson, Levi Waldron, Hervé Pagès, Mike L. Smith, Wolfgang Huber, Martin Morgan, Raphael Gottardo, and Stephanie C. Hicks. *Orchestrating Single-Cell Analysis with Bioconductor*. Bioconductor, 2021. URL https://bioconductor.org/books/3.13/OSCA.intro/analysis-overview.html.

[5] INTEGRA Biosciences. Single-cell rna sequencing methods: plate-, droplet- and microwell-based approaches, 2023. URL https://www.integra-biosciences.com/global/en/blog/article/single-cell-rna-sequencing-methods-plate-droplet-and-microwell-based-approaches. Accedido: 15 mayo 2026.

[6] Evan Z. Macosko, Anindita Basu, Rahul Satija, et al. Highly Parallel Genome-wide Expression Profiling of Individual Cells Using Nanoliter Droplets. *Cell*, 161 (5):1202–1214, 2015. doi: 10.1016/j.cell.2015.05.002.

[7] The Rockefeller University. Single cell rna-seq workshop - session 1, 2024. URL https://rockefelleruniversity.github.io/scRNA-seq/presentations/slides/Session1.html. Accedido: 9 mayo 2026.

[8] Lukas Heumos, Anna C. Schaar, and et al. *Single-cell best practices*, 2023. URL https://www.sc-best-practices.org. Capítulo: Normalization.

[9] Malte D. Luecken and Fabian J. Theis. Current best practices in single-cell rna-seq analysis: a tutorial. *Molecular Systems Biology*, 15(6):e8746, 2019. doi: 10.15252/msb.20188746.

[10] Yoshinori Hayakawa and Haruka Ozaki. A practical guide to single-cell transcriptomic data analysis in neuroscience. *Neuroscience Research*, 214:9–15, 2025. doi: 10.1016/j.neures.2025.03.006.

[11] Wei Vivian Li and Jingyi Jessica Li. An accurate and robust imputation method scimpute for single-cell rna-seq data. *Nature Communications*, 9(1):997, 2018. doi: 10.1038/s41467-018-03405-7.

[12] Can Chen, Chao Wu, Lin Wu, Xiaoyan Wang, Minghua Deng, and Ronglai Xi. scrmd: Imputation for single cell rna-seq data via robust matrix decomposition. *Bioinformatics*, 36(10):3156–3161, 2020. doi: 10.1093/bioinformatics/btaa138.

[13] Yuqi Tan and Patrick Cahan. Singlecellnet: A computational tool to classify single cell rna-seq data across platforms and across species. *Cell Systems*, 9(2): 207–213.e2, 7 2019. doi: 10.1016/j.cels.2019.06.004. URL https://doi.org/10.1016/j.cels.2019.06.004.

[14] Cedric Domínguez Conde, Chen Xu, Laura B. Jarvis, David B. Rainbow, Simon B. Wells, Tomás Gomes, Stephen K. Howlett, Ondrej Suchanek, Krzysztof Polański, Hannah W. King, et al. Cross-tissue immune cell analysis reveals tissue-specific features in humans. *Science*, 376(6594):eabl5197, 2022. doi: 10.1126/science.abl5197. URL https://doi.org/10.1126/science.abl5197.

[15] MathWorks. ¿qué es una máquina de vectores de soporte (svm)?, 2025. URL https://es.mathworks.com/discovery/support-vector-machine.html. Accedido: 15 de mayo de 2026.

[16] Seonwoo Min, Byunghan Lee, and Sungroh Yoon. Deep learning in bioinformatics. *Briefings in Bioinformatics*, 18(5):851–869, 2017. doi: 10.1093/bib/bbw068.

[17] Xuegong Shao, Xianwen Lu, Jie Liao, Han Chen, and Xiaowei Fan. scdeepsort: a pre-trained cell-type annotation method for single-cell transcriptomics using deep learning with a weighted graph neural network. *Nucleic Acids Research*, 49 (21):e122, 2021. doi: 10.1093/nar/gkab775. URL https://doi.org/10.1093/nar/gkab775.

[18] Jiayuan Ding, Renming Liu, Hongzhi Wen, Wenzhuo Tang, Zhaoheng Li, Julian Venegas, Runze Su, Dylan Molho, Wei Jin, Yixin Wang, et al. Dance: A deep learning library and benchmark platform for single-cell analysis. *Genome Biology*, 25(1):1–28, 2024.

[19] scverse community. Anndata documentation, 2025. URL https://anndata.readthedocs.io/en/latest/. Accedido: 15 de mayo de 2026.

[20] Isaac Virshup, Sergei Rybakov, Fabian J. Theis, Philipp Angerer, and F. Alexander Wolf. anndata: Annotated data. https://anndata.readthedocs.io, 2021. Software package for annotated data matrices in single-cell omics.

[21] Giovanni Pasquini et al. Automated methods for cell type annotation on scrna-seq data. *Computational and Structural Biotechnology Journal*, 19, 2021. doi: 10.1016/j.csbj.2021.01.015.

[22] Arjun Raj and Alexander van Oudenaarden. Nature, nurture, or chance: stochastic gene expression and its consequences. *Cell*, 135(2):216–226, 2008. doi: 10.1016/j.cell.2008.09.050.

[23] Shiyan Jia et al. The evolution of single-cell RNA sequencing technology and application: Progress and perspectives. *International Journal of Molecular Sciences*, 24(4):3602, 2023. doi: 10.3390/ijms24043602.

[24] Fuchou Tang, Catalin Barbacioru, Yangzhou Wang, Erik Nordman, Clarence Ho, Leon W. M. M. Terstappen, Myra Aranha, and M. Azim Surani. mRNA-Seq whole-transcriptome analysis of a single cell. *Nature Methods*, 6(5):377–382, May 2009. doi: 10.1038/nmeth.1315.

[25] Grace X. Y. Zheng, Jessica M. Terry, Phillip Belgrader, et al. Massively parallel digital transcriptional profiling of single cells. *Nature Communications*, 8:14049, 2017. doi: 10.1038/ncomms14049.

[26] Gokcen Eraslan, Ziga Avsec, Julien Gagneur, and Fabian J Theis. Deep learning: new computational modelling techniques for genomics. *Nature Reviews Genetics*, 20(7):389–403, 2019.

[27] David Lähnemann, Johannes Köster, Ewa Szczurek, et al. Eleven grand challenges in single-cell data science. *Genome Biology*, 21(1):31, 2020. doi: 10.1186/s13059-020-1926-6.

[28] Wenpin Hou, Zhicheng Ji, Hongkai Ji, and Stephanie C. Hicks. A systematic evaluation of single-cell rna-sequencing imbalanced cell type self-annotation methods. *Briefings in Bioinformatics*, 22(5):bbab029, 2021. doi: 10.1093/bib/bbab029.

[29] Jiarui Ding et al. Dance: a deep learning library and benchmark for single-cell analysis. *bioRxiv*, 2022.

[30] Glassdoor. Machine learning engineer salaries in spain, 2024. URL https://www.glassdoor.es.

[31] Seguridad Social. Bases y tipos de cotización 2024, 2024. URL https://www.seg-social.es.

[32] R. Moncada, D. Barkley, F. Wagner, M. Chiodin, J. C. Devlin, M. Baron, C. H. Hajdu, D. M. Simeone, and I. Yanai. Integrating microarray-based spatial transcriptomics and single-cell rna-seq reveals tissue architecture in pancreatic ductal adenocarcinomas. *Nature Biotechnology*, 38(3):333–342, Mar 2020. doi: 10.1038/s41587-019-0392-8. Erratum in: Nat Biotechnol. 2020 Dec;38(12):1476. doi: 10.1038/s41587-020-00776-5.

[33] Simone Picelli, Åsa K. Björklund, Omid R. Faridani, et al. Smart-seq2 for sensitive full-length transcriptome profiling in single cells. *Nature Methods*, 10 (11):1096–1098, 2013. doi: 10.1038/nmeth.2639.

[34] Cole Trapnell, Davide Cacchiarelli, Jonna Grimsby, et al. The dynamics and regulators of cell fate decisions are revealed by pseudotemporal ordering of single cells. *Nature Biotechnology*, 32(4):381–386, 2014. doi: 10.1038/nbt.2859.

[35] Jason D. Buenrostro, Beijing Wu, Ulrike M. Litzenburger, et al. Single-cell chromatin accessibility reveals principles of regulatory variation. *Nature*, 523 (7561):486–490, 2015. doi: 10.1038/nature14590.

[36] Yibo Liu, Andreas Beyer, and Ruedi Aebersold. On the dependency of cellular protein levels on mrna abundance. *Cell*, 165(3):535–550, 2016. doi: 10.1016/j.cell.2016.03.014.

[37] Marlon Stoeckius, Christoph Hafemeister, William Stephenson, et al. Simultaneous epitope and transcriptome measurement in single cells. *Nature Methods*, 14(9):865–868, 2017. doi: 10.1038/nmeth.4380.

[38] Song Chen, Blue B. Lake, and Kun Zhang. Snare-seq: simultaneous profiling of gene expression and chromatin accessibility in single cells. *Nature Biotechnology*, 37(12):1452–1457, 2019. doi: 10.1038/s41587-019-0290-0.

[39] Sai Ma, Bingjie Zhang, Lindsay M. LaFave, et al. Chromatin potential delineates lineage specification pathways. *Nature*, 583(7817):611–616, 2020. doi: 10.1038/s41586-020-2464-z.

[40] Patrik L. Ståhl, Fredrik Salmén, Sanja Vickovic, et al. Visualization and analysis of gene expression in whole tissue sections by spatial transcriptomics. *Science*, 353(6294):78–82, 2016. doi: 10.1126/science.aaf2403.

[41] Samuel G. Rodriques, Robert R. Stickels, Anna Goeva, et al. Slide-seq: A scalable technology for measuring whole-genome expression at high spatial resolution. *Science*, 363(6434):1463–1467, 2019. doi: 10.1126/science.aaw1219.

[42] Dylan M. Cable, Evan Murray, James S. Zou, et al. Robust decomposition of cell type mixtures in spatial transcriptomics. *Nature Biotechnology*, 40(4):517–526, 2021. doi: 10.1038/s41587-021-00830-w.

[43] Aviv Regev et al. The science and applications of the human cell atlas. *bioRxiv*, 2017. doi: 10.1101/121202.

[44] Jiangping He, Lihui Lin, and Jiekai Chen. Practical bioinformatics pipelines for single-cell RNA-seq data analysis. *Biophysics Reports*, 8(3):158–169, 2022. doi: 10.52601/bpr.2022.210041. URL https://pmc.ncbi.nlm.nih.gov/articles/PMC10189648/.

[45] Constantin Ahlmann-Eltze and Wolfgang Huber. Transformation and preprocessing of single-cell rna-seq data. *Nature Reviews Genetics*, 24(9):585–602, 2023. doi: 10.1038/s41576-023-00586-w.

[46] Robert Dorfman. A note on the δ-method for finding variances. *Biometrika*, 30 (1/2):129–137, 1938.

[47] Philip Brennecke, Simon Anders, Joohee K. Kim, et al. Accounting for technical noise in single-cell rna-seq experiments. *Nature Methods*, 10(11):1093–1095, 2013. doi: 10.1038/nmeth.2645.

[48] Allon M. Klein, Linas Mazutis, Ilke Akartuna, et al. Droplet barcoding for single-cell transcriptomics applied to embryonic stem cells. *Cell*, 161(5):1187–1201, 2015. doi: 10.1016/j.cell.2015.04.044.

[49] Ruizhi Xiang, Wencan Wang, Lei Yang, Shiyuan Wang, Chaohan Xu, and Xiaowen Chen. A comparison for dimensionality reduction methods of single-cell rna-seq data. *Frontiers in Genetics*, 12, 2021. doi: 10.3389/fgene.2021.646936.

[50] Leland McInnes, John Healy, and James Melville. Umap: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*, 2018.

[51] Etienne Becht, Leland McInnes, John Healy, Charles-Antoine Dutertre, Immanuel W. H. Kwok, Lai Guan Ng, Florent Ginhoux, and Evan W. Newell. Dimensionality reduction for visualizing single-cell data using umap. *Nature Biotechnology*, 37(1):38–44, 2019. doi: 10.1038/nbt.4314.

[52] J. MacQueen. Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297, 1967.

[53] F Alexander Wolf, Fiona K Hamey, Mireya Plass, et al. Paga: graph abstraction reconciles clustering with trajectory inference through a topology preserving map of single cells. *Genome Biology*, 20(1):59, 2019.

[54] Jacob H. Levine, Erin F. Simonds, Sean C. Bendall, Kara L. Davis, El-ad D. Amir, Michelle D. Tadmor, Oren Litvin, Harris G. Fienberg, Abraham Jager, Eric R. Zunder, Rachel Finck, Amanda L. Gedman, Igor Radtke, James R. Downing, Dana Pe'er, and Garry P. Nolan. Data-driven phenotypic dissection of aml reveals progenitor-like cells that correlate with prognosis. *Cell*, 162(1):184–197, 2015. doi: 10.1016/j.cell.2015.05.047.

[55] Vincent D. Blondel, Jean-Loup Guillaume, Renaud Lambiotte, and Etienne Lefebvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10):P10008, 2008. doi: 10.1088/1742-5468/2008/10/P10008.

[56] F Alexander Wolf, Philipp Angerer, and Fabian J Theis. Scanpy: large-scale single-cell gene expression data analysis. *Genome Biology*, 19(1):15, 2018.

[57] Rahul Satija, Jeffrey A. Farrell, David Gennert, Alexander F. Schier, and Aviv Regev. Spatial reconstruction of single-cell gene expression data. *Nature Biotechnology*, 33(5):495–502, 2015. doi: 10.1038/nbt.3192.

[58] Ang Duo, Mark D. Robinson, and Charlotte Soneson. A systematic performance evaluation of clustering methods for single-cell rna-seq data. *F1000Research*, 7:1141, 2018. doi: 10.12688/f1000research.15666.1.

[59] Saskia Freytag, Luyi Tian, Ingrid Lönnstedt, Michael Ng, and Melanie Bahlo. Comparison of clustering tools in r for medium-sized 10x genomics single-cell sequencing data. *F1000Research*, 7:1297, 2018. doi: 10.12688/f1000research.15809.2.

[60] Lukas M. Weber and Mark D. Robinson. Comparison of clustering methods for high-dimensional single-cell flow and mass cytometry data. *Cytometry Part A*, 89 (12):1084–1096, 2016. doi: 10.1002/cyto.a.23030.

[61] Vincent A. Traag, Ludo Waltman, and Nees Jan van Eck. From louvain to leiden: guaranteeing well-connected communities. *Scientific Reports*, 9(1):5233, 2019. doi: 10.1038/s41598-019-41695-z.

[62] Amit Zeisel, Hannah Hochgerner, Peter Lönnerberg, et al. Molecular architecture of the mouse nervous system. *Cell*, 174(4):999–1014, 2018.

[63] Wouter Saelens, Robrecht Cannoodt, Hristo Todorov, and Yvan Saeys. A comparison of single-cell trajectory inference methods. *Nature Biotechnology*, 37 (5):547–554, 2019.

[64] Laleh Haghverdi, Maren Büttner, F Alexander Wolf, Florian Buettner, and Fabian J Theis. Diffusion pseudotime robustly reconstructs lineage branching. *Nature Methods*, 13(10):845–848, 2016.

[65] Kelly Street, Davide Risso, Ryan B Fletcher, et al. Slingshot: cell lineage and pseudotime inference for single-cell transcriptomics. *BMC Genomics*, 19(1):477, 2018.

[66] Gioele La Manno, Ruslan Soldatov, Amit Zeisel, et al. Rna velocity of single cells. *Nature*, 560(7719):494–498, 2018.

[67] Volker Bergen, Marius Lange, Stefan Peidli, F Alexander Wolf, and Fabian J Theis. Generalizing rna velocity to transient cell states through dynamical modeling. *Nature Biotechnology*, 38(12):1408–1414, 2020.

[68] Catalina A Vallejos, Davide Risso, Antonio Scialdone, Sandrine Dudoit, and John C Marioni. Normalizing single-cell rna sequencing data: challenges and opportunities. *Nature Methods*, 14(6):565–571, 2017.

[69] Stephanie C Hicks, F William Townes, Mingxiang Teng, and Rafael A Irizarry. Missing data and technical variability in single-cell rna-sequencing experiments. *Biostatistics*, 19(4):562–578, 2018.

[70] Greg Finak, Andrew McDavid, Masanao Yajima, et al. Mast: a flexible statistical framework for assessing transcriptional changes and characterizing heterogeneity in single-cell rna sequencing data. *Genome Biology*, 16(1):278, 2015.

[71] Jianfeng Zou et al. sccode: a robust framework for differential expression analysis in single-cell rna-seq data. *Briefings in Bioinformatics*, 23(6):bbac455, 2022.

[72] Michael Ashburner, Catherine A Ball, Judith A Blake, et al. Gene ontology: tool for the unification of biology. *Nature Genetics*, 25(1):25–29, 2000.

[73] Minoru Kanehisa, Miho Furumichi, Mao Tanabe, Yoko Sato, and Kanae Morishima. Kegg: new perspectives on genomes, pathways, diseases and drugs. *Nucleic Acids Research*, 45(D1):D353–D361, 2017.

[74] Marc Gillespie, Bijay Jassal, Ralf Stephan, et al. The reactome pathway knowledgebase 2022. *Nucleic Acids Research*, 50(D1):D687–D692, 2022.

[75] Yoshua Bengio, Aaron Courville, and Pascal Vincent. Representation learning: A review and new perspectives. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(8):1798–1828, 2013.

[76] Vladimir Yu Kiselev et al. Challenges in unsupervised clustering of single-cell rna-seq data. *Nature Reviews Genetics*, 20:273–282, 2019.

[77] Wei Vivian Hou, Zhe Ji, Hongkai Ji, and Stephanie C. Hicks. A systematic evaluation of single-cell rna-sequencing imputation methods. *Genome Biology*, 21(1):218, 2020. doi: 10.1186/s13059-020-02132-x.

[78] Mengyuan Wang, Jiatao Gan, Changfeng Han, Yanbing Guo, Kaihao Chen, Yazhou Shi, and Ben-gong Zhang. Imputation methods for scrna sequencing data. *Applied Sciences*, 12(20):10684, 2022. doi: 10.3390/app122010684.

[79] Mo Huang, Jingshu Wang, Eduardo Torre, Hannah Dueck, Sydney Shaffer, Roberto Bonasio, John I. Murray, Arjun Raj, Mingyao Li, and Nancy R. Zhang. Saver: gene expression recovery for single-cell rna sequencing. *Nature Methods*, 15(7):539–542, 2018. doi: 10.1038/s41592-018-0033-z.

[80] Jingshu Wang, Dhiren Agarwal, Mo Huang, Guanghua Hu, Zilu Zhou, Cheng Ye, and Nancy R. Zhang. Data denoising with transfer learning in single-cell transcriptomics. *Nature Methods*, 16(9):875–878, 2019. doi: 10.1038/s41592-019-0537-1.

[81] Peilin Lin, Michael Troup, and John W.K. Ho. Cidr: ultrafast and accurate clustering through imputation for single-cell rna-seq data. *Genome Biology*, 18 (1):59, 2017. doi: 10.1186/s13059-017-1188-0.

[82] Arnav Mongia, Dhruba Sengupta, and Angshul Majumdar. Mcimpute: Matrix completion based imputation for single cell rna-seq data. *Frontiers in Genetics*, 10:9, 2019. doi: 10.3389/fgene.2019.00009.

[83] Florian Wagner, Yichao Yan, and Itai Yanai. K-nearest neighbor smoothing for high-throughput single-cell rna-seq data. *bioRxiv*, page 217737, 2018. doi: 10.1101/217737.

[84] Anton Tjärnberg, Omar Mahmood, Christopher A. Jackson, Giuseppe-Amar Saldi, Kyuho Cho, Lionel A. Christiaen, and Richard A. Bonneau. Optimal tuning of weighted knn- and diffusion-based methods for denoising single cell genomics data. *PLoS Computational Biology*, 17(1):e1008569, 2021. doi: 10.1371/journal.pcbi.1008569.

[85] César Arisdakessian, Olivier Poirion, Benjamin Yunits, Xun Zhu, and Lana X. Garmire. Deepimpute: an accurate, fast, and scalable deep neural network method to impute single-cell rna-seq data. *Genome Biology*, 20(1):211, 2019. doi: 10.1186/s13059-019-1837-6.

[86] Romain Lopez, Jeffrey Regier, Michael B. Cole, Michael I. Jordan, and Nir Yosef. Deep generative modeling for single-cell transcriptomics. *Nature Methods*, 15(12): 1053–1058, 2018. doi: 10.1038/s41592-018-0229-2.

[87] Tallulah S. Andrews and Martin Hemberg. False signals induced by single-cell imputation. *F1000Research*, 7:1740, 2018. doi: 10.12688/f1000research.16613.2.

[88] Dvir Aran, Alexander P. Looney, Ling Liu, et al. Reference-based analysis of lung single-cell sequencing reveals a transitional profibrotic macrophage. *Nature Immunology*, 20(2):163–172, 2019. doi: 10.1038/s41590-018-0276-y.

[89] Tamim Abdelaal et al. A comparison of automatic cell identification methods for single-cell rna sequencing data. *Genome Biology*, 20, 2019. doi: 10.1186/s13059-019-1794-7.

[90] Jose Alquicira-Hernandez, Anushree Sathe, Houtao Paul Ji, Quan Nguyen, and Joseph E Powell. scpred: accurate supervised method for cell-type classification from single-cell rna-seq data. *Genome Biology*, 20(1):264, 2019.

[91] Hannah A Pliner, Jay Shendure, and Cole Trapnell. Supervised classification enables rapid annotation of cell atlases. *Nature Methods*, 16(10):983–986, 2019.

[92] Yiqiao Lin, Yang Cao, Hyejin Kim, Asad Salim, Terence P Speed, David M Lin, and Pengyi Yang. scclassify: sample size estimation and multiscale classification of cells using single and multiple reference. *Molecular Systems Biology*, 16(6): e9389, 2020.

[93] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995. doi: 10.1007/BF00994018. URL https://doi.org/10.1007/BF00994018.

[94] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521 (7553):436–444, 2015. doi: 10.1038/nature14539.

[95] Feiyang Ma and Matteo Pellegrini. Actinn: automated identification of cell types in single cell rna sequencing. *Bioinformatics*, 36(2):533–538, 2020. doi: 10.1093/bioinformatics/btz592. URL https://doi.org/10.1093/bioinformatics/btz592.

[96] Adam Paszke, Sam Gross, Francisco Massa, et al. Pytorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32, 2019.

[97] Martín Abadi, Ashish Agarwal, Paul Barham, et al. Tensorflow: Large-scale machine learning on heterogeneous systems. In *12th USENIX Symposium on Operating Systems Design and Implementation*, pages 265–283, 2016.

[98] François Chollet et al. Keras. https://keras.io, 2015.

[99] Minjie Wang, Lingfan Yu, Da Zheng, et al. Deep graph library: Towards efficient and scalable deep learning on graphs. *arXiv preprint arXiv:1909.01315*, 2019.

[100] Matthias Fey and Jan E Lenssen. Fast graph representation learning with pytorch geometric. *ICLR Workshop on Representation Learning on Graphs and Manifolds*, 2019.

[101] Riccardo Miotto, Fei Wang, Shuang Wang, Xiaoqian Jiang, and Joel T. Dudley. Deep learning for healthcare: review, opportunities and challenges. *Briefings in Bioinformatics*, 19(6):1236–1246, 11 2018. doi: 10.1093/bib/bbx044. URL https://doi.org/10.1093/bib/bbx044.

[102] Jiayuan Ding, Zhongyu Xing, Yixin Wang, Renming Liu, Sheng Liu, Zhi Huang, Wenzhuo Tang, Yuying Xie, James Zou, Xiaojie Qiu, et al. Dance 2.0: Transforming single-cell analysis from black box to transparent workflow. *bioRxiv*, pages 2025–07, 2025.

[103] F. Alexander Wolf, Philipp Angerer, and Fabian J. Theis. Scanpy: large-scale single-cell gene expression data analysis. *Genome Biology*, 19(1):15, 2018. doi: 10.1186/s13059-017-1382-0.

[104] Juntuo Ding et al. Dance: A deep learning library for single-cell analysis. *arXiv preprint arXiv:2205.03377*, 2022.

[105] Xiaoping Han et al. Mapping the mouse cell atlas by microwell-seq. *Cell*, 172(5): 1091–1107, 2018.

[106] David N. Louis, Arie Perry, Guido Reifenberger, Andreas von Deimling, Dominique Figarella-Branger, Webster K. Cavenee, Hiroko Ohgaki, Otmar D. Wiestler, Paul Kleihues, and David W. Ellison. The 2016 world health organization classification of tumors of the central nervous system: a summary. *Acta Neuropathologica*, 131(6):803–820, 2016. doi: 10.1007/s00401-016-1545-1.

[107] W. Tang, C. W. S. Lo, A. T. W. Chu, et al. Mapping glioblastoma's isoform diversity using long-read single-cell analysis. *Nature Communications*, 2026. doi: 10.1038/s41467-026-72258-2. Received: 13 October 2025; Accepted: 13 April 2026; Published: 23 April 2026.

[108] Mariella G. Filbin et al. Cyril Neftel, Julie Laffy. An integrative model of cellular states, plasticity, and genetics for glioblastoma. *Cell*, 178(4):835–849.e21, 2019. ISSN 0092-8674. doi: https://doi.org/10.1016/j.cell.2019.06.024. URL https://www.sciencedirect.com/science/article/pii/S0092867419306877.

[109] Roel G.W. Verhaak, Katherine A. Hoadley, Elizabeth Purdom, et al. Integrated genomic analysis identifies clinically relevant subtypes of glioblastoma characterized by abnormalities in pdgfra, idh1, egfr, and nf1. *Cancer Cell*, 17(1): 98–110, 2010. doi: 10.1016/j.ccr.2009.12.020.

[110] Qiang Wang, Bin Hu, Xiaoyu Hu, et al. Gene expression profiling reveals molecular subtypes and intratumoral heterogeneity in glioblastoma. *Genome Medicine*, 9(1):20, 2017. doi: 10.1186/s13073-017-0412-8.

[111] Anoop P. Patel, Itay Tirosh, John J. Trombetta, et al. Single-cell rna-seq highlights intratumoral heterogeneity in primary glioblastoma. *Science*, 344(6190):1396–1401, 2014. doi: 10.1126/science.1254257.

[112] Andrea Sottoriva, Inmaculada Spiteri, Sara G.M. Piccirillo, et al. Intratumor heterogeneity in human glioblastoma reflects cancer evolutionary dynamics. *Proceedings of the National Academy of Sciences*, 110(10):4009–4014, 2013. doi: 10.1073/pnas.1219747110.

[113] Amos Tanay and Aviv Regev. Scaling single-cell genomics from phenomenology to mechanism. *Nature*, 541(7637):331–338, 2017. doi: 10.1038/nature21350.

[114] Itay Tirosh and Mario L. Suvà. Deciphering human tumor biology by single-cell expression profiling. *Annual Review of Cancer Biology*, 3:151–166, 2019. doi: 10.1146/annurev-cancerbio-030518-055609.

[115] Spyros Darmanis, Steven A. Sloan, Derek Croote, et al. Single-cell rna-seq analysis of infiltrating neoplastic cells at the migrating front of human glioblastoma. *Cell Reports*, 21(5):1399–1410, 2017. doi: 10.1016/j.celrep.2017.10.030.